KNN算法

黑马程序员
www.itheima.com
传智教育旗下
高端IT教育品牌

目录

Contents

- KNN算法简介
  KNN思想、分类和回归问题处理流程
- KNN算法API介绍
  分类、回归实现
- 距离度量
  常用距离计算方法
- 特征预处理
  归一化、标准化

学习目标

Learning Objectives

1. 理解K近邻算法的思想
2. 知道K近邻算法分类流程
3. 知道K近邻算法回归流程

KNN

- K-近邻算法（K Nearest Neighbor，简称KNN）。比如：根据你的“邻居”来推断出你的类别

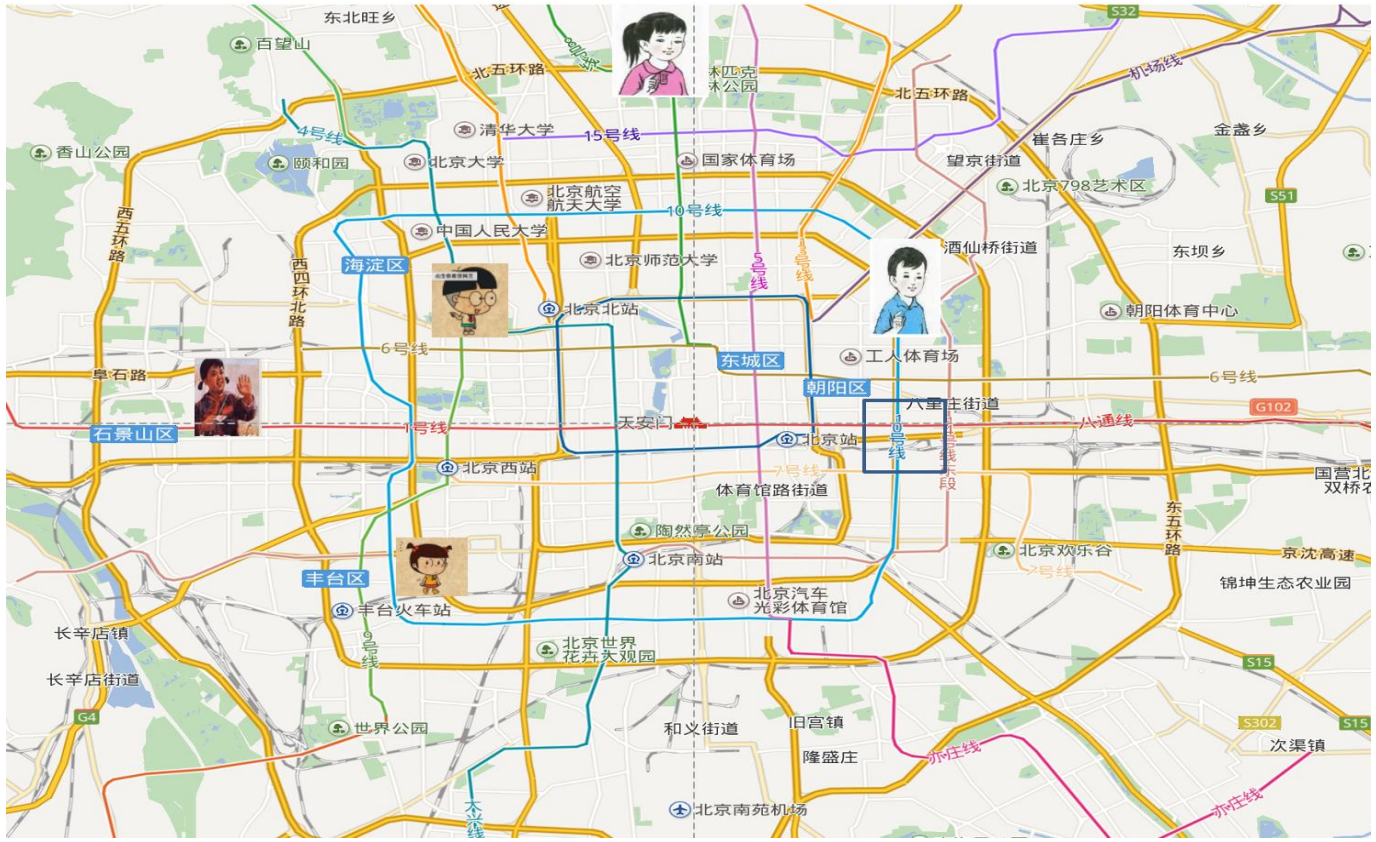

- KNN算法思想：如果一个样本在特征空间中的 k 个最相似的样本中的大多数属于某一个类别，则该样本也属于这个类别

思考：如何确定样本的相似性？

KNN算法

- 解决问题：分类问题、回归问题
- 算法思想：若一个样本在特征空间中的 k 个最相似的样本大多数属于某一个类别，则该样本也属于这个类别
- 相似性：欧氏距离

分类流程

1. 计算未知样本到每一个训练样本的距离
2. 将训练样本根据距离大小升序排列
3. 取出距离最近的 K 个训练样本
4. 进行多数表决，统计 K 个样本中哪个类别的样本个数最多
5. 将未知的样本归属到出现次数最多的类别

回归流程

1. 计算未知样本到每一个训练样本的距离
2. 将训练样本根据距离大小升序排列
3. 取出距离最近的 K 个训练样本
4. 把这个 K 个样本的目标值计算其平均值
5. 作为将未知的样本预测的值

总结

1 KNN概念 K Nearest Neighbor

- 一个样本最相似的 k 个样本中的大多数属于某一个类别，则该样本也属于这个类别

2 KNN分类流程

1. 计算未知样本到每一个训练样本的距离
2. 将训练样本根据距离大小升序排列
3. 取出距离最近的 K 个训练样本
4. 进行多数表决，统计 K 个样本中哪个类别的样本个数最多
5. 将未知的样本归属到出现次数最多的类别

3 KNN回归流程

1. 计算未知样本到每一个训练样本的距离
2. 将训练样本根据距离大小升序排列
3. 取出距离最近的 K 个训练样本
4. 把这个 K 个样本的目标值计算其平均值
5. 将未知的样本预测的值了

目录

Contents

- KNN算法简介
  KNN思想、分类和回归问题处理流程
- KNN算法API介绍
  分类、回归实现
- 距离度量
  常用距离计算方法
- 特征预处理
  归一化、标准化

学习目标

Learning Objectives

1. 掌握KNN算法分类API
2. 掌握KNN算法回归API

练习 KNN算法API使用 - 分类问题

- KNN分类API

  sklearn.neighbors.KNeighborsClassifier(n_neighbors=5)

  n_neighbors：int,可选（默认= 5），k_neighbors查询默认使用的邻居数

```
from sklearn.neighbors import KNeighborsClassifier
def dm01_knnapi_分类():
    estimator =  KNeighborsClassifier(n_neighbors=1)
    X = [[0], [1], [2], [3]]
    y = [0, 0, 1, 1]
    estimator.fit(X, y)
    myret = estimator.predict([[4]])
    print('myret-->', myret)
```

练习

KNN算法API使用 - 回归问题

KNN回归API：

`sklearn.neighbors.KNeighborsRegressor(n_neighbors=5)`

```
from sklearn.neighbors import KNeighborsRegressor
def dm02_knnapi_回归():
    estimator =  KNeighborsRegressor(n_neighbors=2)
    X = [[0, 0, 1],
        [1, 1, 0],
        [3, 10, 10],
        [4, 11, 12]]
    y = [0.1, 0.2, 0.3, 0.4]
    estimator.fit(X, y)
    myret = estimator.predict([[3, 11, 10]])
    print('myret-->', myret)
```

学习目标

Learning Objectives

1. 掌握欧氏距离的计算方法
2. 掌握曼哈顿距离的计算方法
3. 了解切比雪夫距离的计算方法
4. 了解闵可夫斯基距离的计算方法

距离度量 distance measure - 常见距离公式

距离类型	核心思想	关键参数	对异常值敏感性	适用场景
欧氏距离	直线最短距离	$p = 2$	高	连续数值、低维空间（如KNN
曼哈顿距离	各维度差异绝对值之和	$p = 1$	中	高维稀疏数据、离散特征
切比雪夫距离	仅关注最大维度差异	$p \to \infty$	极高	极值主导场景（如路径规划）
闵可夫斯基距离	通过 p 灵活调整距离性质	任意 p	依赖 p	需平衡不同维度差异的通用场

距离度量 distance measure - 常见距离公式

$$d_{12} = \sqrt[p]{\sum_{k=1}^{n} \left| x_{1k} - x_{2k} \right|^{p}}$$

其中p是一个变参数：

当 p=1 时，就是曼哈顿距离；

当 p=2 时，就是欧氏距离；

当 p→∞ 时，就是切比雪夫距离

根据 p 的不同，闵氏距离可表示某一类种的距离

目录

Contents

- KNN算法简介
  KNN思想、分类和回归问题处理流程
- KNN算法API介绍
  分类、回归实现
- 距离度量
  常用距离计算方法
- 特征预处理
  归一化、标准化

学习目标

Learning Objectives

1. 知道为什么进行归一化、标准化
2. 能应用归一化API处理数据
3. 能应用标准化API处理数据
4. 使用KNN算法进行鸢尾花分类

特征预处理

- 为什么做归一化和标准化 ？

特征的**单位或者大小相差较大，或者某特征的方差相比其他的特征要大出几个数量级，容易影响（支配）目标结果**，使得一些模型（算法）无法学习到其它的特征。

编号	身高 m	体重 kg	视力 0.2-2.0	健康状况
1	1.70	67	1.5	1
2	1.71	80	0.8	2
3	1.75	70	1.5	1
4	1.76	68	1.2	1
5	1.80	80	1.8	1
6	1.81	90	0.6	2
男子身高体重视力与健康关系表 健康为1 不健康为2				

特征预处理

- 归一化：通过对原始数据进行变换把数据映射到【mi,mx】(默认为[0,1])之间

$$X' = \frac{x - min}{max - min} \qquad X'' = X' * (mx - mi) + mi$$

特征1	特征2	特征3	特征4
90	2	10	40
60	4	15	45
75	3	13	46

特征1	特征2	特征3	特征4
$\frac{90-60}{90-60}$	$\frac{2-2}{4-2}$	$\frac{10-10}{15-10}$	$\frac{40-40}{46-40}$
$\frac{60-60}{90-60}$	$\frac{4-2}{4-2}$	$\frac{15-10}{15-10}$	$\frac{45-40}{46-40}$
$\frac{75-60}{90-60}$	$\frac{3-2}{4-2}$	$\frac{13-10}{15-10}$	$\frac{46-40}{46-40}$

注：里面是第一步，还需要第二步乘以(1-0)+0

特征1	特征2	特征3	特征4
1.	0.	0.	0.
0.	1.	1.	0.83
0.5	0.5	0.6	1.

特征预处理

- 数据归一化：通过对原始数据进行变换把数据映射到【mi, mx】(默认为[0, 1])之间

数据归一化API：

1. sklearn.preprocessing.MinMaxScaler (feature_range=(0,1)…)
   feature_range 缩放区间
2. fit_transform(X) 将特征进行归一化缩放

```python
import numpy as np
from sklearn.preprocessing import MinMaxScaler

def dm01_MinMaxScaler():
 # 1. 准备数据
   data = [[90, 2, 10, 40],
         [60, 4, 15, 45],
         [75, 3, 13, 46]]

   # 2. 初始化归一化对象
   transformer = MinMaxScaler()

   # 3. 对原始特征进行变换
   data = transformer.fit_transform(data)

   # 4. 打印归一化后的结果
   print(data)
```

特征预处理

- 数据标准化：通过对原始数据进行标准化，转换为均值为0标准差为1的标准正态分布的数据

$$X' = \frac{x - \text{mean}}{\sigma}$$

mean 为特征的平均值

σ 为特征的标准差

数据标准化API：

1. sklearn.preprocessing. StandardScaler()
2. fit_transform(X) 将特征进行归一化缩放

```
from sklearn.preprocessing import StandardScaler
def dm03_StandardScaler():      # 对特征值进行标准化
    # 1. 准备数据
    data = [[90, 2, 10, 40],
            [60, 4, 15, 45],
            [75, 3, 13, 46]]

    # 2. 初始化标准化对象
    transformer = StandardScaler()

    # 3. 对原始特征进行变换
    data = transformer.fit_transform(data)

    # 4. 打印归一化后的结果
    print(data)

    # 5 打印每1列数据的均值和标准差
    print('transfer.mean_-->', transfer.mean_)
    print('transfer.var_-->', transfer.var_)
```

特征预处理

数据归一化

- 如果出现异常点，影响了最大值和最小值，那么结果显然会发生改变
- 应用场景：最大值与最小值非常容易受异常点影响，鲁棒性较差，只适合传统精确小数据场景
- sklearn.preprocessing.MinMaxScaler (feature_range=(0,1)…)

数据标准化

- 如果出现异常点，由于具有一定数据量，少量的异常点对于平均值的影响并不大
- 应用场景：适合现代嘈杂大数据场景。(以后就是用你了)
- sklearn.preprocessing.StandardScaler( )

黑马程序员

www.itheima.com

传智教育旗下高端IT教育品牌