线性回归

黑马程序员
www.itheima.com
传智教育旗下
高端IT教育品牌

目录

Contents

- 线性回归简介
  定义、线性回归的分类、应用场景
- 线性回归问题的求解
  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法
- 回归模型评估方法
  MAE、MSE、RMSE
- 线性回归API和梯度下降API
  波斯顿案例

学习目标

Learning Objectives

1. 理解线性回归是什么？
2. 知道一元线性回归和多元线性回归的区别
3. 知道线性回归的应用场景

线性回归概念 - 举个栗子

- 假如有了以下身高和体重数据. 假如已知播仔的身高，你能预测播仔体重吗？

编号	身高	体重
1	160	56.3
2	166	60.6
3	172	65.1
4	174	68.5
5	180	75
6	176	?

- 这样的问题是回归问题，该如何求解呢？

线性回归概念 - 举个栗子

- 思路：先从已知身高X和体重Y中找规律，再预测

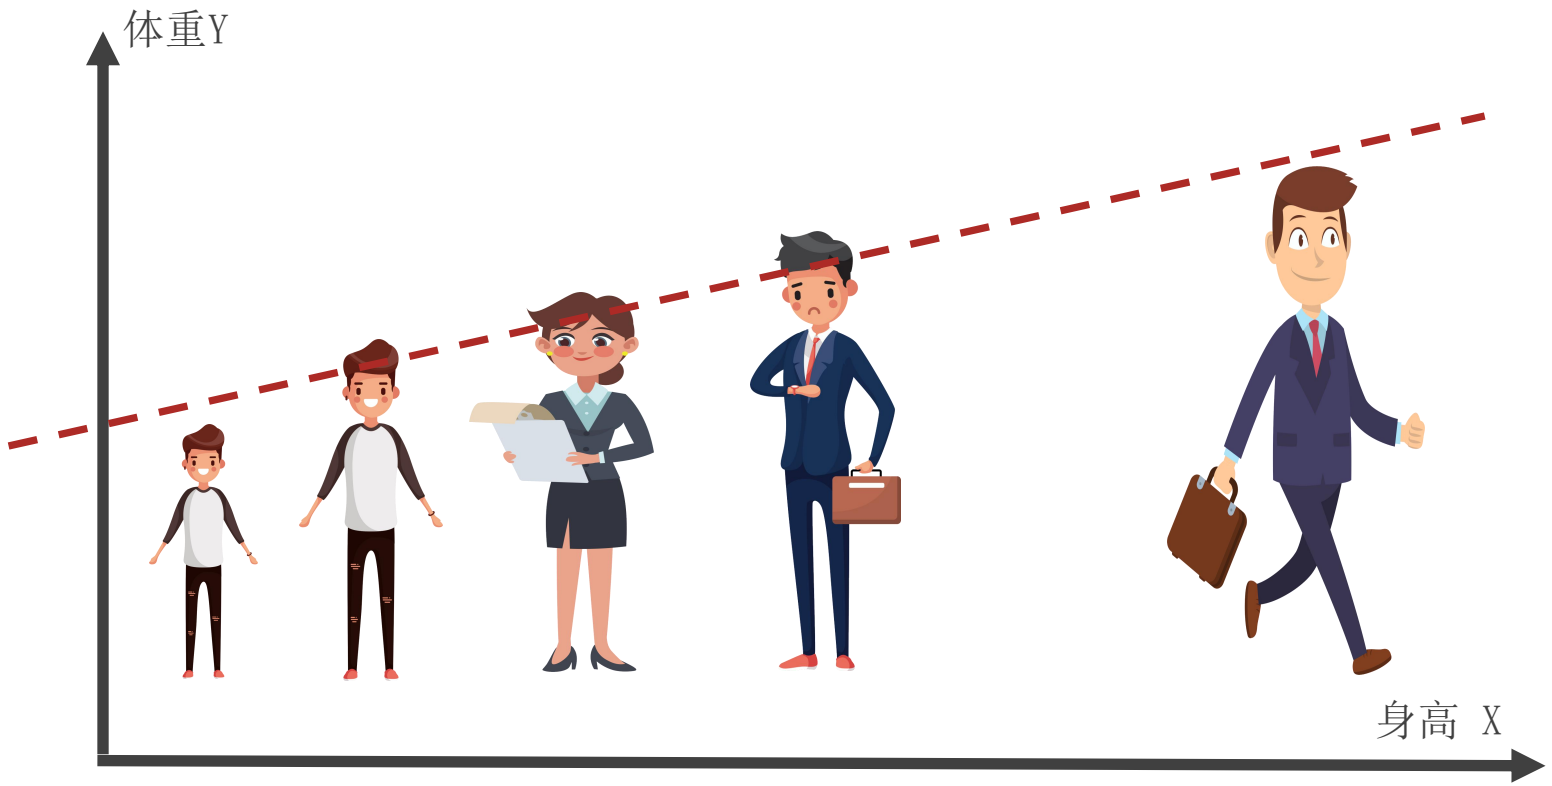

线性回归概念 - 举个栗子

- 数学问题：用一条线来拟合身高和体重之间的关系，再对新数据进行预测

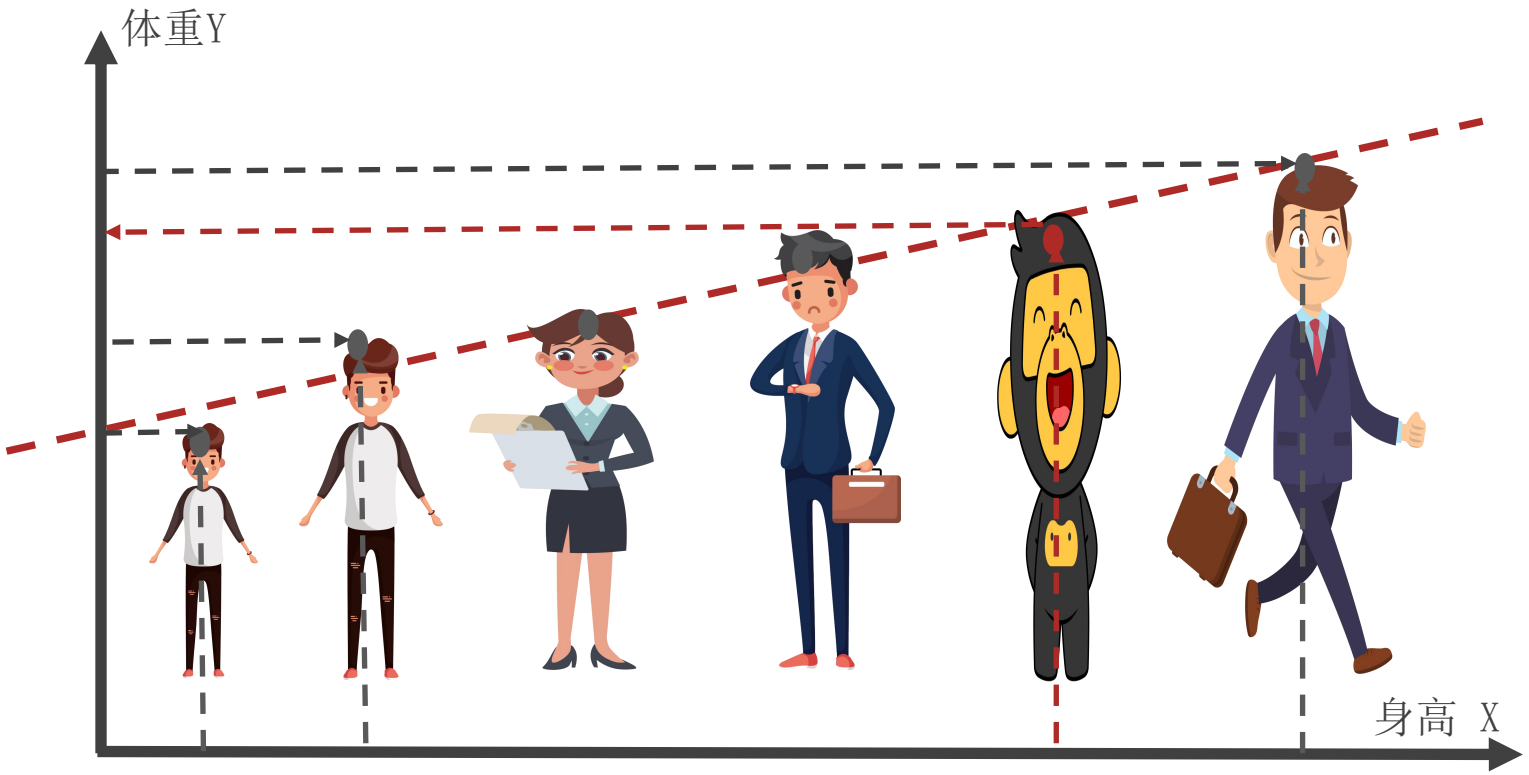

编号	身高	体重
1	160	56.3
2	166	60.6
3	172	65.1
4	174	68.5
5	180	75
6	176	?

方程 Y = kX + b

k160 + b = 56.3 -- (1)

k166 + b = 60.6 -- (2)

。。。。

k：斜率 b:截距

线性回归概念

- 定义

利用**回归方程(函数)** 对 **一个或多个自变量(特征值)和因变量(目标值)之间** 关系进行建模的一种分析方式。

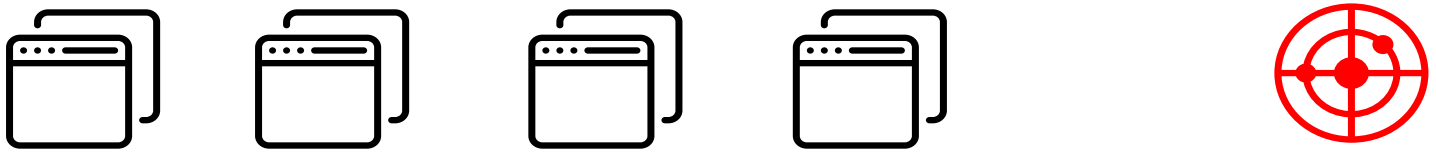

房子面积　房子位置　房子楼层　房子朝向　房子价格

- 数学公式： $h_{(w)} = w_1x_1 + w_2x_2 + w_3x_3 + \cdots + b = w^T\mathrm{x} + b$

其中 w为：$\begin{pmatrix} b \\ w_1 \\ w_2 \\ \vdots \end{pmatrix}$，x为$\begin{pmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \end{pmatrix}$　根据矩阵运算：$w^T\mathrm{x}$ 为 $[b, w_1\ w_2\ \cdots]$ @ $\begin{pmatrix} 1 \\ x_1 \\ x_2 \\ \vdots \end{pmatrix}$

线性回归概念

- 线性回归分类
  - 一元线性回归：y = wx +b
  - 目标值(因标量)只与一个特征(自变量)有关系
  - 多元线性回归： $y = w_1x_1 + w_2x_2 + w_3x_3 + \cdots + b$
  - 目标值(因标量)同时与多个特征(自变量)有关系

编号	身高	体重
1	160	56.3
2	166	60.6
3	172	65.1
4	174	68.5
5	180	75
6	176	?

	房子面积	房子位置	房子楼层	房子朝向	房子价格
数据1	80	1	3	0	81
数据2	100	2	5	1	121
数据3	80	3	3	0	102
…					
数据n	90	2	4	1	?

线性回归概念

- 应用常见场景是非常多

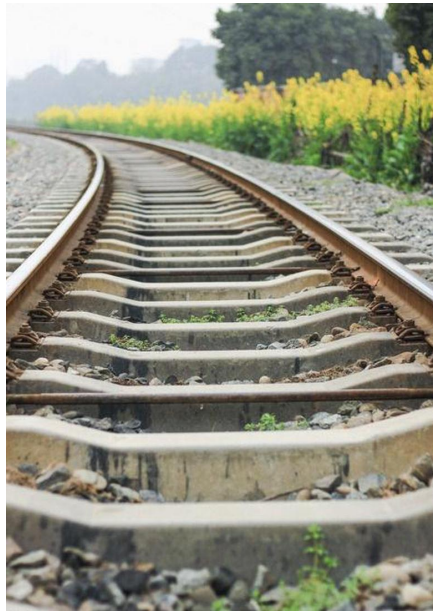

钢轨伸缩长度与温度

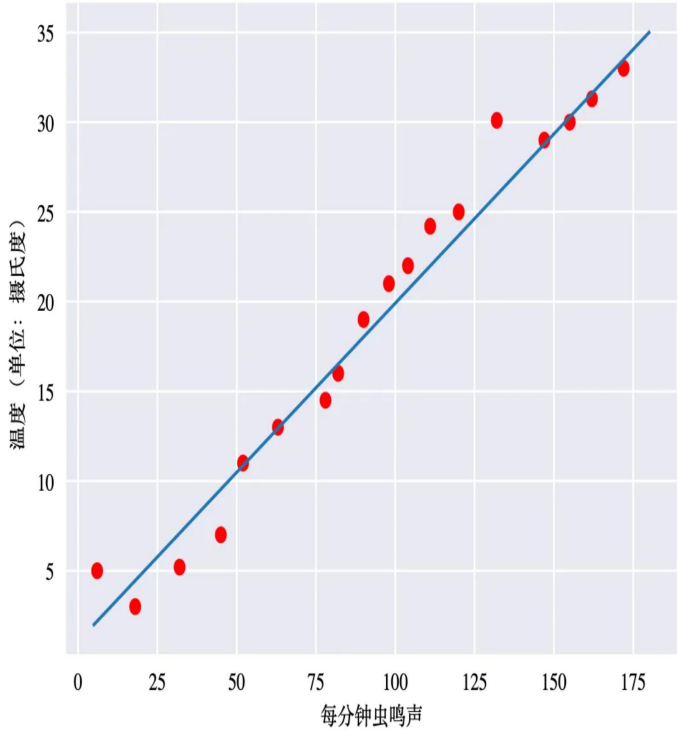

昆虫鸣叫次数与天气

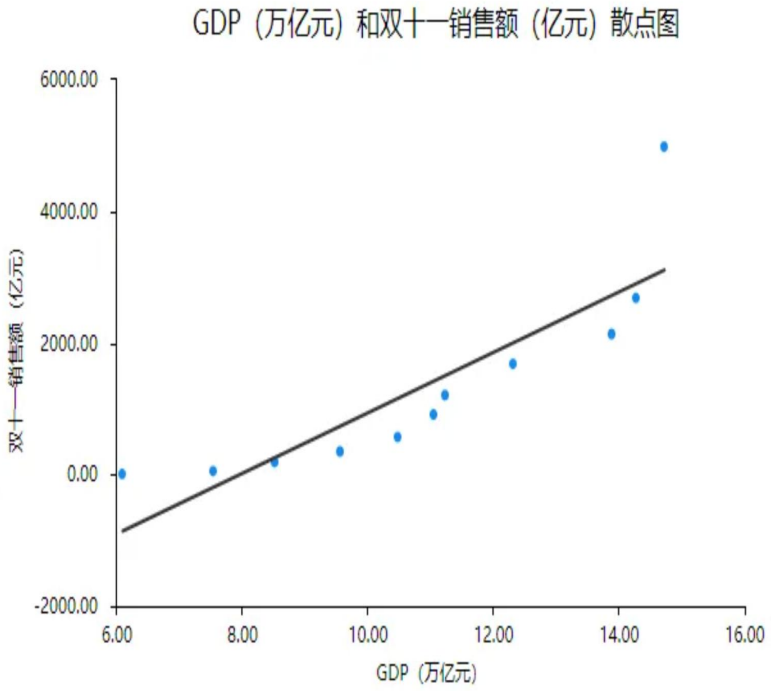

国内GDP与双十一销售额

如何利用线性回归API来快速的解决实际问题呢？

总结

1 线性回归概念

- 利用 回归方程(函数) 对 一个或多个自变量(特征值)和因变量(目标值)之间 关系进行建模的一种分析方式。
- 数学公式： $h_{(w)} = w_1x_1 + w_2x_2 + w_3x_3 + \cdots + b = w^T\mathrm{x} + b$

2 线性回归分类

- 一元线性回归、多元线性回归

目录

Contents

- 线性回归简介

  定义、线性回归的分类、应用场景

- 线性回归问题的求解

  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法

- 回归模型评估方法

  MAE、MSE、RMSE

- 线性回归API和梯度下降API

  波斯顿案例

学习目标

Learning Objectives

1. 知道线性回归API的使用
2. 知道损失函数是什么

案例　一元线性回归案例：根据播仔身高预测体重

- 已知数据：

编号	身高
1	160
2	166
3	172
4	174
5	180
6	176

?

体重
56.3
60.6
65.1
68.5
75
?

- 需求：播仔身高是176，请预测体重？

对于这个回归案例如何利用API快速求解呢？

线性回归API介绍

1 导入线性回归包 → 2 准备数据 → 3 实例化线性回归模型 → 4 训练线性回归模型 → 5 模型预测

导包 from sklearn.linear_model import LinearRegression

X: 身高数据
x = [[160],
[166], …]
Y:体重数据
y = [56.3, 60.6, …]

使用类
LinearRegression
实例化对象
estimator

estimator.fit(x, y)
从数据中获取规律
查看模型参数
斜率 coef_
截距 intercept_

estimator.predict([[176]])

线性回归API介绍

```
from sklearn.linear_model import LinearRegression

def dm01_lr预测播仔身高():
    # 1 准备数据身高和体重
    x = [[160], [166],  [172], [174],[180]]
    y = [56.3, 60.6, 65.1, 68.5, 75]

    # 2 实例化 线性回归模型 estimator
    estimator = LinearRegression()
    # 3 训练 线性回归模型fit() h(w) = w1x1 + w2x2 + b
    estimator.fit(x, y)

    # 4 打印 线性回归模型参数 coef_ intercept_
    print('estimator.coef_-->', estimator.coef_)
    print('estimator.intercept_-->', estimator.intercept_)


    # 5 模型预测predit()

    myres = estimator.predict([[176]])

    print('myres-->', myres)
```

总结

线性回归API使用步骤:

- 导包:from sklearn.linear_model import LinearRegression
- 实例化模型: estimator = LinearRegression()
- 训练模型: estimator.fit(x_train, y_train)
- 模型预测: estimator.predict(x_test)

线性回归问题求解需要什么？

数据 → 线性回归模型 → 损失函数 → 优化方法

样本数据

特征值x和目标值y组成，
假设数据分布线性的

线性方程式（假设函数）

1、样本x特征值有1个，
$Y = kx + b$ 线性关系
2 、样本特征值x由多个

损失函数种类

LS
MSE
MAE

让损失函数最小的方法

1、通过求方程法（求导、求偏导）
2、梯度下降法：利用梯度逐步逼近最优解

线性回归的求解方法

通过线性回归API可快速的找到拟合结果，那是怎么求解的呢？

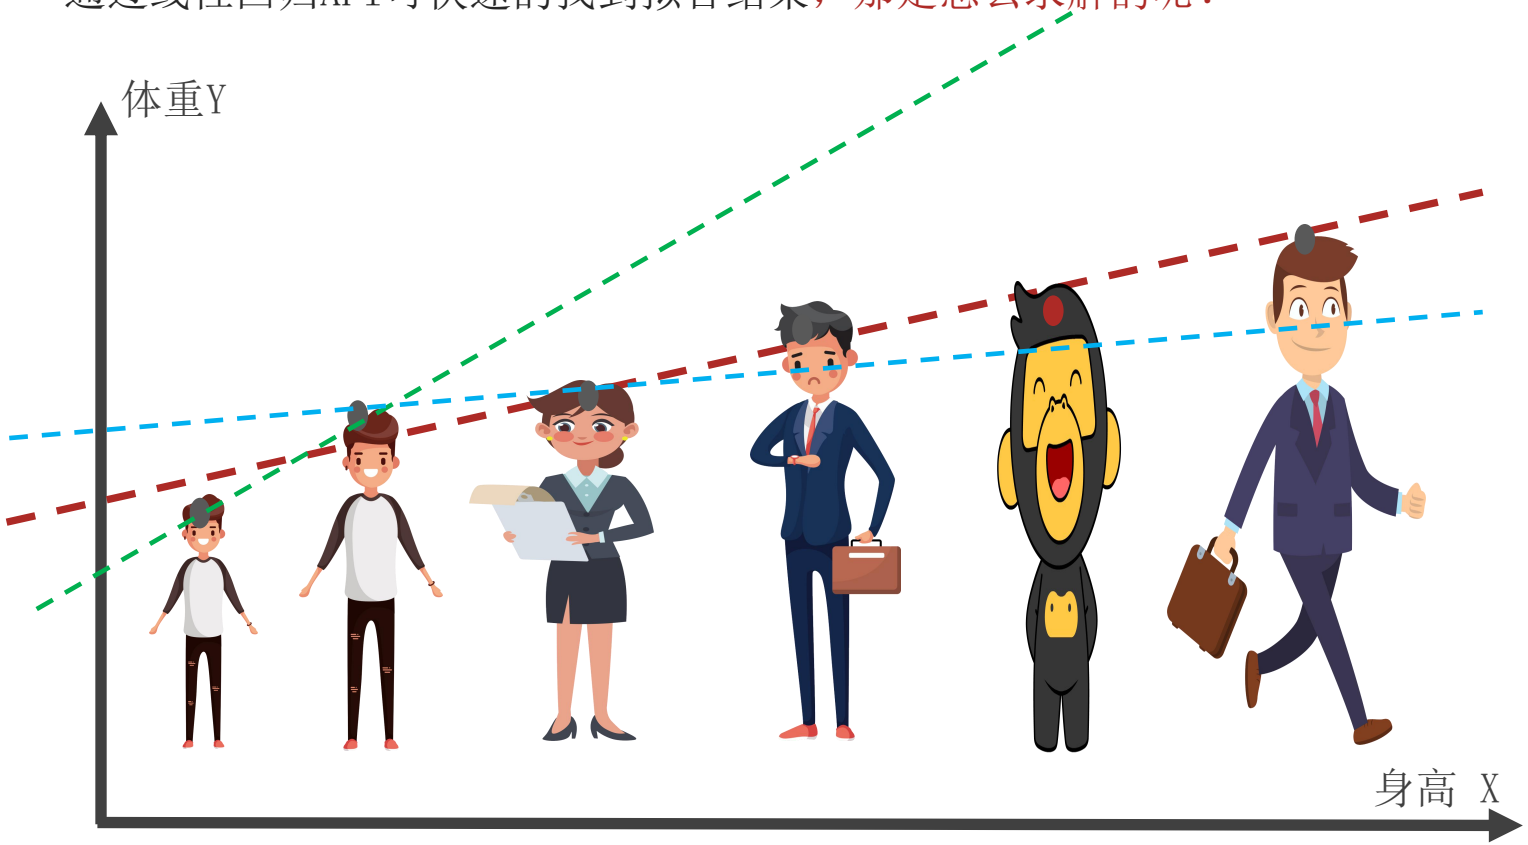

如何学习数据分布规律 ？

如何找到最优解 ？

损失函数

- 需要设置一个评判标准

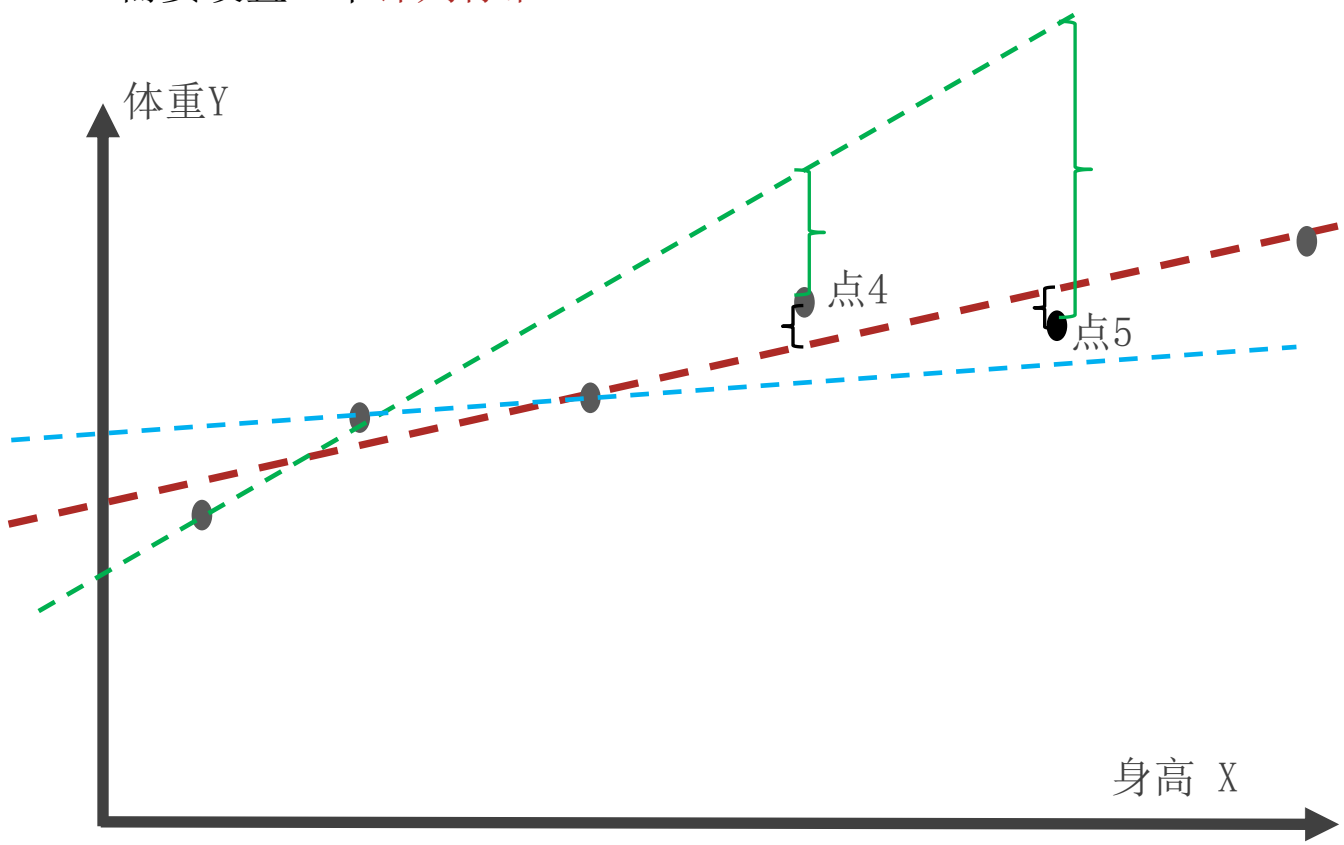

图中“红色直线能更好的拟合所有点”也就是误差最小；

1. 误差概念：用预测值y － 真实值y就是误差

2、损失函数：衡量每个样本预测值与真实值效果的函数，也叫代价函数、成本函数、目标函数

常见损失函数

- 最小二乘法 ： 误差平方和
  - $\sum_{i=0}^{m}(h(x^{(i)}) - y^{(i)})^2$
- 均方误差 ： 误差平方和取平均值
  - $\frac{1}{m}\sum_{i=0}^{m}(h(x^{(i)}) - y^{(i)})^2$
- 平均绝对误差 误差绝对值和取平均值
  - $\frac{1}{m}\sum_{1}^{m}\left[h(x^{(i)}) - y^{(i)}\right]$

总结

损失函数概念

- 误差：预测值 – 真实值的差值
- 损失函数：衡量预测值和真实值效果的函数，也叫代价函数、目标函数

回归问题中的损失函数

- 最小二乘法 ：误差平方和
  - $\sum_{i=0}^{m}(h(x^{(i)}) - y^{(i)})^2$
- 均方误差 ：误差平方和取平均值
  - $\frac{1}{\mathrm{m}}\sum_{i=0}^{m}(h(x^{(i)}) - y^{(i)})^2$
- 平均绝对误差 误差绝对值和取平均值
  - $\frac{1}{\mathrm{m}}\sum_{1}^{\mathrm{m}}\left[h(x^{(i)}) - y^{(i)}\right]$

线性回归问题求解需要什么？

数据 → 线性回归模型 → 损失函数 → 优化方法

样本数据

特征值x和目标值y组成，
假设数据分布线性的

线性方程式（假设函数）

1、样本x特征值有1个，
$Y = kx + b$ 线性关系
2 、样本特征值x由多个

损失函数种类

LS
MSE
MAE

让损失函数最小的方法

1、通过求方程法（求导、求偏导）
2、梯度下降法：利用梯度逐步逼近最优解

目录

Contents

- 线性回归简介

  定义、线性回归的分类、应用场景

- 线性回归问题的求解

  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法

- 回归模型评估方法

  MAE、MSE、RMSE

- 线性回归API和梯度下降API

  波斯顿案例

学习目标

Learning Objectives

1. 知道什么是导数
2. 知道什么是偏导
3. 知道向量和矩阵的简单运算

导数 - 基本概念

导数是微积分的核心概念，描述 函数在某一点处的瞬时变化率

设函数 $y = f(x)$ 在点 x_0 的某个邻域内有定义，当自变量 x 在 x_0 处产生一个增量 Δx（$x_0 + \Delta x$ 仍在该邻域内）时，函数取得增量 $\Delta y = f(x_0 + \Delta x) - f(x_0)$。如果当 $\Delta x \to 0$ 时，比值 $\frac{\Delta y}{\Delta x}$ 的极限存在，则称函数 $f(x)$ 在点 x_0 处可导，并称这个极限为 $f(x)$ 在点 x_0 处的导数，记作：

$$f'(x_0) = \lim_{\Delta x \to 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

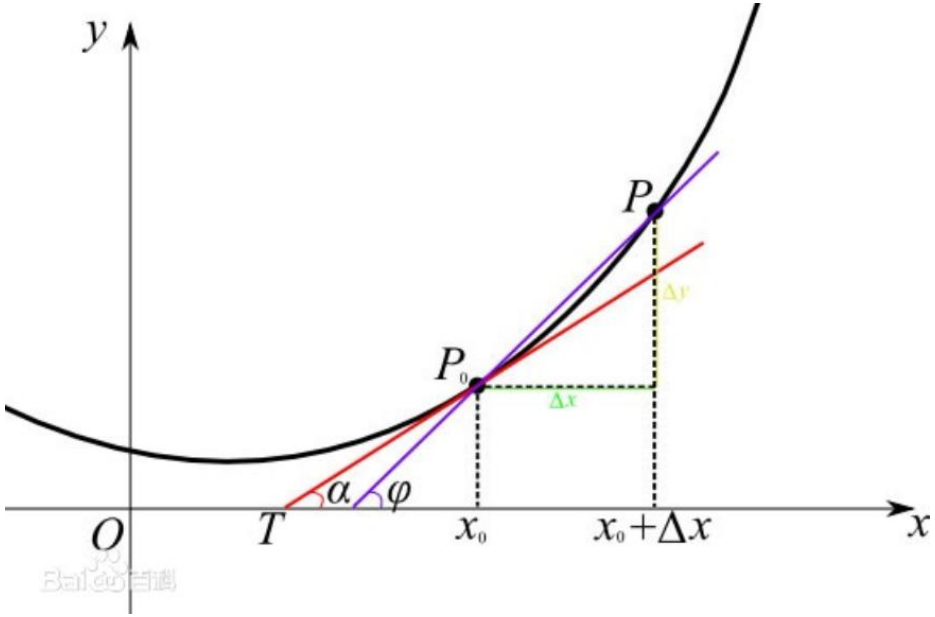

导数的几何意义

函数 $y=f(x)$在点x_0处的导数的几何意义，就是曲线$y=f(x)$在点$P(x_0,f(x_0))$处的切线的斜率，即曲线$y=f(x)$在点$P(x_0,f(x_0))$ 处的切线的斜率是 $f'(x_0)$.

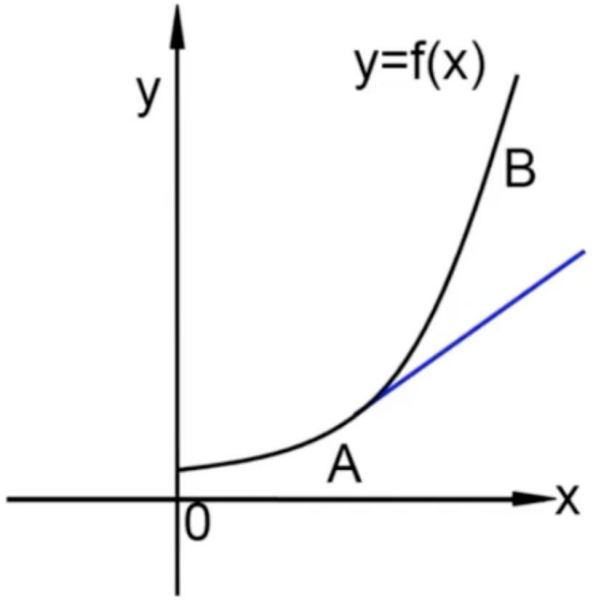

导数的入门案例

求函数 $f(x) = x^2$ 在 $x = 2$ 处的导数

计算增量:

$$\Delta y = f(2+\Delta x) - f(2) = (2+\Delta x)^2 - 2^2 = 4 + 4\Delta x + (\Delta x)^2 - 4 = 4\Delta x + (\Delta x)^2$$

计算平均变化率:

$$\frac{\Delta y}{\Delta x} = \frac{4\Delta x + (\Delta x)^2}{\Delta x} = 4 + \Delta x$$

取极限:

$$f'(2) = \lim_{\Delta x \to 0}(4 + \Delta x) = 4$$

因此，函数 $f(x) = x^2$ 在 $x = 2$ 处的导数为 4，表示曲线在点 $(2, 4)$ 处的切线斜率为 4。

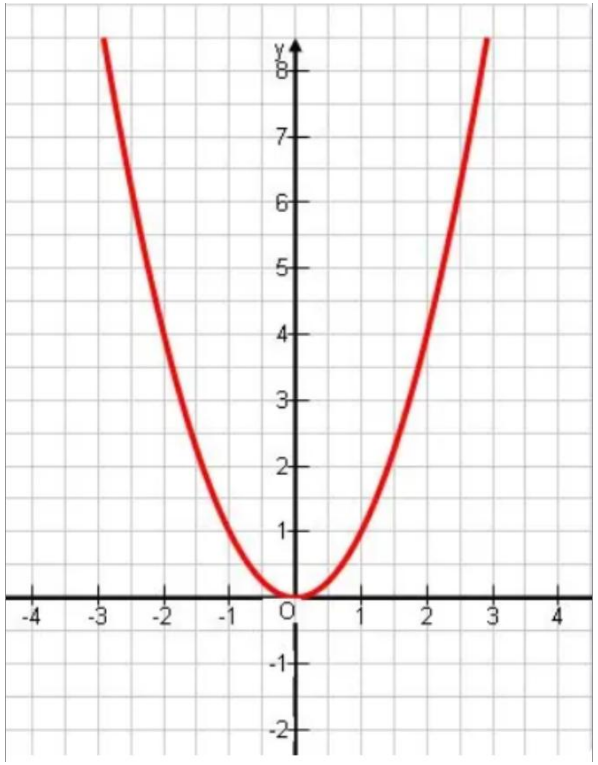

常见函数的导数

公式	例子
$(C)' = 0$	$(5)' = 0 \qquad (10)' = 0$
$(x^{\alpha})' = \alpha x^{\alpha-1}$	$(x^3)' = 3x^2 \qquad (x^5)' = 5x^4$
$(a^x)' = a^x \ln a$	$(2^x)' = 2^x \ln 2 \qquad (7^x)' = 7^x \ln 7$
$(e^x)' = e^x$	$(e^x)' = e^x$
$(\log_a x)' = \frac{1}{x \ln a}$	$(\log_{10} x)' = \frac{1}{x \ln 10} \qquad (\log_6 x)' = \frac{1}{x \ln 6}$
$(\ln x)' = \frac{1}{x}$	$(\ln x)' = \frac{1}{x}$
$(\sin x)' = \cos x$	$(\sin x)' = \cos x$
$(\cos x)' = -\sin x$	$(\cos x)' = -\sin x$

导数的四则运算

$[u(x)\pm v(x)]'=u'(x)\pm v'(x)$	$(e^x+4\ln x)'=(e^x)'+(4\ln x)'=e^x+\frac{4}{x}$
$[u(x)\cdot v(x)]'=u'(x)\cdot v(x)+u(x)\cdot v'(x)$	$(\sin x\cdot\ln x)'=(\sin x)'\cdot\ln x+\sin x\cdot(\ln x)'=\cos x\cdot\ln x+\sin x\cdot\frac{1}{x}$
$\left[\frac{u(x)}{v(x)}\right]'=\frac{u'(x)\cdot v(x)-u(x)\cdot v'(x)}{v^2(x)}$	$\left(\frac{e^x}{\cos x}\right)'=\frac{(e^x)'\cdot\cos x-e^x\cdot(\cos x)'}{\cos^2(x)}=\frac{e^x\cdot\cos x-e^x\cdot(-\sin x)}{\cos^2(x)}$
$\{g[h(x)]\}'=g'(h)\cdot h'(x)$	$(e^{2x})'=e^{2x}\cdot(2x)'=2e^{2x}$ $\quad(\sin 2x)'=\cos 2x\cdot(2x)'=2\cos 2x$

- 注意：复合函数求导：g(h)是外函数 h(x)是内函数。先对外函数求导，再对内函数求导
- 举个例子:计算该函数$y=(x^2+2x)^2$ 的导函数

$$y'=2(x^2+2x)^{(2-1)}(x^2+2x)'=2(x^2+2x)(2x+2)=4(x^3+3x^2+2x)=4x^3+12x^2+8x$$

导数求极值

- 导数为0的位置是函数的极值点

- 求函数 $y = x^2 - 4x + 5$ 的极小值

求导法：对x求导，令导数=0： $y' = 2x - 4 = 0$

对x求导结果：$x = 2$。

最终代入x求y极小值 $= 1$

总结

1 导数 Derivative

- 导数是微积分中的一个核心概念，它用于描述函数在某一点上的瞬时变化率

2 导数的求解方法

- 常数、指数函数、幂指数、正弦余弦都有自己的导函数，会查表应用
- 特别注意复合函数求导：先对外函数求导，在对内函数求导

3 利用导数求极值

- 导数为0的位置即为极值点

偏导

偏导数的定义

对于一个给定的多元函数 $f(x_1, x_2, \ldots, x_n)$，它的偏导数表示当且仅当一个变量变化而其他所有变量保持不变时，函数值的变化率。以二元函数 $f(x, y)$ 为例：

- 对 x 的偏导数记作 $\frac{\partial f}{\partial x}$ 或 f_x，表示当 y 固定时，f 关于 x 的变化率。
- 对 y 的偏导数记作 $\frac{\partial f}{\partial y}$ 或 f_y，表示当 x 固定时，f 关于 y 的变化率。

如何计算偏导数

计算偏导数的过程与计算普通一元函数的导数相似，但需要将不涉及求导的那个变量视为常数。

举例说明

考虑函数 $f(x, y) = x^2 + 3xy + y^2$：

- 对 x 的偏导数 $\frac{\partial f}{\partial x} = 2x + 3y$（这里把 y 当做常数）。
- 对 y 的偏导数 $\frac{\partial f}{\partial y} = 3x + 2y$（这里把 x 当做常数）。

总结

偏导数

- 偏导数是多元函数微积分中的一个基本概念，对于一个给定的多元函数 f(x1, x2, …, xn)，它的偏导数表示当且仅当一个变量变化而其他所有变量保持不变时，函数值的变化率

基础数学 - 机器学习中常见的数据表述

宗旨：用到就学什么，不要盲目的展开、大篇幅学数学

- 标量scalar：一个独立存在的数，只有大小没有方向

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

- 向量vector：向量指一列顺序排列的元素。默认是列向量
  - 比如张三的数理化成绩信息：70, 80, 90 $\begin{pmatrix} 70 \\ 80 \\ 90 \end{pmatrix} \in R^3$
  - 向量有大小和方向
- 矩阵matrix：二维数组
  - 比如张三、李四的数理化成绩信息：70, 80, 90； 75, 85, 95 $\begin{pmatrix} 70, & 80, & 90 \\ 75, & 85, & 95 \end{pmatrix} \in R^{2*3}$

$A \epsilon R^{m \times n}$

m代表多少行
n代表特征数

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ a_{31} & a_{32} & \cdots & a_{3n} \\ \cdots & \cdots & & \cdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

- 张量Tensor：数组，张量是基于向量和矩阵的推广
  - 数学中的张量 $tensor \in R^{2*3*4}$ ：2个3*4矩阵 3个2*4 或4个2*3

基础数学向量和矩阵 - 范数Norm

- 范数(norm)是数学中的一种基本概念，**用于度量向量或者矩阵的大小或者长度**
  - 1范数(L1范数)-向量中各个元素绝对值之和
  - 2范数(L2范数)-向量的模长，每个元素平方求和，再开平方根
  - p-范数：向量中每一个元素p幂求和，在开p次根
- L1范数

  $x^T = (1,\ 2,\ -3)$ $\quad \|x\|_1 = |1| + |2| + |-3| = 6$

- L2范数

  $x^T = (1,\ 2,\ -3)$ $\quad \|x\|_2 = \sqrt[2]{1^2 + 2^2 + (-3)^2} = \sqrt{14}$

  $x^T = (1,\ 2,\ -3)$ 注意：向量的转置@向量 $\quad x^T x = 1^2 + 2^2 + (-3)^2 = 14$

  X为向量：$x^T x$ 与 $\|x\|_2^2$ 是一样的

- Lp范数 $\|x\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{\frac{1}{p}}$

基础数学向量和矩阵 – 向量运算

- 向量是有大小和方向
  - 几何意义上表示：向量(1,1)，向量（1,2）

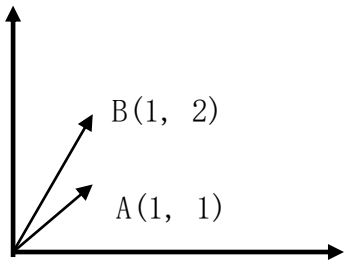

- 向量基运算

$$\begin{pmatrix}1\\2\\3\end{pmatrix} + \begin{pmatrix}4\\5\\6\end{pmatrix} = \begin{pmatrix}5\\7\\9\end{pmatrix} \in R^3 \qquad \begin{pmatrix}1\\2\\3\end{pmatrix} - \begin{pmatrix}4\\5\\6\end{pmatrix} = \begin{pmatrix}-3\\-3\\-3\end{pmatrix} \in R^3 \qquad 3 * \begin{pmatrix}4\\5\\6\end{pmatrix} = \begin{pmatrix}12\\15\\18\end{pmatrix} \in R^3$$

- 向量矩阵转置 Transpose

$$X = \begin{pmatrix}1\\2\\3\end{pmatrix} \qquad x^T = (1,\ 2,\ 3) \qquad Y = \begin{bmatrix}11 & 12 & 13\\21 & 22 & 23\end{bmatrix} \qquad Y^T = \begin{bmatrix}11 & 21\\12 & 22\\13 & 23\end{bmatrix}$$

基础数学向量和矩阵 - 矩阵 Matrix 1

- 矩阵:是一个按照长方形排列的复数或实数集合，它由若干行和若干列组成。

  例如 a_{ij} 表示矩阵 A 中第 i 行第 j 列的元素

- 矩阵在机器学习中的表达

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \in R^{2*2}$$

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in R^{2*3}$$

一个矩阵m行n列：$A \in R^{2*3}$　　一个数据集$X \in R^{N*D}$ N多少行数据，D特征数

- 矩阵加法和减法

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} + \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} = \begin{bmatrix} 2 & 4 & 6 \\ 8 & 10 & 12 \end{bmatrix} \qquad \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} - \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

- 矩阵乘法 ：对应行列元素相乘，然后再加和再一起

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in R^{2*3} \quad B = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 1 & 1 \end{bmatrix} \in R^{3*2} \quad C = \begin{bmatrix} 1*1+2*3+3*1, & 1*2+2*4+3*1 \\ 4*1+5*3+6*1, & 4*2+5*4+6*1 \end{bmatrix} = \begin{bmatrix} 10, & 13 \\ 25, & 34 \end{bmatrix} \in R^{2*2}$$

$A \in R^{m*n}$, $B \in R^{n*d}$ ➔ $A@B=C \in R^{m*d}$

基础数学向量和矩阵 - 矩阵 Matrix 2

- 矩阵:是一个按照长方形排列的复数或实数集合，它由若干行和若干列组成。

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

- 方阵：一种特殊的矩阵，其行数=列数

$$B = \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nn} \end{pmatrix}$$

- 对称方阵：一种特殊的方阵，沿着主对角线，其元素对称. $a_{ij} = a_{ji}$

$$C = \begin{pmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{12} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{1n} & c_{2n} & \cdots & c_{nn} \end{pmatrix}$$

- 单位阵：一种特殊的对角方阵，用符号E 或者 I表示. 主对角线为1，其他为0

$$I_{3*3} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- 同阶方阵：指的是具有相同的行数和列数的两个方阵

基础数学向量和矩阵 - 矩阵 Matrix 3

- 矩阵乘法的性质
  - 矩阵的乘法不满足交换律：A×B≠B×A
    - eg: A∈ R^{5*2}, B∈ R^{2*5} A@B∈ R^{5*5} B@A=∈ R^{2*2}
    - 特殊条件下满足： AB=BA 的前提是A、B是同阶方阵 eg: A_{2*2} B_{2*2} = B_{2*2} A_{2*2}
  - 矩阵的乘法满足结合律。即：A×（B×C）=（A×B）×C
    - eg: A∈ R^{5*2}, B∈ R^{2*5} C∈ R^{5*3} （A×B）×C数据形状R^{5*3}
  - 矩阵与单位矩阵相乘等于矩阵本身
    - eg: A@I = A I@A = A I为单位矩阵
  - 矩阵的逆 若矩阵A = $\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$ ∈ R^{2*2} A@B = I单位矩阵 则B为A的逆矩阵，记为：A^{-1}

基础数学向量和矩阵 - 矩阵 Matrix 4

- 矩阵转置

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \in R^{2*3} \qquad A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \in R^{3*2}$$

- 矩阵@矩阵的转置

$A@A^T$ 是方阵

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} @ \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} = \begin{bmatrix} 1*1+2*2+3*3 & 1*4+2*5+3*6 \\ 4*1+5*2+6*3 & 4*4+5*5+6*6 \end{bmatrix} = \begin{bmatrix} 14 & 32 \\ 32 & 77 \end{bmatrix}$$

$A^T@A$ 是方阵

$$\begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} @ \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} = \begin{bmatrix} 1*1+4*4 & 1*2+4*5 & 1*3+4*6 \\ 2*1+5*4 & 2*2+5*5 & 2*3+5*6 \\ 3*1+6*4 & 3*2+6*5 & 3*3+6*6 \end{bmatrix} = \begin{bmatrix} 17 & 22 & 27 \\ 22 & 29 & 36 \\ 27 & 36 & 45 \end{bmatrix}$$

基础数学向量和矩阵 - 矩阵 Matrix 4

- 矩阵转置的性质
  - $(A^T)^T = A$
  - $(A+B)^T = A^T + B^T$
  - $(kA)^T = kA^T$ k为一个常数
  - $(AB)^T = B^T A^T$

比如：

$$\left(\begin{bmatrix}1 & 2 & 3\\4 & 5 & 6\end{bmatrix} @ \begin{bmatrix}1 & 2\\3 & 4\\1 & 1\end{bmatrix}\right)^T = \begin{bmatrix}1 & 2\\3 & 4\\1 & 1\end{bmatrix}^T @ \begin{bmatrix}1 & 2 & 3\\4 & 5 & 6\end{bmatrix}^T$$

总结

矩阵的概念

- 方阵
- 对称方阵
- 单位阵
- 同阶方阵
- 矩阵的逆

矩阵的运算

- 1 矩阵数学表示 $X \in R^{N*D}$
- 2 矩阵加减法：形状相同对应元素加减
- 3 矩阵乘法：条件$A \in R^{m*n}$，$B \in R^{n*d}$ ➔ $A@B=C \in R^{m*d}$
- 4 矩阵的乘法不满足交换律：$A \times B \neq B \times A$ ；矩阵的乘法满足结合律
- ...

线性回归问题求解需要什么？

数据 → 线性回归模型 → 损失函数 → 优化方法

样本数据

特征值x和目标值y组成，
假设数据分布线性的

线性方程式（假设函数）

1、样本x特征值有1个，
$Y = kx + b$ 线性关系
2 、样本特征值x由多个

损失函数种类

LS
MSE
MAE

让损失函数最小的方法

1、通过求方程法（求导、求偏导）
2、梯度下降法：利用梯度逐步逼近最优解

目录

Contents

- 线性回归简介

  定义、线性回归的分类、应用场景

- 线性回归问题的求解

  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法

- 回归模型评估方法

  MAE、MSE、RMSE

- 线性回归API和梯度下降API

  波斯顿案例

学习目标

Learning Objectives

1. 知道正规方程法求解过程

多元线性回归 - 正规方程法

正规方程法（Normal Equation）是求解线性回归问题的一种解析方法，它提供了一种直接计算模型参数的方法，而不需要迭代过程。这种方法基于最小化代价函数来找到最佳拟合直线的参数。

正规方程法的基本概念

在机器学习中，尤其是线性回归问题中，我们试图找到一个假设函数 $h_\theta(x) = \theta_0 + \theta_1 x_1 + \cdots + \theta_n x_n$ 来拟合一组数据点。这里，x_i 是输入特征值，θ_i 是我们需要确定的参数。

为了找到这些参数的最佳值，我们通常定义一个代价函数（Cost Function），如均方误差（Mean Squared Error, MSE），然后通过最小化这个代价函数来寻找最优参数。

正规方程的形式

对于一组训练样本 (X, y)，其中 X 是一个 $m \times (n+1)$ 的矩阵（m 是样本数量，n 是特征数量，额外的一列用于偏置项 θ_0），y 是一个 m 维向量表示目标值，正规方程可以形式化为：

$$\theta = (X^T X)^{-1} X^T y$$

这里：

- X^T 表示矩阵 X 的转置。
- $(X^T X)^{-1}$ 表示矩阵 $X^T X$ 的逆矩阵。

多元线性回归 －正规方程法

- 正规方程w公式的解释说明：

x_0	Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

X(0)	X(1)	X(2)	X(3)	X(4)	y
1	2104	5	1	45	460
1	1416	3	2	40	232
1	1534	3	2	30	315
1	852	2	1	36	178

$$X = \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix}$$

正规方程的w：

$$w = (X^T X)^{-1} X^T y$$

$$\left\{ \begin{bmatrix} 1 & 1 & 1 & 1 \\ 2104 & 1416 & 1534 & 852 \\ 5 & 3 & 3 & 2 \\ 1 & 2 & 2 & 1 \\ 45 & 40 & 30 & 36 \end{bmatrix} \times \begin{bmatrix} 1 & 2104 & 5 & 1 & 45 \\ 1 & 1416 & 3 & 2 & 40 \\ 1 & 1534 & 3 & 2 & 30 \\ 1 & 852 & 2 & 1 & 36 \end{bmatrix} \right\}^{-1} \times \begin{bmatrix} 1 & 1 & 1 & 1 \\ 2104 & 1416 & 1534 & 852 \\ 5 & 3 & 3 & 2 \\ 1 & 2 & 2 & 1 \\ 45 & 40 & 30 & 36 \end{bmatrix} \times \begin{bmatrix} 460 \\ 232 \\ 315 \\ 178 \end{bmatrix}$$

多元线性回归 - 正规方程法

正规方程优缺点：

优点：

不需要选择学习率。

不需要迭代。

不需要对特征进行缩放处理。

缺点：

如果特征数量 nn 很大（例如超过10,000），则计算 (XTX)−1(XTX)−1 的逆会非常慢。

如果 XTXXTX 是不可逆的（即奇异或退化），则无法直接应用该方法。这可能发生在有线性相关的特征或者特征数量多于样本数量的情况下。

总结:正规方程法是一种有效解决小规模线性回归问题的方法，但对于大规模数据集或者特征数量较多的情况，可能会遇到计算效率的问题。

总结

多元线性回归的正规方程

公式： $w = (X^T X)^{-1} X^T y$

缺点：

计算量比较大

如果没有逆矩阵，方程无解

目录

Contents

- 线性回归简介

  定义、线性回归的分类、应用场景

- 线性回归问题的求解

  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法

- 回归模型评估方法

  MAE、MSE、RMSE

- 线性回归API和梯度下降API

  波斯顿案例

学习目标

Learning Objectives

1. 掌握梯度下降算法的思想
2. 知道梯度下降算法的分类
3. 知道正规方程和梯度下降算法的特点

梯度下降法 - 梯度下降和梯度

- 什么是梯度下降法
  - 顾名思义：沿着梯度下降的方向求解极小值
  - 举个例子：坡度最陡下山法

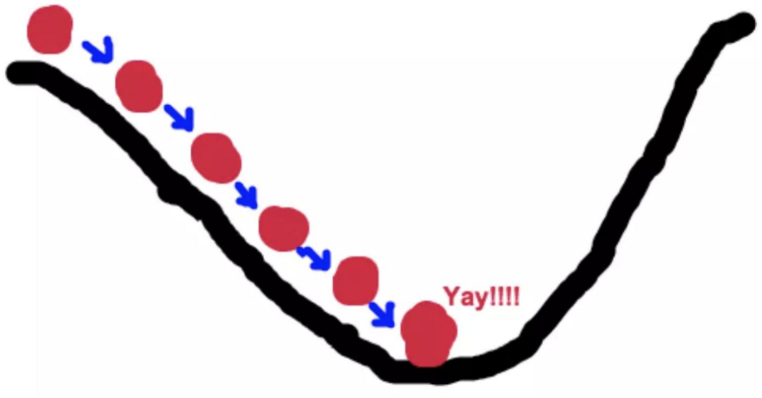

- 输入：初始化位置S；每步距离为a 。输出：从位置S到达山底
- 步骤1：令初始化位置为山的任意位置S
- 步骤2：在当前位置环顾四周，如果四周都比S高返回S；否则执行步骤3
- 步骤3： 在当前位置环顾四周，寻找坡度最陡的方向，令其为x方向
- 步骤4：沿着x方向往下走，长度为a，到达新的位置S'
- 步骤5：在S'位置环顾四周，如果四周都比S'高，则返回S'。否则转到步骤3

梯度下降过程就和下山场景类似

可微分的损失函数，代表着一座山

寻找的函数的最小值，也就是山底

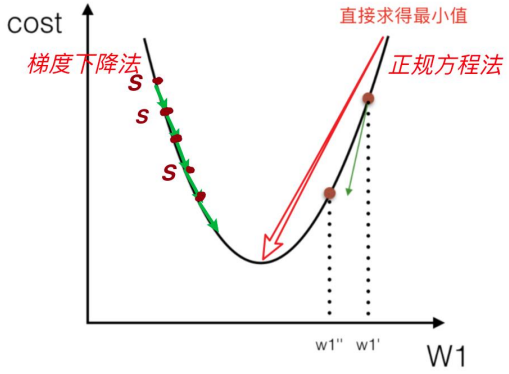

梯度下降法 - 梯度下降和梯度

- 什么是梯度 gradient grad
  - 单变量函数中，梯度就是某一点切线斜率（某一点的导数）；有方向为函数增长最快的方向
  - 多变量函数中，梯度就是某一个点的偏导数；有方向：偏导数分量的向量方向

- 梯度下降公式[理解]
  - 循环迭代求当前点的梯度，更新当前的权重参数

$$\theta_{i+1} = \theta_i - \alpha \frac{\partial}{\partial \theta_i} J(\theta)$$

  - α：学习率(步长) 不能太大，也不能太小. 机器学习中：0.001 ~ 0.01
  - 梯度是上升最快的方向，我们需要是下降最快的方向，所以需要加负号

梯度下降法 - 梯度下降和梯度

- 单变量梯度下降 - 举个栗子

函数：$J(\theta) = \theta^2$，求当 θ 为何值时，J(θ) 值最小　J(θ) 函数关于 θ 的导数为：2θ

初始化 ：起点为：1 ，学习率：α = 0.4

我们开始进行梯度下降的迭代计算过程：

第一步：θ = 1

第二步：θ = θ - α * (2θ) = 1 - 0.4 * (2*1) = 0.2

第三步：θ = θ - α * (2θ) = 0.2 - 0.4 * (2*0.2) = 0.04

第四步：θ = θ - α * (2θ) = 0.04 - 0.4 * (2*0.04) = 0.008

第五步：θ = θ - α * (2θ) = 0.008 - 0.4 * (2*0.008) = 0.0016

....

第N步：θ 已经极其接近最优值 0，J(θ) 也接近最小值。

小结：经过四次的运算，即走了四步，基本抵达了函数的最低点

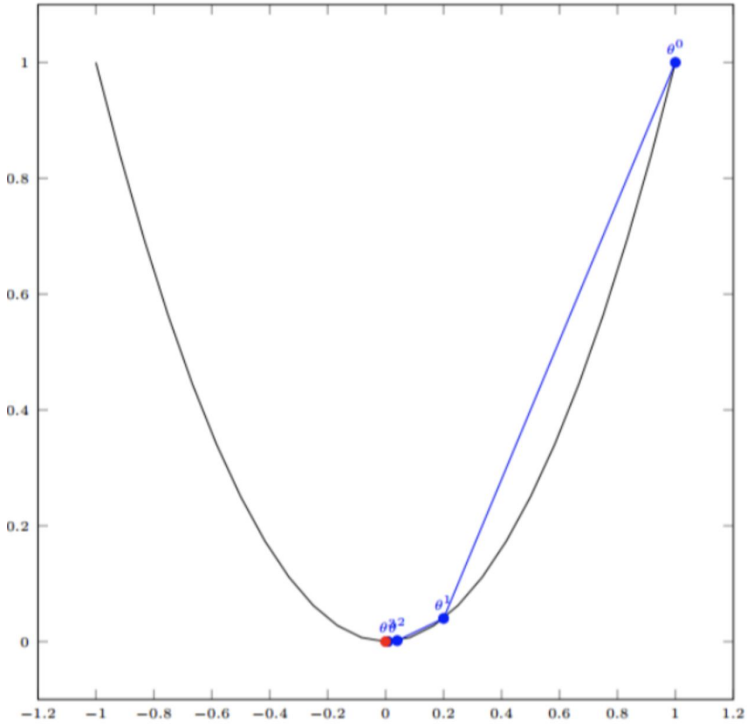

梯度下降法 - 梯度下降和梯度

- 梯度下降优化过程
  1. 给定初始位置、步长（学习率）
  2. 计算该点当前的梯度的负方向
  3. 向该负方向移动步长
  4. 重复 2-3 步 直至收敛
     - 两次差距小于指定的阈值
     - 达到指定的迭代次数

- 有关学习率步长(Learning rate)
  1. **步长决定了在梯度下降迭代的过程中，每一步沿梯度负方向前进的长度**
  2. 学习率太小，下降的速度会慢
  3. 学习率太大：容易造成错过最低点、产生下降过程中的震荡、甚至梯度爆炸

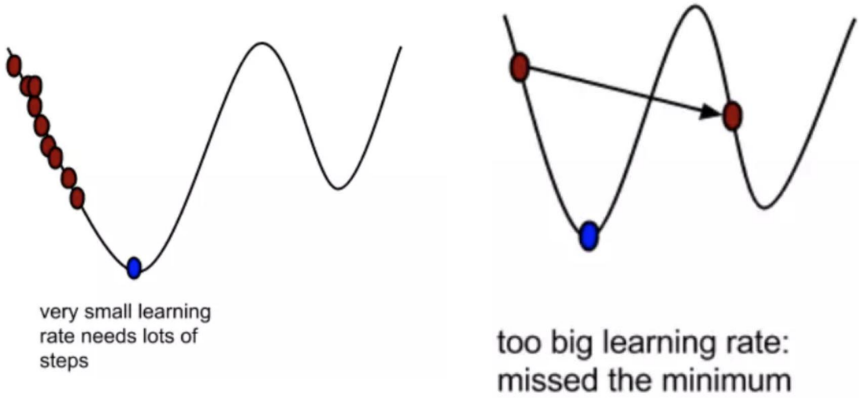

梯度下降法分类

- 全梯度下降算法 FGD

  由于使用全部数据集，训练速度较慢

- 随机梯度下降算法 SGD

  简单，高效，不稳定。SG每次只使用一个样本迭代，若遇上噪声则容易陷入局部最优解

- 小批量梯度下降算法 mini-batch

  结合了 SG 的胆大和 FG 的心细，它的表现也正好居于 SG 和 FG 二者之间。

  目前使用最多，正是因为它避开了 FG 运算效率低成本大和 SG 收敛效果不稳定的缺点

- 随机平均梯度下降算法 SAG

  训练初期表现不佳，优化速度较慢。这是因为我们常将初始梯度设为0，

  而 SAG 每轮梯度更新都结合了上一轮梯度值。

- 目前使用较多的是：小批量梯度下降

总结

1 梯度概念

- 梯度：单变量函数就是导数；多变量函数就是偏导数

2 梯度下降法

- 公式：$\theta_{i+1} = \theta_i - \alpha \frac{\partial}{\partial \theta_i} J(\theta)$
  - w新 = w旧 - a * 梯度
  - $(w_1, w_2, \cdots w_n)$ = $(w_1, w_2, \cdots w_n)$ - a * (梯度1，梯度2… 梯度n)
- 学习率 俗称步长
  - 学习率太小学的慢；学习率太大，梯度下降中抖动、震荡、易错过最优解

3. 梯度下降算法中常用的是哪个?

小批量梯度下降：随机选择小部分样本的梯度值更新权重

线性回归问题求解需要什么？

数据 → 线性回归模型 → 损失函数 → 优化方法

样本数据

特征值x和目标值y组成，
假设数据分布线性的

线性方程式（假设函数）

1、样本x特征值有1个，
$Y = kx + b$ 线性关系
2 、样本特征值x由多个

损失函数种类

LS
MSE
MAE

让损失函数最小的方法

1、通过求方程法（求导、求偏导）
2、梯度下降法：利用梯度逐步逼近最优解

梯度下降法与正规方程对比

梯度下降

- 需要选择学习率
- 需要迭代求解
- 特征数量较大可以使用
- 应用场景：更加普适，迭代的计算方式，适合于嘈杂、大数据应用场景
- 注意：梯度下降在各种损失函数（目标函数）求解中大量使用。深度学习中更是如此，深度学习模型参数很轻松就上亿，只能通过迭代的方式求最优解。

正规方程

- 不需要学习率
- 一次运算得出，一蹴而就
- 应用场景：小数据量场景、精准的数据场景
- 缺点：计算量大、容易收到噪声、特征强相关性的影响
- 注意：X^TX的逆矩阵不存在时，无法求解
- 注意：计算X^TX的逆矩阵非常耗时
- 如果数据规律不是线性的，无法使用或效果不好

目录

Contents

- 线性回归简介
  定义、线性回归的分类、应用场景
- 线性回归问题的求解
  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法
- 回归模型评估方法
  MAE、MSE、RMSE
- 线性回归API和梯度下降API
  波斯顿案例

学习目标

Learning Objectives

1. 掌握常用的回归评估方法
2. 了解不同评估方法的特点

线性回归模型评估 - MAE、MSE、RMSE三种指标

- **为什么要进行线性回归模型的评估**
  - 我们希望衡量预测值和真实值之间的差距，
  - 会用到MAE、MSE、RMSE**多种测评函数进行评价**

- **均方误差 Mean Squared Error MSE**

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

n 为样本数量，y 为实际值，ŷ为预测值

MSE 越小模型预测约准确

```
from sklearn.metrics import mean_squared_error
mean_squared_error(y_test,y_predict)
```

- **平均绝对误差 Mean Absolute Error MAE**

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

n 为样本数量，y 为实际值，ŷ为预测值

MAE 越小模型预测约准确

```
from sklearn.metrics import mean_absolute_error
mean_absolute_error(y_test,y_predict)
```

- **均方根误差 Root Mean Squared Error (RMSE)**

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

n 为样本数量，y 为实际值，ŷ为预测值

RMSE 越小模型预测约准确

RMSE 是 MSE 的平方根，某些情况下比MSE更有用

总结

1 一般使用MAE 和 RMSE 这两个指标

- MAE反应的是“真实”的平均误差，RMSE会将误差大的数据点放大
- MAE 不能体现出误差大的数据点，RMSE放大大误差的数据点对指标的影响， 但是对异常数据比较敏感

2 综合结论

- 都能反映出预测值和真实值之间的误差
- MAE对误差大小不敏感
- RMSE会放大预测误差较大的样本的影响
- RMSE对异常数据敏感

目录

Contents

- 线性回归简介

  定义、线性回归的分类、应用场景

- 线性回归问题的求解

  线性回归API、损失函数、导数和矩阵、正规方程法、梯度下降算法

- 回归模型评估方法

  MAE、MSE、RMSE

- 线性回归API和梯度下降API

  波斯顿案例

线性回归正规方程API和梯度下降API

sklearn提供两种实现的API， 根据选择使用

1: sklearn.linear_model.LinearRegression(fit_intercept=True)

- 通过正规方程优化
- 参数：fit_intercept，是否计算偏置
- 属性：LinearRegression.coef_ （回归系数） LinearRegression.intercept_（偏置）

2: sklearn.linear_model.SGDRegressor(loss="squared_loss", fit_intercept=True, learning_rate ='constant', eta0=0.01)

- SGDRegressor类实现了随机梯度下降学习，它支持不同的损失函数和正则化惩罚项，来拟合线性回归模型。
- 参数

  loss（损失函数类型） eg：loss=" squared_loss"

  fit_intercept（是否计算偏置）

  learning_rate （学习率策略）：string, optional ，可以配置学习率随着迭代次数不断减小

  - 比如：学习率不断变小策略： ‘invscaling’ : eta = eta0 / pow(t, power_t=0.25)

  eta0=0.01 （学习率的值）
- 属性

  SGDRegressor.coef_ （回归系数）SGDRegressor.intercept_ （偏置）

波士顿房价预测

- 1 案例背景 – 数据来源

实例数量:	506
属性数量:	13 数值型或类别型，帮助预测的属性

:中位数（第14个属性）经常是学习目标

属性信息 (按顺序):	• CRIM 城镇人均犯罪率 • ZN 占地面积超过2.5万平方英尺的住宅用地比例 • INDUS 城镇非零售业务地区的比例 • CHAS 查尔斯河虚拟变量 (= 1 如果土地在河边；否则是0) • NOX 一氧化氮浓度（每1000万份） • RM 平均每居民房数 • AGE 在1940年之前建成的所有者占用单位的比例 • DIS 与五个波士顿就业中心的加权距离 • RAD 辐射状公路的可达性指数 • TAX 每10,000美元的全额物业税率 • PTRATIO 城镇师生比例 • B 1000(Bk - 0.63)^2 其中 Bk 是城镇的黑人比例 • LSTAT 人口中地位较低人群的百分数 • MEDV 以1000美元计算的自有住房的中位数
缺失属性值:	无
创建者:	Harrison, D. and Rubinfeld, D.L.

这是UCI ML（欧文加利福尼亚大学 机器学习库）房价数据集的副本。 http://archive.ics.uci.edu/ml/datasets/Housing

该数据集是从位于卡内基梅隆大学维护的StatLib图书馆取得的。

波士顿房价预测

- 1 案例背景 – 数据属性

属性名	解释	类型
CRIM	该镇的人均犯罪率	连续值
ZN	占地面积超过25,000平方呎的住宅用地比例	连续值
INDUS	非零售商业用地比例	连续值
CHAS	是否邻近 Charles River	离散值，1=邻近；0=不邻近
NOX	一氧化氮浓度	连续值
RM	每栋房屋的平均客房数	连续值
AGE	1940年之前建成的自用单位比例	连续值
DIS	到波士顿5个就业中心的加权距离	连续值
RAD	到径向公路的可达性指数	连续值
TAX	全值财产税率	连续值
PTRATIO	学生与教师的比例	连续值
B	1000(BK - 0.63)^2，其中BK为黑人占比	连续值
LSTAT	低收入人群占比	连续值
MEDV	同类房屋价格的中位数	连续值

波士顿房价预测

- 2 案例分析

  回归当中的数据大小不一致，是否会导致结果影响较大。所以需要做标准化处理。

  - 数据分割与标准化处理
  - 回归预测
  - 线性回归的算法效果评估

- 3 回归性能评估

  均方误差(Mean Squared Error)MSE)**评价机制：**

  $$MSE = \frac{1}{m}\sum_{i=1}^{m}\left(y^i - \bar{y}\right)^2$$

  sklearn.metrics.mean_squared_error(y_true, y_pred)

  均方误差回归损失

  - y_true:真实值
  - y_pred:预测值
  - return:浮点数结果

波士顿房价预测

- 导入库

```
from sklearn.datasets import load_boston                # 数据
from sklearn.preprocessing import StandardScaler        # 特征处理
from sklearn.model_selection import train_test_split    # 数据集划分
from sklearn.linear_model import LinearRegression       # 正规方程的回归模型
from sklearn.linear_model import SGDRegressor           # 梯度下降的回归模型
from sklearn.metrics import mean_squared_error          # 均方误差评估

from sklearn.linear_model import Ridge, RidgeCV
```

波士顿房价预测

- 正规方程

```
 正规方程
def linear_model1():
    # 1 获取数据
    data = load_boston()

    # 2 数据集划分
    x_train, x_test, y_train, y_test = train_test_split(data.data, data.target,
random_state=22)

    # 3 特征工程-标准化
    transfer = StandardScaler()
    x_train = transfer.fit_transform(x_train)
    x_test = transfer.transform(x_test)

    # 4 机器学习-线性回归(正规方程)
    estimator = LinearRegression()
    estimator.fit(x_train, y_train)

    # 5 模型评估 # 获取模型系数
    y_predict = estimator.predict(x_test)
    print("预测值为:\n", y_predict)
    print("模型的权重系数为:\n", estimator.coef_)
    print("模型的偏置为:\n", estimator.intercept_)

    # 5.2 评价 均方误差
    error = mean_squared_error(y_test, y_predict)
    print("误差为:\n", error)
```

波士顿房价预测

- 梯度下降

```
# 梯度下降方式
def linear_model2():
    # 1.获取数据
    data = load_boston()

    # 2.数据集划分
    x_train, x_test, y_train, y_test = train_test_split(data.data, data.target, random_state=22)

    # 3.特征工程-标准化
    transfer = StandardScaler()
    x_train = transfer.fit_transform(x_train)
    x_test = transfer.transform(x_test)

    # 4.机器学习-线性回归(正规方程)
    estimator = SGDRegressor()
    # estimator = SGDRegressor(max_iter=1000, learning_rate="constant", eta0=0.001)
    estimator.fit(x_train, y_train)

    # 5.模型评估 # 5.1 获取模型参数
    y_predict = estimator.predict(x_test)
    print("预测值为:\n", y_predict)
    print("模型的权重系数为:\n", estimator.coef_)
    print("模型的偏置为:\n", estimator.intercept_)

    # 5.2 评价 均方误差
    error = mean_squared_error(y_test, y_predict)
    print("误差为:\n", error)
```

总结

1 正规方程

- sklearn.linear_model.LinearRegression()

2 梯度下降

- sklearn.linear_model.SGDRegressor(）

黑马程序员

www.itheima.com

传智教育旗下高端IT教育品牌