逻辑回归

黑马程序员
www.itheima.com
传智教育旗下
高端IT教育品牌

目录

Contents

- 逻辑回归简介
  应用场景，数学知识
- 逻辑回归原理
- 逻辑回归API函数和案例

学习目标

Learning Objectives

1. 知道逻辑回归的应用场景
2. 复习逻辑回归应用到的数学知识

逻辑回归的应用场景

预测疾病 （是阳性、不是阳性）

银行信任贷款（放贷、还是不放贷）

情感分析 （正面、负面）

预测广告点击率 （点击、不点击）

逻辑回归是解决二分类问题的利器，你还能想到哪些二分类的场景？

逻辑回归数学基础 - sigmoid函数

逻辑回归(Logistic Regression)通过将线性回归的输出映射到(0,1)区间，使用Sigmoid函数将连续值转换为概率值，然后根据概率值进行分类预测。

- Sigmoid函数 $f(x) = \frac{1}{1+e^{-x}}$

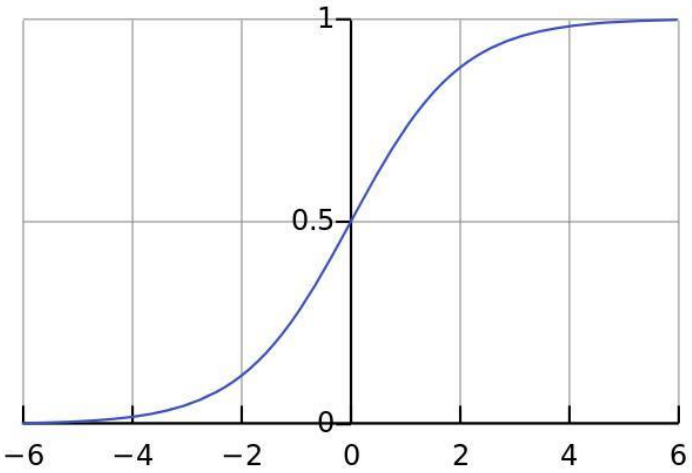

- 作用 把(-∞, +∞) 映射到 (0， 1)

- 数学性质 单调递增函数

  拐点在x=0时y=0.5的位置,此时斜率最大

  当 f(x)>0.5时，预测结果为1；

  当 f(x)<0.5 时，预测结果为0。

- 导函数公式 $f'(x) = f(x)(1 - f(x))$

  这个导数公式在计算梯度下降等优化算法时非常有用

逻辑回归数学基础 - 概率

- 边际概率 - 描述的是单一事件发生的可能性: 记作P(A) 或者 P(B)
- 联合概率 - 描述的是两个或多个独立事件同时发生的概率:记作 P(A∩B) 或 P(A,B)
- 条件概率 - 描述的是在事件A已发生的条件下，事件B发生的概率:记作 P(B | A)

场景1：联合概率（独立事件）

- 事件：
  - A：周一早上堵车，$P(A) = 0.7$
  - B：周二早上堵车，$P(B) = 0.7$（假设独立）
- 联合概率：

$\boxed{P(A \cap B) = P(A) \times P(B)}$ $P(A \cap B) = 0.7 \times 0.7 = 0.49$

场景2：条件概率（依赖事件）

- 事件：
  - A：周一早上堵车，$P(A) = 0.7$
  - B：周一中午堵车，且已知 $P(B|A) = 0.3$（即早上堵车时，中午堵车的概率为 0.3）
- 联合概率：

$\boxed{P(A \cap B) = P(A) \times P(B \mid A)}$ $P(A \cap B) = 0.7 \times 0.3 = 0.21$

- 条件概率：

$\boxed{P(B|A) = \frac{P(A \cap B)}{P(A)}}$ $P(B|A) = 0.3$ （题目直接给出）

总结

1 逻辑回归的作用？

解决二分类问题

2 激活函数 sigmoid 作用？

把 数值 映射到 (0， 1）区间,进行分类预测

3 极大似然估计

通过极大化概率事件，来估计最优参数

目录

Contents

- 逻辑回归简介
  应用场景，数学知识
- 逻辑回归原理
- 逻辑回归API函数和案例

学习目标

Learning Objectives

1. 理解逻辑回归算法的原理
2. 知道逻辑回归的优化操作

逻辑回归原理 - 概念

- 逻辑回归概念 Logistic Regression
  - 一种分类模型，把线性回归的输出，作为逻辑回归的输入。
  - 输出是（0, 1）之间的值
- 基本思想
  1. 利用线性模型 $f(x) = w^T x + b$ 根据特征的重要性计算出一个值
  2. 再使用 sigmoid 函数将 f(x) 的输出值映射为概率值
     1. 设置阈值(eg：0.5)
     2. 输出概率值大于 0.5，则将未知样本输出为 1 类
     3. 否则输出为 0 类
- 逻辑回归的假设函数

  $h(w) = \text{sigmoid}(w^T x + b)$

  线性回归的输出，作为逻辑回归的输入

逻辑回归原理 - 概念

- 举个栗子：逻辑回归预测过程（阈值为0.6）

样本特征值输入				回归		逻辑回归结果		预测结果	真实结果
12.3	20.0	16		82.4		0.4		B	A
9.4	21.1	7.2	回归计算	89.1	sigmoid	0.68		A	B
34.4	18.7	8.1	x W =	80.2	→	0.41	→	B	A
10.2	16.0	12.5		81.3		0.55		B	B
5.6	10.0	6.3		90.4		0.71		A	A

假设得出概率值是属于A的概率值

逻辑回归原理 – 交叉熵损失函数

- 交叉熵是衡量两个概率分布（真实分布 y和预测分布 p）差异的指标

最小化交叉熵损失函数实际上是在寻找能够最大化观测数据的对数似然性的模型

$$\text{Loss}(L) = -\sum_{i=1}^{m} (y_i \log(p_i) + (1 - y_i) \log(1 - p_i))$$

- y_i：第 i 个样本的真实标签，通常取值为 0 或 1（二分类问题）。
- p_i：模型预测的第 i 个样本属于类别 1 的概率（即 $P(y_i = 1|x_i)$）。
- log：自然对数（以 e 为底）。
- **求和**：对所有样本（共 m 个）的损失求和。

- 举个栗子 – 损失函数手工计算

样本特征值输入				回归		逻辑回归结果		真实结果
12.3	20.0	16		82.4		0.4		1
9.4	21.1	7.2	回归计算	89.1	sigmoid	0.68		0
34.4	18.7	8.1	x W =	80.2	→	0.41	→	1
10.2	16.0	12.5		81.3		0.55		0
5.6	10.0	6.3		90.4		0.71		1

计算损失示例：= [1log0.40 + (1-1)log(1-0.40) + # 第1个样本产生的损失

0log0.68 + (1-0)log(1-0.68) + # 第2个样本产生的损失

1log0.41 + (1-1)log(1-0.41) + …. # ...

逻辑回归原理 – 似然函数

- 1、伯努利分布

伯努利分布是描述**单次二分类试验**结果的离散概率分布，其随机变量 X 只有两种取值：

- $X = 1$（表示"成功"，概率为 p），
- $X = 0$（表示"失败"，概率为 $1 - p$）。

概率质量函数（PMF）：

$$P(X = k) = \begin{cases} p & \text{if } k = 1, \\ 1 - p & \text{if } k = 0. \end{cases}$$

或简写为：

$$P(X = k) = p^k (1 - p)^{1-k}, \quad k \in \{0, 1\}$$

- 2、伯努利分布函数

假设：有样本[(x_1, y_1)，(x_1, y_2) ⋯，(x_n, y_n)]，n个样本都预测正确的概率就是伯努利分布的似然函数

$$P = P(y_1|x_1)P(y_2|x_2)\ldots P(y_n|x_n) = \prod_{i=1}^{n} p^{y_i}(1-p)^{1-y_i}$$

1. p_i 表示每个样本被分类正确时的概率
2. y_i 表示每个样本的真实类别（0或1）

问题转化为：让联合概率事件最大时，估计w、b的权重参数，这就是极大似然估计（Maximum Likelihood Estimation）

其核心思想是：在已知观测数据的情况下，选择使得这些数据出现概率最大的参数值。

逻辑回归原理 – 交叉熵和似然函数关系

伯努利分布的似然函数是逻辑回归交叉熵损失的来源,对其取负对数，直接得到交叉熵损失!

1.把最大化问题将其变为最小化问题(最大化似然函数 -> 最小化交叉熵损失)：

$$P = P(y_1|x_1)P(y_2|x_2)\ldots P(y_n|x_n) = \prod_{i=1}^{n} p^{y_i}(1-p)^{1-y_i}$$

$$\text{Loss}(L) = -\sum_{i=1}^{m}(y_i\log(p_i) + (1-y_i)\log(1-p_i))$$

2.把连乘问题将其变为连加问题：

假设数据 $y = [1, 0]$，模型预测 $p = [0.8, 0.3]$:

1. **伯努利似然**:

$$L = 0.8^1 \times (1-0.8)^0 \times 0.3^0 \times (1-0.3)^1 = 0.8 \times 0.7 = 0.56$$

2. **交叉熵损失**:

$$\text{Loss} = -[1\cdot\log(0.8) + 0\cdot\log(0.3) + 0\cdot\log(0.2) + 1\cdot\log(0.7)] \approx 0.713$$

总结

1 逻辑回归核心思想

- 思想：解决分类问题，把线性回归的输出作为逻辑回归的输入

2 逻辑回归的优化操作

- 极大化似然函数
- 最小化交叉熵损失

目录

Contents

- 逻辑回归简介
  应用场景，数学知识
- 逻辑回归原理
- 逻辑回归API函数和案例

学习目标

Learning Objectives

1. 知道逻辑回归的API
2. 动手实现癌症分类案例

逻辑回归API函数和案例 - 案例癌症分类预测

- **数据描述**

（1）699条样本，共11列数据，第一列用于检索的id，后9列分别是与肿瘤相关的医学特征，最后一列表示肿瘤类型的数值。

（2）包含16个缺失值，用”?”标出。

（3）2表示良性，4表示恶性

- **逻辑回归API**

sklearn.linear_model.LogisticRegression()

	A	B	C	D	E	F	G	H	I	J	K
1	Sample code number	Clump Thickness	Uniformity of Cell Size	Uniformity of Cell Shape	Marginal Adhesion	Single Epithelial Cell Size	Bare Nuclei	Bland Chromatin	Normal Nucleoli	Mitoses	Class
2	1000025	5	1	1	1	2	1	3	1	1	2
3	1002945	5	4	4	5	7	10	3	2	1	2
4	1015425	3	1	1	1	2	2	3	1	1	2
5	1016277	6	8	8	1	3	4	3	7	1	2
6	1017023	4	1	1	3	2	1	3	1	1	2
7	1017122	8	10	10	8	7	10	9	7	1	4
8	1018099	1	1	1	1	2	10	3	1	1	2
9	1018561	2	1	2	1	2	1	3	1	1	2
10	1033078	2	1	1	1	2	1	1	1	5	2
11	1033078	4	2	1	1	2	1	2	1	1	2
12	1035283	1	1	1	1	1	1	3	1	1	2
13	1036172	2	1	1	1	2	1	2	1	1	2
14	1041801	5	3	3	3	2	3	4	4	1	4
15	1043999	1	1	1	1	2	3	3	1	1	2

逻辑回归API函数和案例 - 癌症分类预测

- 代码实现

```
def dm_LogisticRegression():
    # 1 获取数据
    data = pd.read_csv('./data/breast-cancer-wisconsin.csv')
    data.info()
    # 2 基本数据处理
    # 2.1 缺失值处理
    data = data.replace(to_replace="?", value=np.NaN)
    data = data.dropna()
    # 2.2 确定特征值,目标值
    x = data.iloc[:, 1:-1]
    print('x.head()-->\n', x.head())
    y = data["Class"]
    print('y.head()-->\n', y.head())
    # 2.3 分割数据
    x_train, x_test, y_train, y_test = train_test_split(x, y, random_state=22)

    # 3 特征工程(标准化)
    transfer = StandardScaler()
    x_train = transfer.fit_transform(x_train)
    x_test = transfer.transform(x_test)
    # 4 机器学习(逻辑回归)
    estimator = LogisticRegression()
    estimator.fit(x_train, y_train)
    # 5 模型评估
    y_predict = estimator.predict(x_test)
    print('y_predict-->', y_predict)
    accuracy = estimator.score(x_test, y_test)
    print('accuracy-->', accuracy)
```

黑马程序员

www.itheima.com

传智教育旗下高端IT教育品牌