聚类算法

黑马程序员
www.itheima.com
传智教育旗下
高端IT教育品牌

目录

Contents

- 聚类算法简介
- 聚类算法API的使用

学习目标

Learning Objectives

1. 知道什么是聚类
2. 了解聚类算法的应用场景
3. 知道聚类算法的分类

聚类算法 - 概念

- 什么是聚类算法？

  聚类算法是一类无监督学习方法，旨在将数据划分为若干组（簇），使得同一簇内的样本相似度高，而不同簇间的样本差异大。

  - 根据样本之间的相似性，将样本划分到不同的类别中；不同的相似度计算方法，会得到不同的聚类结果，常用的相似度计算方法有欧式距离法。
  - 聚类算法的目的是在没有先验知识的情况下，自动发现数据集中的内在结构和模式。

- 使用不同的聚类准则，产生的聚类结果不同

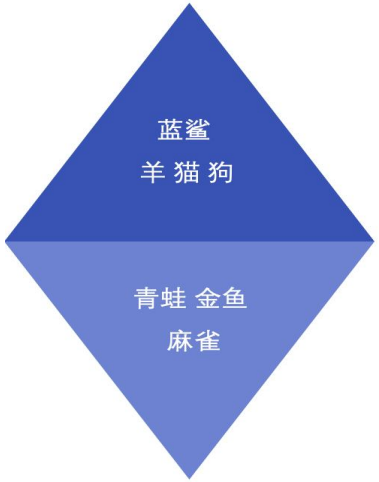

繁衍方式（胎生、卵生）

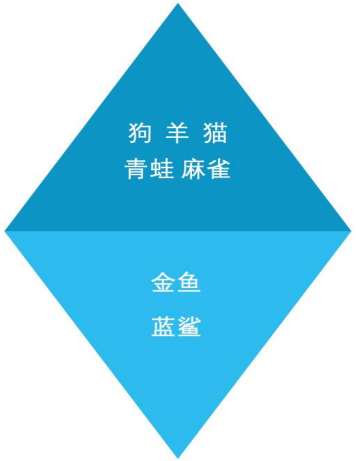

呼吸方式（肺、腮）

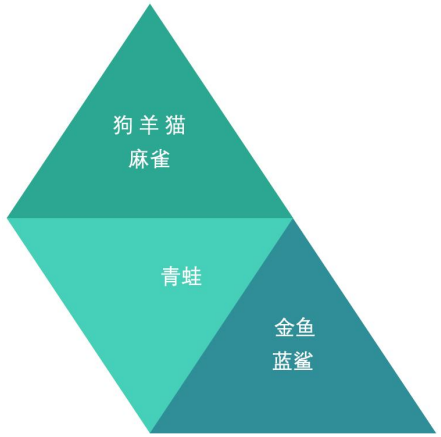

生活环境(陆地、两栖、水中)

聚类算法在现实生活中的应用

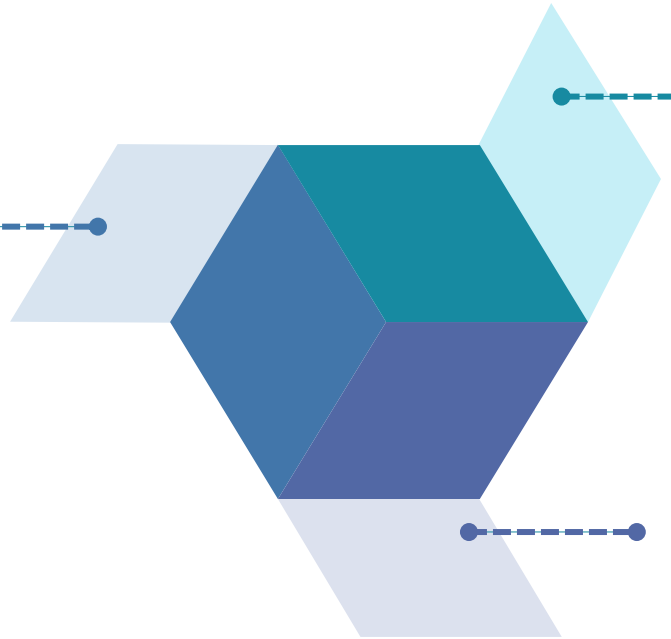

基于位置信息的商业推送
新闻聚类，筛选排序

用户画像，广告推荐
Data Segmentation
搜索引擎的流量推荐
恶意流量识别

图像分割，降维，识别
离群点检测，信用卡异常消费
发掘相同功能的基因片段

聚类算法分类

1. 根据聚类颗粒度分类

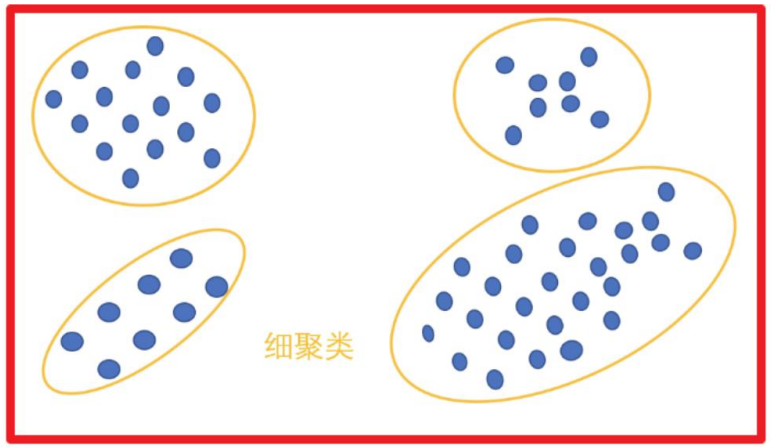

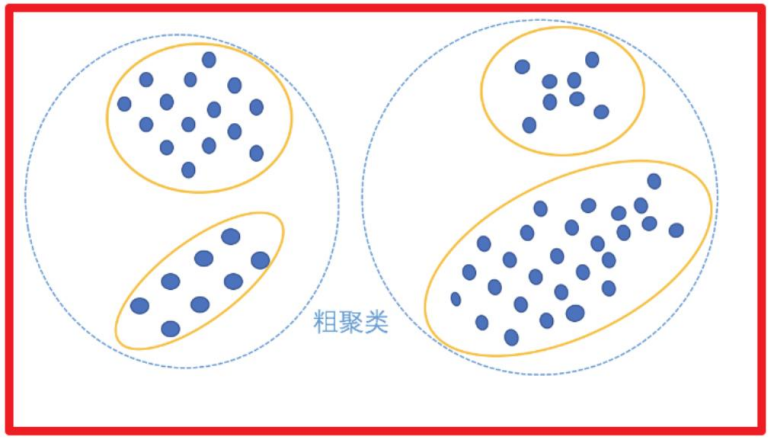

2. 根据实现方法分类

- 基于划分的聚类：K-means算法->按照质心(一个簇的中心位置,通过均值计算)分类
- 基于层次的聚类：DIANA（自顶向下）AGNES（自底向上）
- 基于密度的聚类：DBSCAN算法
- 基于图的聚类：谱聚类（Spectral Clustering）
- ...

总结

1 聚类概念

无监督学习算法，主要用于将相似的样本自动归到一个类别中；

计算样本和样本之间的相似性，一般使用欧式距离

2 聚类分类

- 颗粒度：粗聚类、细聚类。
- 实现方法： K-means聚类、层次聚类、 DBSCAN聚类、谱聚类

目录

Contents

- 聚类算法简介
- 聚类算法API的使用

学习目标

Learning Objectives

1. 了解Kmeans算法的API
2. 动手实践Kmeans算法

聚类算法API

- sklearn.cluster.KMeans(n_clusters=8)
  - 参数：n_clusters:开始的聚类中心数量
    整型，缺省值=8，生成的聚类数，即产生的质心（centroids）数。
  - 方法
    estimator.fit(x)
    estimator.predict(x)
    estimator.fit_predict(x)：计算聚类中心并预测每个样本属于哪个类别，
    相当于先调用fit(x),然后再调用predict(x)

案例 使用KMeans模型数据探索聚类

随机创建不同二维数据集作为训练集，并结合k-means算法将其聚类，尝试分别聚类不同数量的簇，并观察聚类效果：

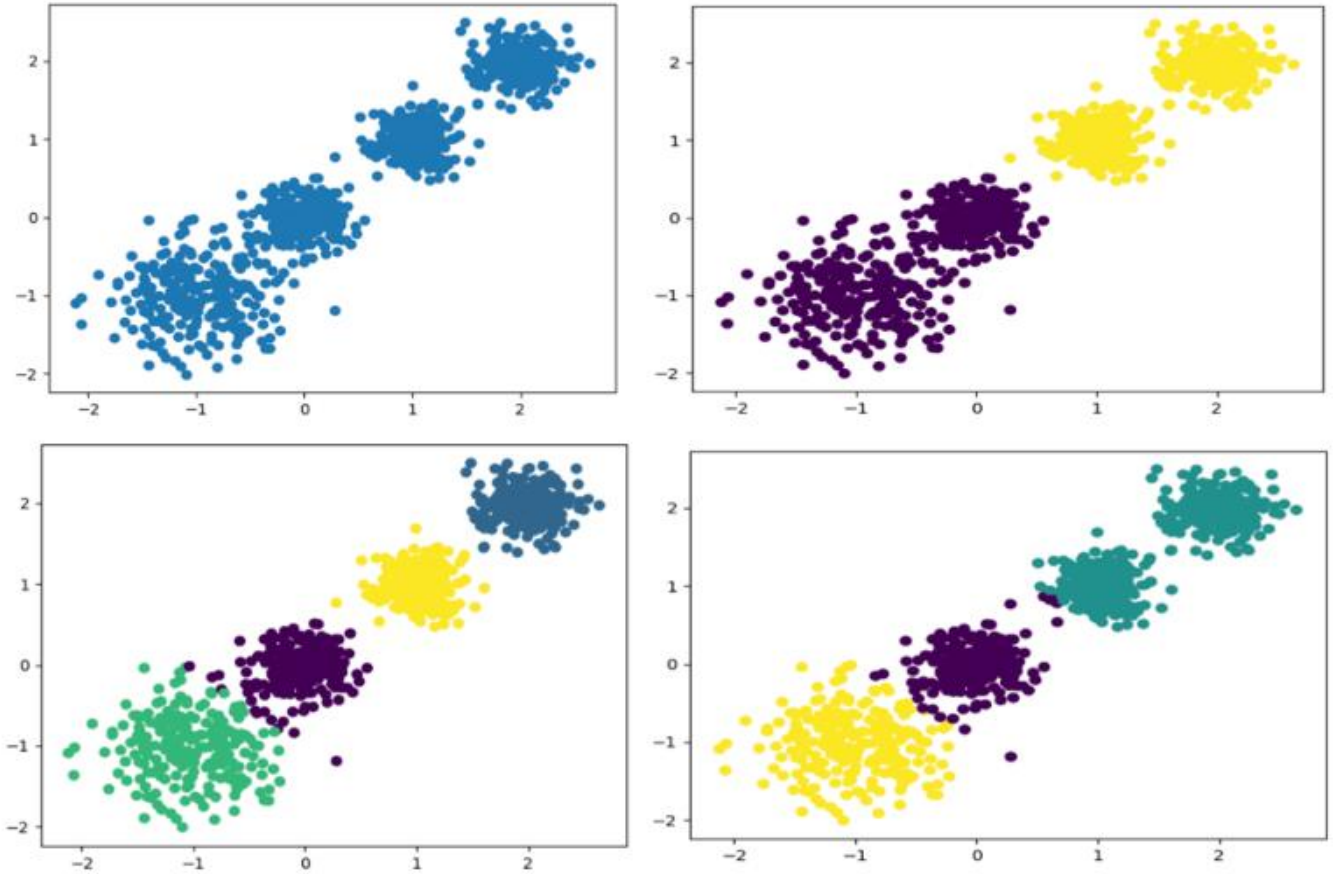

案例

使用KMeans模型数据探索聚类

1 导包 sklearn.cluster.KMeans sklearn.datasets.make_blobs

2 创建数据集

3 实例化Kmeans模型并预测

4 展示聚类效果

5 评估聚类效果好坏

案例

使用KMeans模型数据探索聚类

```
# 1.导入工具包
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs
from sklearn.metrics import calinski_harabasz_score  # calinski_harabaz_score 废弃
# 2 创建数据集 1000个样本, 每个样本2个特征 4个质心簇数据标准差[0.4, 0.2, 0.2, 0.2]
x, y = make_blobs(n_samples=1000, n_features=2, centers=[[-1,-1], [0,0], [1,1], [2,2]],
            cluster_std = [0.4, 0.2, 0.2, 0.2], random_state=22)
plt.figure()
plt.scatter(x[:, 0], x[:, 1], marker='o')
plt.show()

# 3 使用k-means进行聚类, 并使用CH方法评估
y_pred = KMeans(n_clusters=4, random_state=22).fit_predict(x)
plt.scatter(x[:, 0], x[:, 1], c=y_pred)
plt.show()

# 4 模型评估
print(calinski_harabasz_score(x, y_pred))
```

总结

聚类算法API

```
sklearn.cluster.KMeans(n_clusters=8)
```

黑马程序员

www.itheima.com

传智教育旗下高端IT教育品牌