神经网络基础

黑马程序员
www.itheima.com
传智教育旗下
高端IT教育品牌

学习目标

Learning Objectives

1. 知道什么是人工神经网络
2. 知道常见的激活函数
3. 了解常见的参数初始化方法
4. 能够完成神经网络模型的搭建
5. 知道常见的损失函数
6. 知道神经网络模型参数的计算方法

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

什么是神经网络

人工神经网络（ Artificial Neural Network， 简写为ANN）也简称为神经网络（NN），是一种模仿生物神经网络结构和功能的**计算模型**。人脑可以看做是一个生物神经网络，由众多的**神经元**连接而成。各个神经元传递复杂的电信号，树突接收到**输入信号**，然后对信号进行处理，通过轴突**输出信号**。下图是生物神经元示意图：

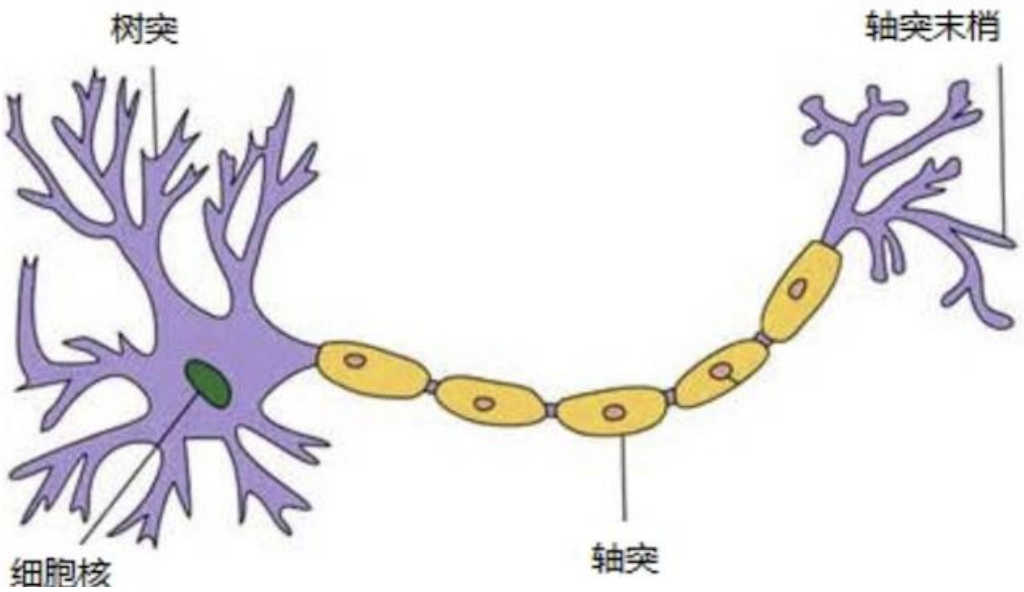

当电信号通过树突进入到细胞核时，会逐渐聚集电荷。达到一定的电位后，细胞就会被激活，通过轴突发出电信号。

神经网络相关概念

1. **神经元（Neuron）**
   - 神经网络的基本单元，模拟生物神经元。
   - 接收输入信号（$x_1, x_2, \ldots, x_n$），加权求和（$w_1x_1 + w_2x_2 + \ldots + b$，其中 b 是偏置项）过**激活函数**（如ReLU、Sigmoid）输出结果。
2. **层（Layer）**
   - **输入层**：接收原始数据（如图像像素、文本向量）。
   - **隐藏层**：介于输入和输出层之间，负责特征提取和转换（深度网络有多层隐藏层）。
   - **输出层**：生成最终预测结果（如分类概率、回归值）。
3. **权重（Weights）与偏置（Bias）**
   - 权重决定输入信号的重要性，偏置调整神经元的激活阈值。
   - 通过训练（如反向传播）不断调整这些参数。
4. **激活函数（Activation Function）**
   - 引入非线性，使网络能拟合复杂函数。常见函数：
     - **Sigmoid**：输出范围(0,1)，适用于概率。
     - **ReLU**：简单高效，解决梯度消失问题。
     - **Softmax**：多分类输出归一化。
5. **前向传播（Forward Propagation）**
   - 数据从输入层逐层计算，最终得到输出结果。
6. **损失函数（Loss Function）**
   - 衡量预测值与真实值的差异（如交叉熵损失、均方误差）。
7. **反向传播（Backpropagation）**
   - 根据损失函数，从输出层反向计算梯度，利用优化器（如SGD、Adam）调整权重。

神经元

神经网络是由多个神经元组成，构建神经网络就是在构建神经元。以下是神经网络中神经元的构建说明：

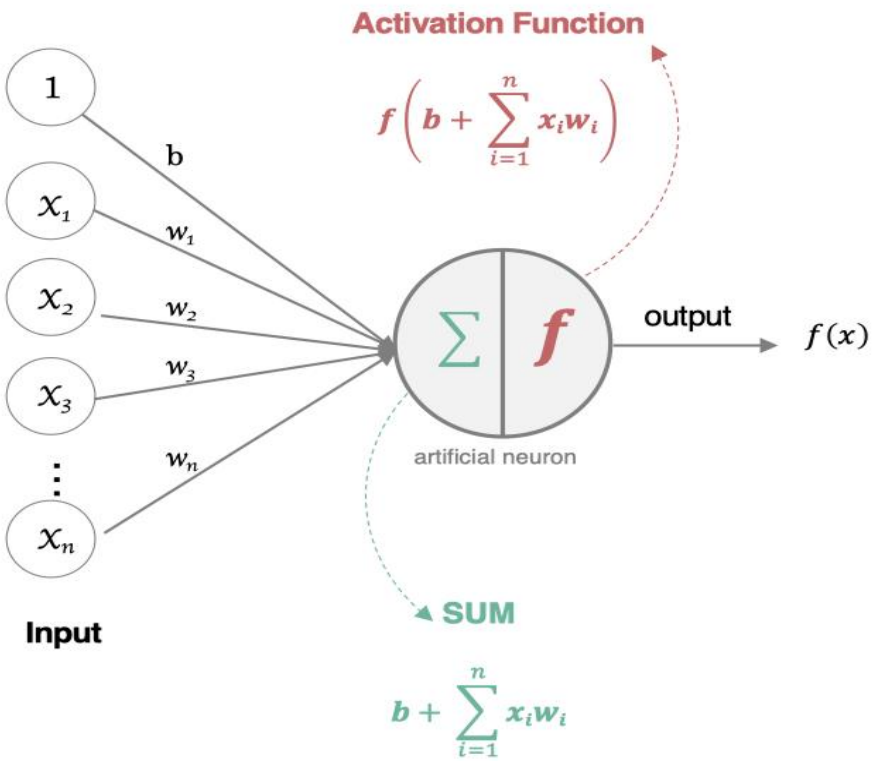

这个过程就像，来源不同树突(树突都会有不同的权重)的信息，进行的加权计算，输入到细胞中做加和，再通过激活函数输出细胞值。

如何构建神经网络

神经网络中信息只向一个方向移动，即从输入节点向前移动，通过隐藏节点，再向输出节点移动。其中的基本部分是:

1. **输入层（Input Layer）**：即输入x的那一层（如图像、文本、声音等）。每个输入特征对应一个神经元。输入层将数据传递给下一层的神经元。

2. **输出层（Output Layer）**：即输出y的那一层。输出层的神经元根据网络的任务（回归、分类等）生成最终的预测结果。

3. **隐藏层（Hidden Layers）**：输入层和输出层之间都是隐藏层，神经网络的“深度”通常由隐藏层的数量决定。隐藏层的神经元通过加权和激活函数处理输入，并将结果传递到下一层。

特点是：

- 同一层的神经元之间没有连接
- 第 N 层的每个神经元和第 N-1层 的所有神经元相连（这就是full connected的含义），这就是全连接神经网络
- 全连接神经网络接收的样本数据是二维的，数据在每一层之间需要以二维的形式传递
- 第N-1层神经元的输出就是第N层神经元的输入
- 每个连接都有一个权重值（w系数和b系数）

建神经网络图解

多个神经元构成神经网络，相邻层之间的神经元相互连接，且都有权重与偏置，如下图所示：

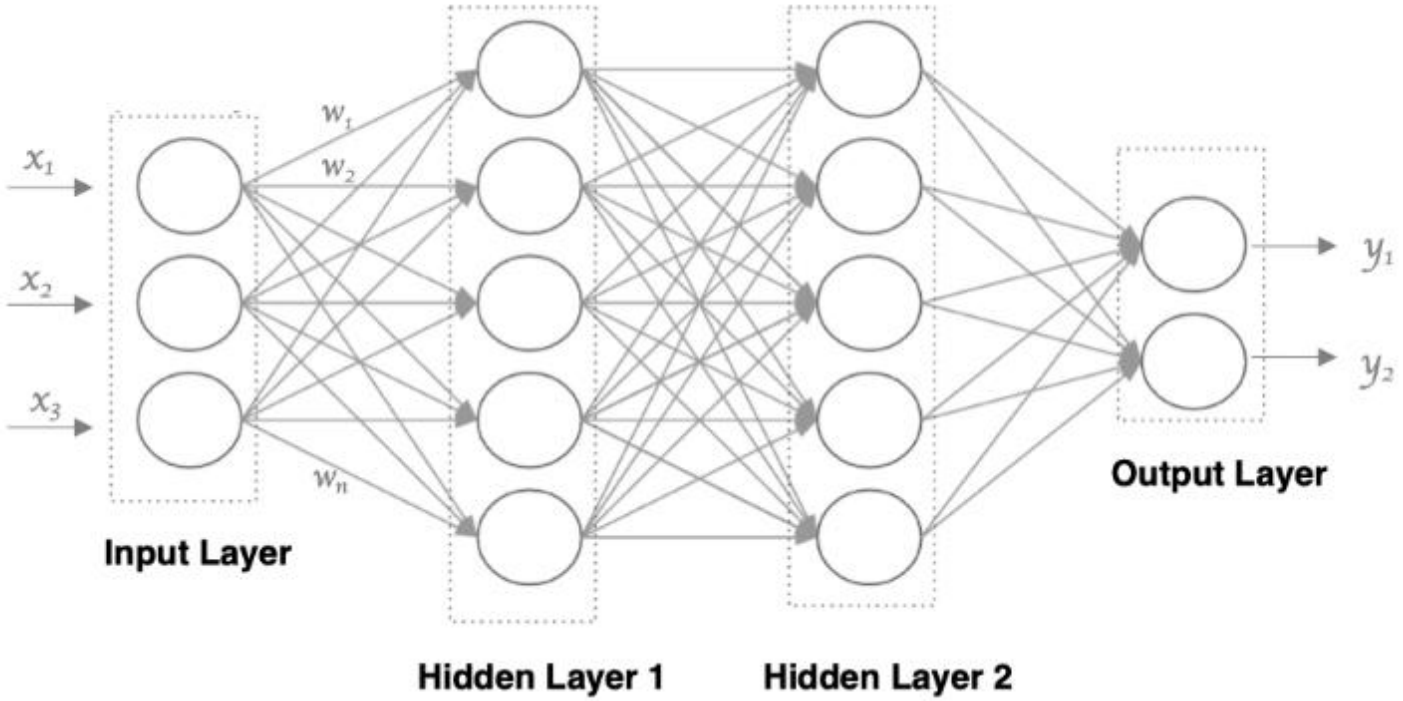

神经网络内部状态值和激活值

每一个神经元工作时，会产生4个值：

前向传播会产生**内部状态值（加权求和值）**和**激活值**；反向传播时会产生**激活值梯度**和**内部状态值梯度**。

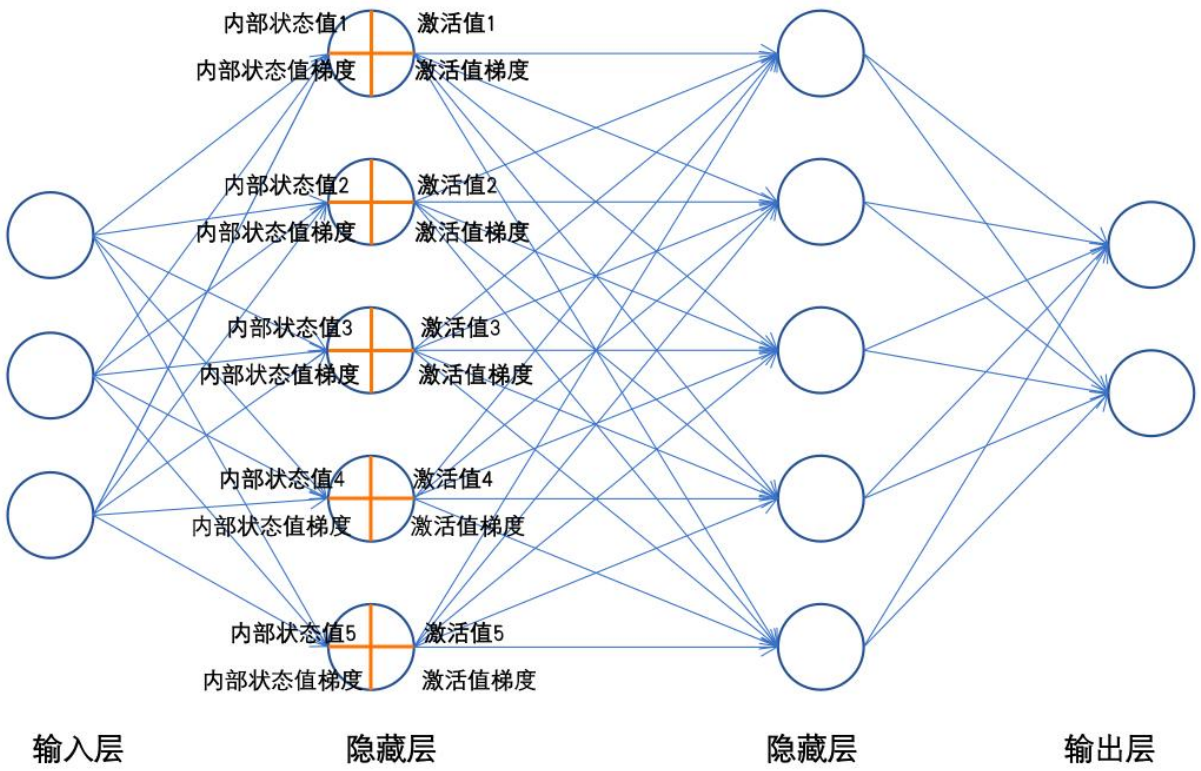

内部状态值： $z = W \cdot x + b$

W：权重矩阵

x：输入值

b：偏置

激活值： $a=f(z)$

f：激活函数

z：内部状态值

总结

1. 知道神经网络是什么

一种模仿生物神经网络结构和功能的计算模型，由神经元构成（加权和+激活函数）

2. 神经网络的构成

输入层，隐藏层和输出层

3. 知道什么是内部状态和激活值

内部状态值:神经元接收到的输入、历史信息以及网络内部的权重计算结果

激活值:激活函数对内部状态值进行非线性变换后得到的结果

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

激活函数

激活函数用于对每层的**输出数据进行变换**，进而为整个网络注入了**非线性因素**。此时，神经网络就可以拟合各种曲线。

1. 没有引入非线性因素的网络等价于使用一个线性模型来拟合
2. 通过给网络输出增加激活函数，实现引入非线性因素，使得网络模型可以逼近任意函数，提升网络对复杂问题的拟合能力.

激活函数

神经网络中的激活函数（Activation Function）决定了神经元的输出特性，不同的激活函数在值域、导数（梯度）、计算效率等方面有显著差异。

如果不使用激活函数，其本质还相当于一种**线性模型,所以激活函数最重要作用是：引入非线性因素**

常见的激活函数：

激活函数	公式	值域	导数范围
Sigmoid	$\frac{1}{1+e^{-x}}$	(0, 1)	(0, 0.25]
Tanh	$\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$	(-1, 1)	(0, 1]
ReLU	$\max(0, x)$	[0, +∞)	{0, 1}
Softmax	$\frac{e^{x_i}}{\sum_j e^{x_j}}$	(0, 1)（和为1）	复杂

神经网络演示

常见的激活函数-sigmoid 激活函数

激活函数公式：

$$f(x) = \frac{1}{1 + e^{-x}}$$

激活函数求导公式：

$$f'(x) = \left(\frac{1}{1+e^{-x}}\right)' = \frac{1}{1+e^{-x}}\left(1 - \frac{1}{1+e^{-x}}\right) = f(x)(1 - f(x))$$

sigmoid 激活函数的函数图像如下：

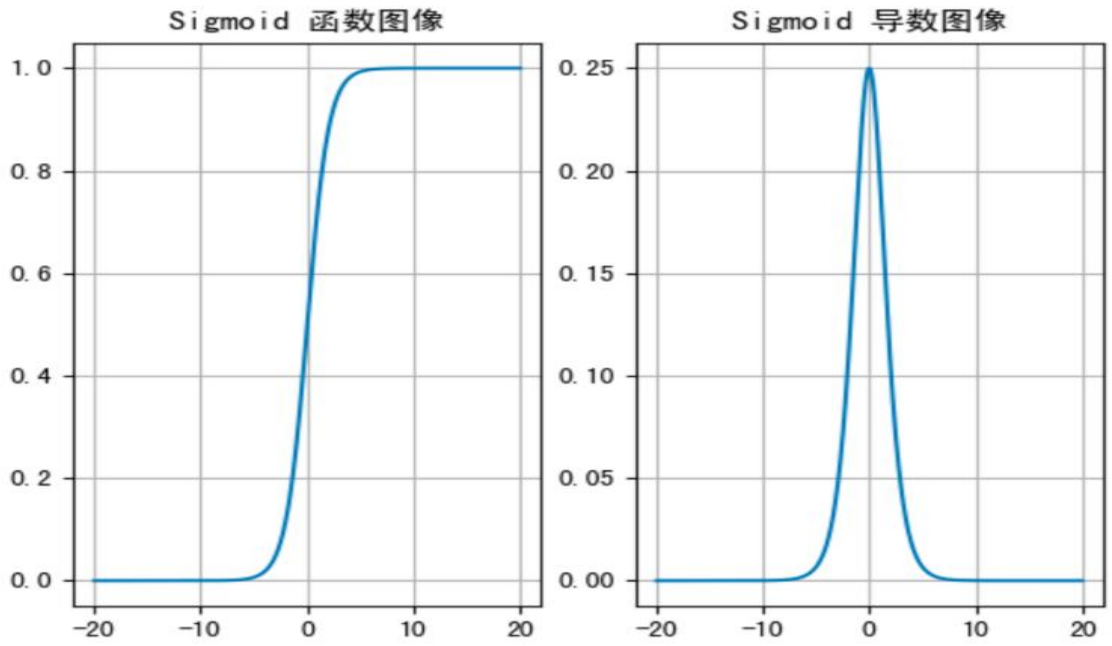

常见的激活函数-sigmoid 激活函数

绘制激活函数图像时出现以下提示，需要将anaconda3/Lib/site-packages/torch/lib目录下的libiomp5md.dll文件删除

OMP: Error #15: Initializing libiomp5md.dll, but found libiomp5md.dll already initialized.

```
import torch
import matplotlib.pyplot as plt

# 创建画布和坐标轴
_, axes = plt.subplots(1, 2)
# 函数图像
x = torch.linspace(-20, 20, 1000)
# 输入值x通过sigmoid函数转换成激活值y
y = torch.sigmoid(x)
axes[0].plot(x, y)
axes[0].grid()
axes[0].set_title('Sigmoid 函数图像')
```

```
# 导数图像
x = torch.linspace(-20, 20, 1000, requires_grad=True)
torch.sigmoid(x).sum().backward()
# x.detach():输入值x的数值
# x.grad:计算梯度，求导
axes[1].plot(x.detach(), x.grad)
axes[1].grid()
axes[1].set_title('Sigmoid 导数图像')
plt.show()
```

常见的激活函数 -tanh 激活函数

Tanh 的公式如下：

$$f(x) = \frac{1 - e^{-2x}}{1 + e^{-2x}}$$

激活函数求导公式：$f'(x) = (\frac{1-e^{-2x}}{1+e^{-2x}})' = 1 - f^2(x)$

Tanh 的函数图像、导数图像如下：

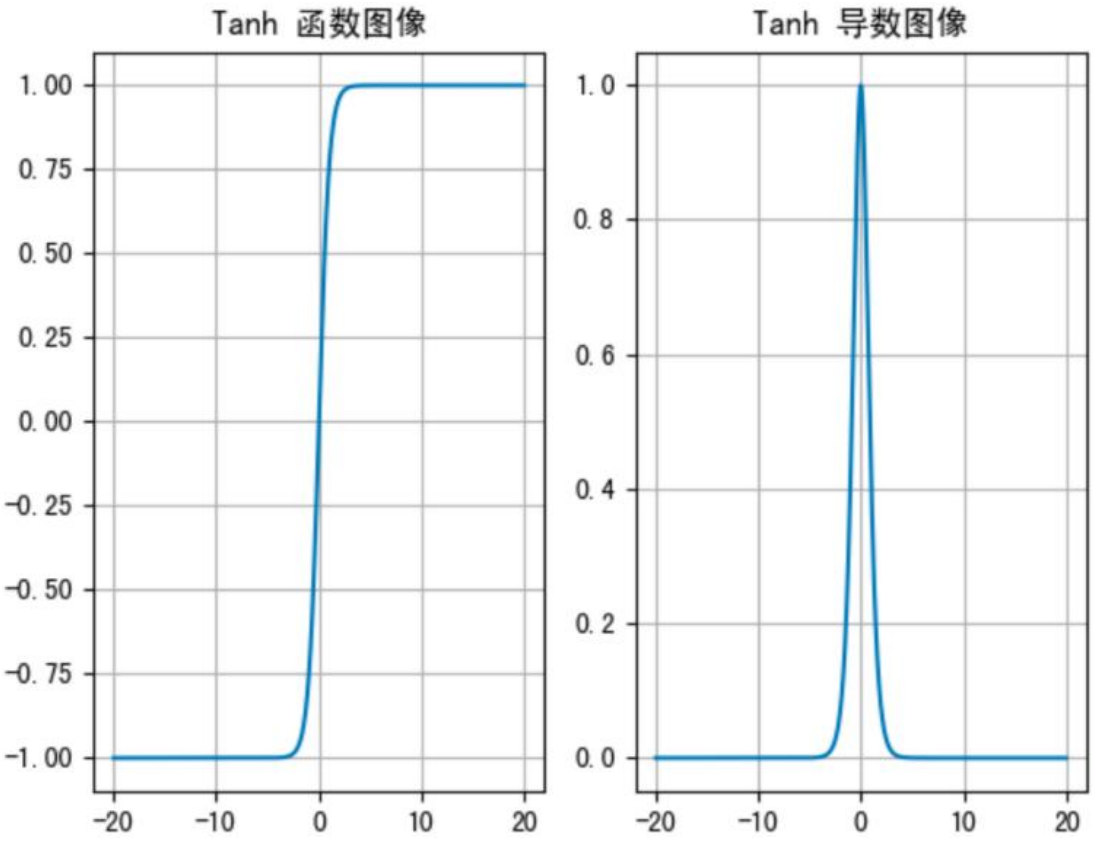

常见的激活函数 -tanh 激活函数

```
# 创建画布和坐标轴
_, axes = plt.subplots(1, 2)
# 函数图像
x = torch.linspace(-20, 20, 1000)
y = torch.tanh(x)
axes[0].plot(x, y)
axes[0].grid()
axes[0].set_title('Tanh 函数图像')
# 导数图像
x = torch.linspace(-20, 20, 1000, requires_grad=True)
torch.tanh(x).sum().backward()
axes[1].plot(x.detach(), x.grad)
axes[1].grid()
axes[1].set_title('Tanh 导数图像')
plt.show()
```

常见的激活函数-ReLU 激活函数

ReLU 公式如下： $f(x) = \max(0, x)$

激活函数求导公式:

$$f'(x) = 0\text{或}1$$

ReLU 的函数图像如下：

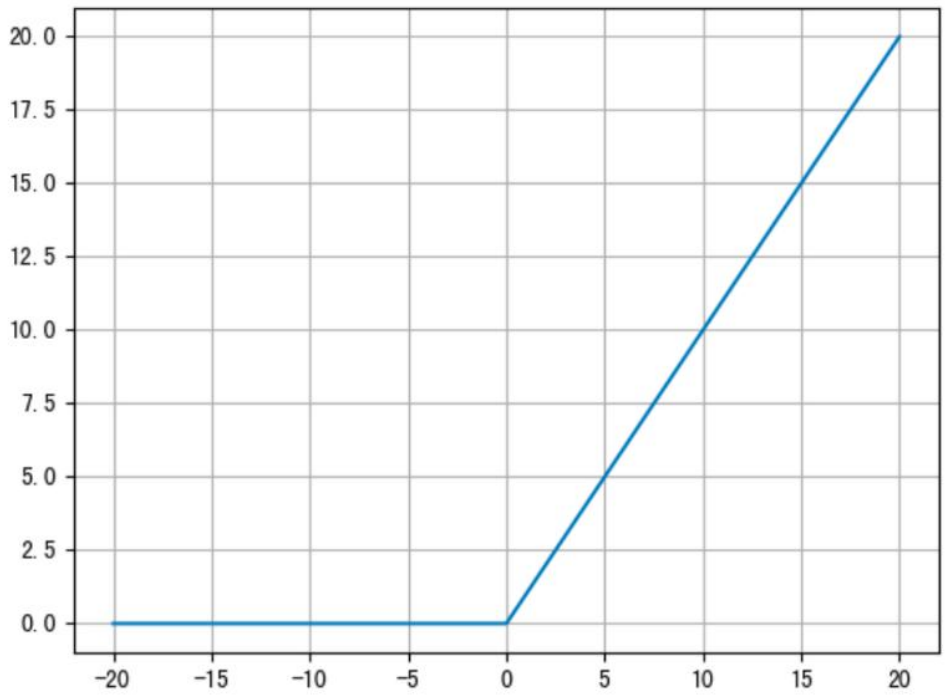

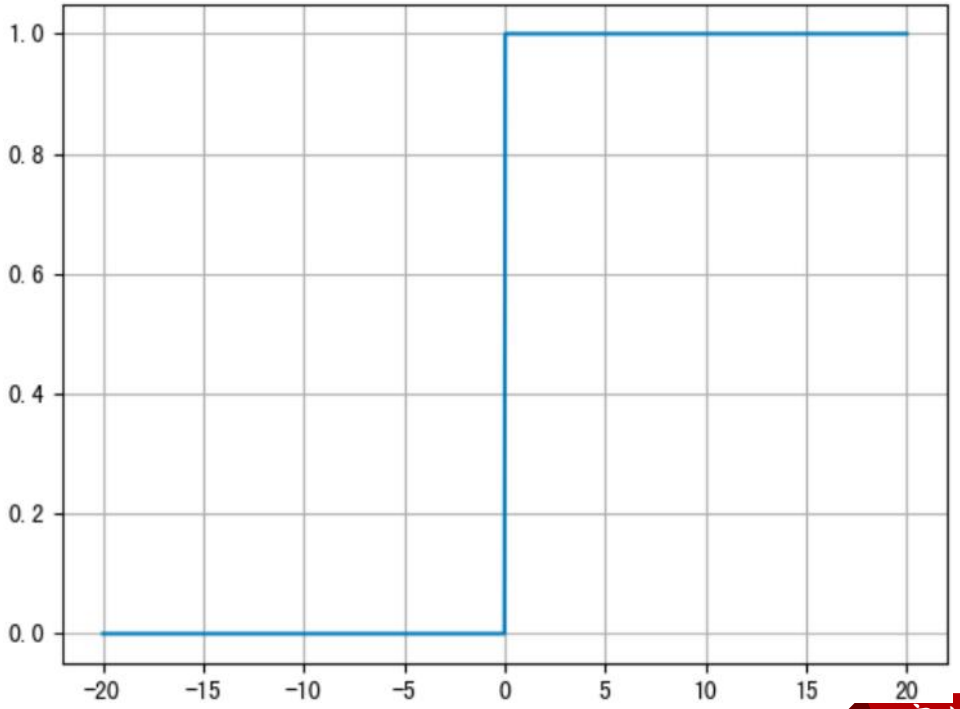

常见的激活函数-ReLU 激活函数

```
# 创建画布和坐标轴
_, axes = plt.subplots(1, 2)
# 函数图像
x = torch.linspace(-20, 20, 1000)
y = torch.relu(x)
axes[0].plot(x, y)
axes[0].grid()
axes[0].set_title('ReLU 函数图像')
# 导数图像
x = torch.linspace(-20, 20, 1000, requires_grad=True)
torch.relu(x).sum().backward()
axes[1].plot(x.detach(), x.grad)
axes[1].grid()
axes[1].set_title('ReLU 导数图像')
plt.show()
```

常见的激活函数-SoftMax 激活函数

softmax用于**多分类**过程中，它是二分类函数sigmoid在多分类上的推广，目的是**将多分类的结果以概率的形式展现出来**。计算方法如下图所示：

$$softmax(z_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

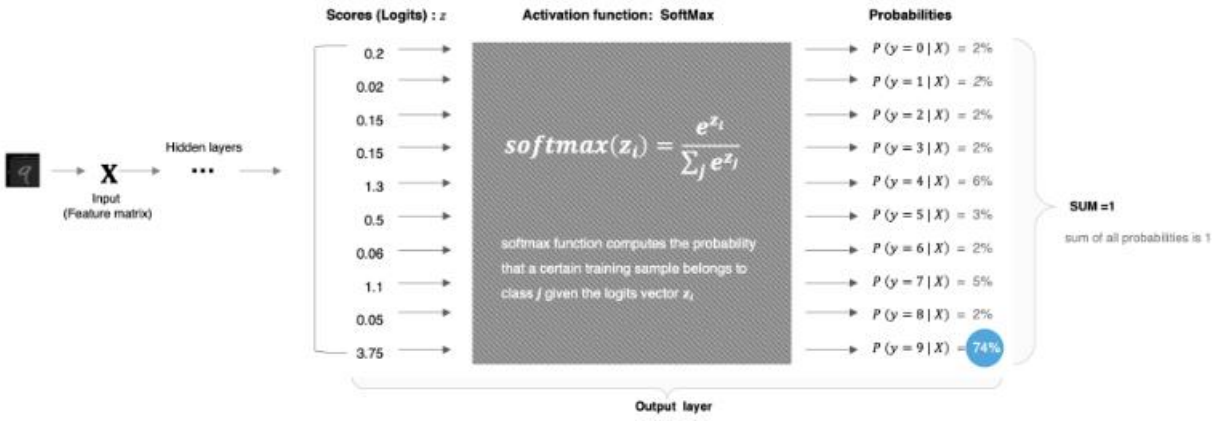

常见的激活函数-SoftMax 激活函数

Softmax 就是将网络输出的 logits 通过 softmax 函数，就映射成为(0,1)的值，而**这些值的累和为1**（满足概率的性质），那么我们将它理解成概率，**选取概率最大（也就是值对应最大的）节点**，作为我们的**预测目标类别**。

```
import torch


scores = torch.tensor([0.2, 0.02, 0.15, 0.15, 1.3, 0.5, 0.06, 1.1, 0.05, 3.75])
# dim = 0,按行计算
probabilities = torch.softmax(scores, dim=0)
print(probabilities)
```

输出结果:

```
tensor([0.0212, 0.0177, 0.0202, 0.0202, 0.0638, 0.0287, 0.0185, 0.0522,
0.0183,0.7392])
```

其他常见的激活函数

Name	Plot	Equation	Derivative (with respect to x)	Range
Identity function		$f(x) = x$	$f'(x) = 1$	$(-\infty, \infty)$
Binary step		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{for } x \neq 0 \\ ? & \text{for } x = 0 \end{cases}$	$\{0, 1\}$
Logistic		$f(x) = \frac{1}{1+e^{-x}}$	$f'(x) = f(x)(1 - f(x))$	$(0, 1)$
TanH		$f(x) = \tanh(x) = \frac{2}{1+e^{-2x}} - 1$	$f'(x) = 1 - f(x)^2$	$(-1, 1)$
Rectified linear unit (ReLu)		$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$[0, \infty)$
Leaky ReLU		$f(x) = \begin{cases} 0.01x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(x) = \begin{cases} 0.01 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$
Parameteric rectified linear unit (PReLU)		$f(\alpha, x) = \begin{cases} \alpha x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$
Randomized leaky rectified linear unit (RReLU)		$f(\alpha, x) = \begin{cases} \alpha x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$ [1]	$f'(\alpha, x) = \begin{cases} \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\infty, \infty)$
Exponential linear unit (ELU)		$f(\alpha, x) = \begin{cases} \alpha(e^x - 1) & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$	$f'(\alpha, x) = \begin{cases} f(\alpha, x) + \alpha & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$	$(-\alpha, \infty)$

激活函数的选择方法

对于**隐藏层**:

1. 优先选择ReLU激活函数
2. 如果ReLu效果不好，那么尝试其他激活，如Leaky ReLu等。
3. 如果你使用了ReLU， 需要注意一下Dead ReLU问题， 避免出现0梯度从而导致过多的神经元死亡。
4. 少用使用sigmoid激活函数，可以尝试使用tanh激活函数

对于**输出层**:

1. 二分类问题选择sigmoid激活函数
2. 多分类问题选择softmax激活函数
3. 回归问题选择identity激活函数

总结

1. 激活函数的作用？

向神经网络中添加非线性元素

2. 常见的激活函数及其特点？

Sigmoid, tanh, relu, softmax等

3. 激活函数的选择方法？

隐藏层：relu

输出层：二分类：sigmoid, 多分类：softmax, 回归：恒等

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

参数初始化_7种方式

- 均匀分布初始化
  - 权重参数初始化从区间均匀随机取值，默认区间为（0，1）。可以设置为在(-1/√d,1/√d)均匀分布中生成当前神经元的权重，其中d为神经元的输入数量
- 正态分布初始化
  - 随机初始化从均值为0，标准差是1的高斯分布中取样，使用一些很小的值对参数W进行初始化
- 全0初始化
  - 将神经网络中的所有权重参数初始化为 0
- 全1初始化
  - 将神经网络中的所有权重参数初始化为 1
- 固定值初始化
  - 将神经网络中的所有权重参数初始化为某个固定值

参数初始化

- kaiming 初始化，也叫做 **HE 初始化**
  - HE 初始化分为正态分布的 HE 初始化、均匀分布的 HE 初始化.
    - 正态分布的he初始化
      - 它是从 [0, std] 中抽取样本的，std = sqrt(2 / fan_in)
    - 均匀分布的he初始化
      - 它从 [-limit，limit] 中的均匀分布中抽取样本，limit是 sqrt(6 / fan_in)
    - fan_in 输入层神经元的个数
- xavier 初始化，也叫做 **Glorot初始化**
  - 该方法也有两种，一种是正态分布的 xavier 初始化、一种是均匀分布的 xavier 初始化.
    - 正态化的Xavier初始化
      - 它是从 [0, std] 中抽取样本的，std = sqrt(2 / (fan_in + fan_out))
    - 均匀分布的Xavier初始化
      - [-limit，limit] 中的均匀分布中抽取样本，limit 是 sqrt(6 / (fan_in + fan_out))
    - fan_in 是输入层神经元的个数， fan_out 是输出层神经元个数

参数初始化

```
import torch
import torch.nn.functional as F
import torch.nn as nn
# 1. 均匀分布随机初始化
def test01():
    linear = nn.Linear(5, 3)
    # 从0-1均匀分布产生参数
    nn.init.uniform_(linear.weight)
    print(linear.weight.data)
# 2.固定初始化
def test02():
    linear = nn.Linear(5, 3)
    nn.init.constant_(linear.weight, 5)
    print(linear.weight.data)
```

参数初始化

```
# 3. 全0初始化
def test03():
    linear = nn.Linear(5, 3)
    nn.init.zeros_(linear.weight)
    print(linear.weight.data)
# 4. 全1初始化
def test04():
    linear = nn.Linear(5, 3)
    nn.init.ones_(linear.weight)
    print(linear.weight.data)
# 5. 正态分布随机初始化
def test05():
    linear = nn.Linear(5, 3)
    nn.init.normal_(linear.weight, mean=0, std=1)
    print(linear.weight.data)
```

参数初始化

```
# 6. kaiming 初始化
def test06():
    # kaiming 正态分布初始化
    linear = nn.Linear(5, 3)
    nn.init.kaiming_normal_(linear.weight)
    print(linear.weight.data)

    # kaiming 均匀分布初始化
    linear = nn.Linear(5, 3)
    nn.init.kaiming_uniform_(linear.weight)
    print(linear.weight.data)
```

参数初始化

```
# 7. xavier 初始化
def test07():
    # xavier 正态分布初始化
    linear = nn.Linear(5, 3)
    nn.init.xavier_normal_(linear.weight)
    print(linear.weight.data)

    # xavier 均匀分布初始化
    linear = nn.Linear(5, 3)
    nn.init.xavier_uniform_(linear.weight)
    print(linear.weight.data)
```

参数初始化选择

激活函数的选择：根据激活函数的类型选择对应的初始化方法
Sigmoid/Tanh：Xavier 初始化
ReLU/Leaky ReLU：kaiming 初始化

网络的深度
浅层网络：随机初始化即可
深层网络：需要考虑方差平衡，如 Xavier 或 kaiming 初始化

总结

1. 常见的初始化方式

均匀分布初始化，正态分布初始化，全0全1初始化，固定值初始化，kaiming的初始化，xavier初始化

2. 初始化方法的选择

一般我们在使用 PyTorch 构建网络模型时，每个网络层的参数都有默认的初始化方法，优先选择kaiming的初始化，xavier初始化方式。

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

学习目标

Learning Objectives

1. 知道分类任务的损失函数
2. 知道回归任务的损失函数

什么是损失函数

在深度学习中，**损失函数是用来衡量模型参数的质量的函数**，衡量的方式是比较网络输出和真实输出的差异：

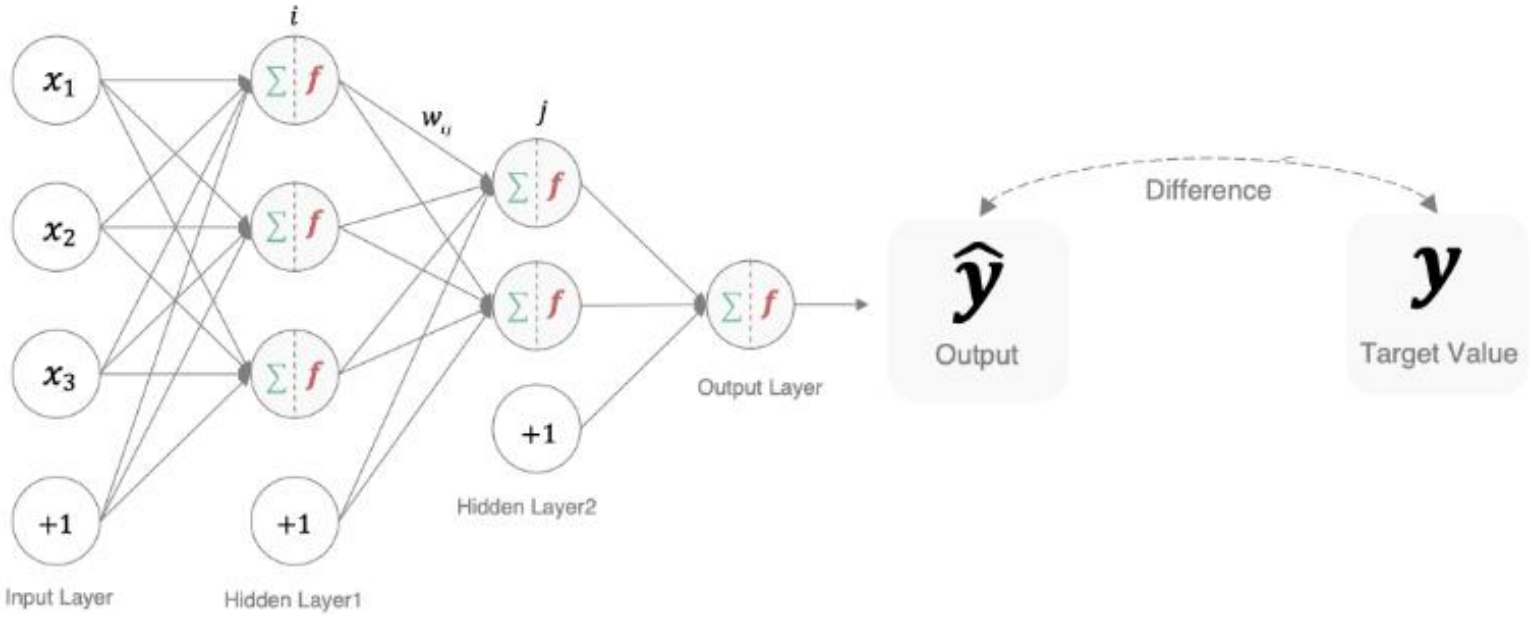

什么是损失函数

损失函数在不同的文献中名称是不一样的，主要有以下几种命名方式：

多分类任务损失函数

在多分类任务通常使用softmax将logits转换为概率的形式，所以多分类的交叉熵损失也叫做**softmax损失**，它的计算方法是：

labels (one-hot)

$$\mathcal{L} = -\sum_{i=1}^{n} \mathbf{y}_i \log(S(f_\theta(\mathbf{x}_i)))$$

Softmax

其中：

1. y是样本x属于某一个类别的真实概率
2. 而f(x)是样本属于某一类别的预测分数
3. S是softmax激活函数，将属于某一类别的预测分数转换成概率
4. L用来衡量真实值y和预测值f(x)之间差异性的损失结果

多分类任务损失函数

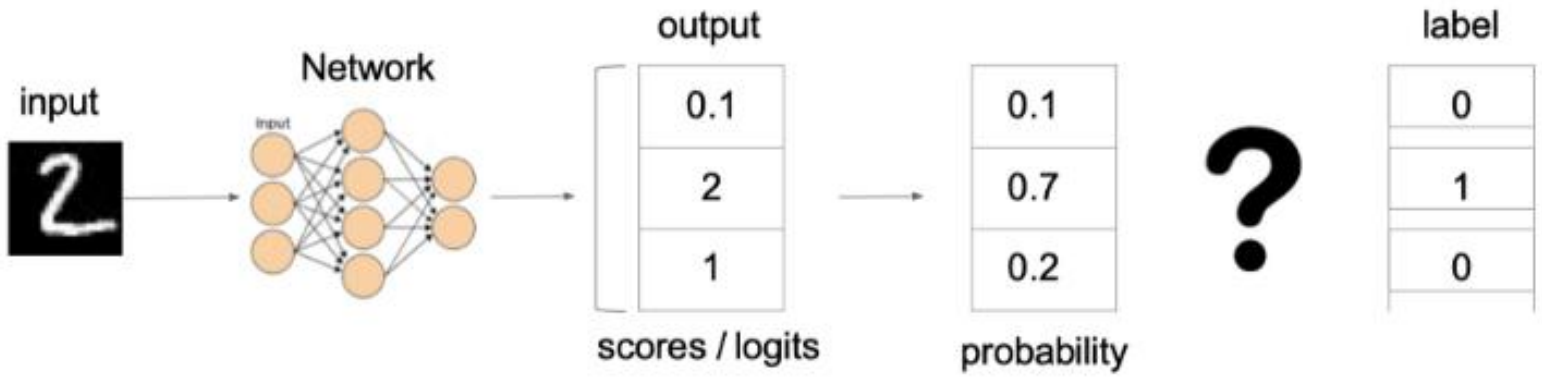

上图中的交叉熵损失为：$-(0log(0.10)+1log(0.7)+0log(0.2)) = -log0.7$

从概率角度理解，我们的目的是最小化正确类别所对应的预测概率的对数的负值(损失值最小)，如下图所示：

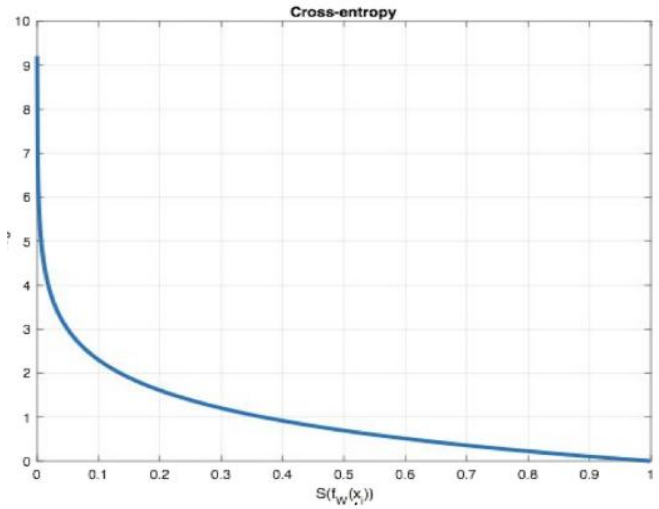

多分类任务损失函数

在pytorch中使用nn.CrossEntropyLoss()实现，如下所示：

```
# 分类损失函数：交叉熵损失使用nn.CrossEntropyLoss()实现。nn.CrossEntropyLoss()=softmax + 损失计算
def test01():
    # 设置真实值：可以是热编码后的结果也可以不进行热编码
    # y_true = torch.tensor([[0, 1, 0], [0, 0, 1]], dtype=torch.float32)
    # 注意的类型必须是64位整型数据
    y_true = torch.tensor([1, 2], dtype=torch.int64)
    y_pred = torch.tensor([[0.2, 0.6, 0.2], [0.1, 0.8, 0.1]], requires_grad=True,
dtype=torch.float32)
    # 实例化交叉熵损失
    loss = nn.CrossEntropyLoss()
    # 计算损失结果
    my_loss = loss(y_pred, y_true).detach().numpy()
    print('loss:', my_loss)
```

二分类任务损失函数

在处理二分类任务时，我们不再使用softmax激活函数，而是使用sigmoid激活函数，那损失函数也相应的进行调整，使用二分类的交叉熵损失函数：

$$L = -y \log \hat{y} - (1-y)\log(1-\hat{y})$$

其中：

1. y是样本x属于某一个类别的真实概率
2. 而y^是样本属于某一类别的预测概率
3. L用来衡量真实值y与预测值y^之间差异性的损失结果。

在pytorch中实现时使用nn.BCELoss()，如下所示：

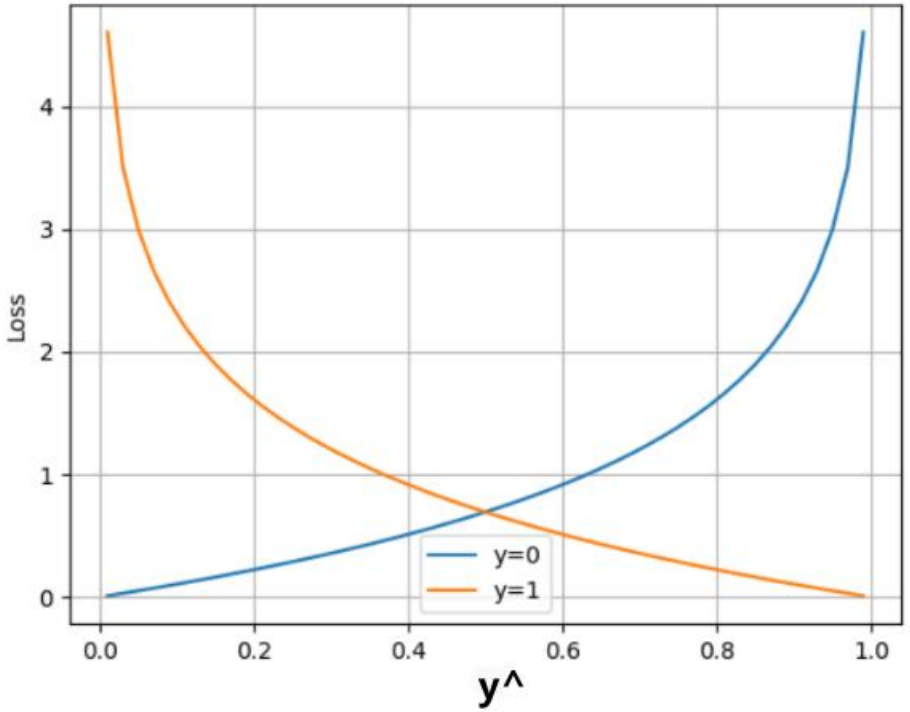

二分类任务损失函数

```
def test02():
    # 1 设置真实值和预测值
    # 预测值是sigmoid输出的结果
    y_pred = torch.tensor([0.6901, 0.5459, 0.2469],
requires_grad=True)
    y_true = torch.tensor([0, 1, 0], dtype=torch.float32)
    # 2 实例化二分类交叉熵损失
    loss = nn.BCELoss()
    # 3 计算损失
    my_loss = loss(y_pred, y_true).detach().numpy()
    print('loss: ', my_loss)
```

回归任务损失函数-MAE损失函数

Mean absolute loss(MAE)也被称为L1 Loss，是以绝对误差作为距离。损失函数公式:

$$\mathcal{L} = \frac{1}{n}\sum_{i=1}^{n}|y_i - f_\theta(x_i)|$$

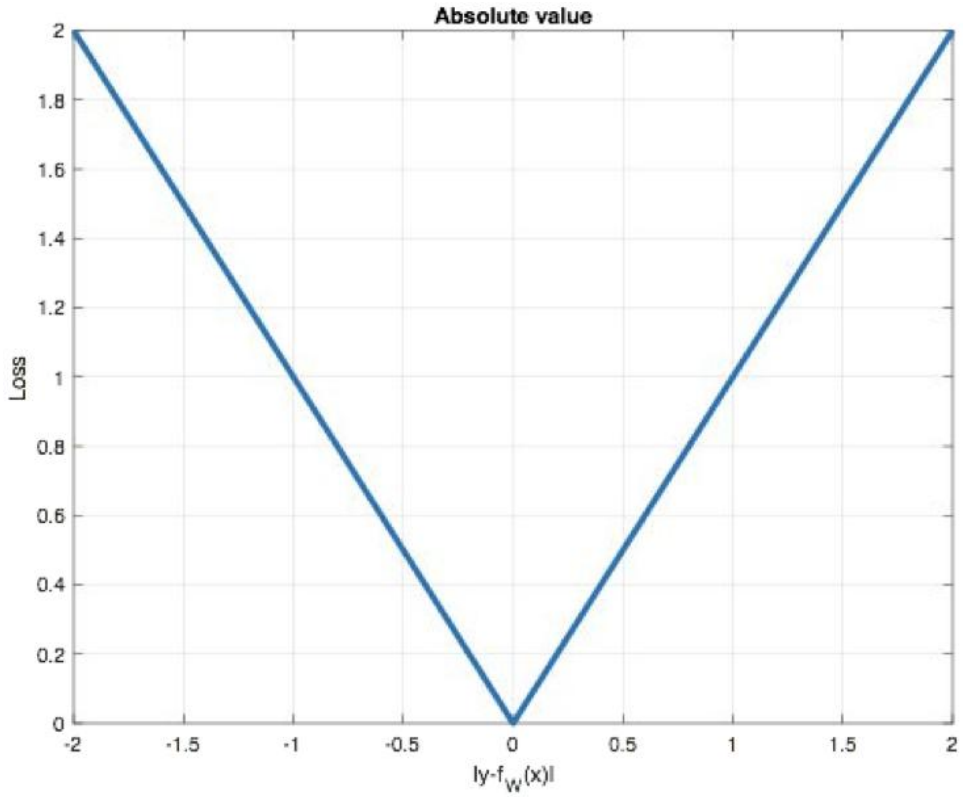

特点是:

1. 由于L1 loss具有稀疏性，为了惩罚较大的值，因此常常将其作为正则项添加到其他loss中作为约束。
2. L1 loss的最大问题是梯度在零点不平滑，导致会跳过极小值。

回归任务损失函数- MAE损失函数

在pytorch中使用nn.L1Loss()实现，如下所示：

```
# 计算inputs与target之差的绝对值
def test03():
    # 1 设置真实值和预测值
    y_pred = torch.tensor([1.0, 1.0, 1.9],
requires_grad=True)
    y_true = torch.tensor([2.0, 2.0, 2.0],
dtype=torch.float32)
    # 2 实例MAE损失对象
    loss = nn.L1Loss()
    # 3 计算损失
    my_loss = loss(y_pred, y_true).detach().numpy()
    print('loss:', my_loss)
```

回归任务损失函数-MSE损失函数

Mean Squared Loss/ Quadratic Loss(MSE loss)也被称为L2 loss，或欧氏距离，它以误差的平方和的均值作为距离

损失函数公式:

$$\mathcal{L} = \frac{1}{n}\sum_{i=1}^{n}(y_i - f_\theta(x_i))^2$$

曲线如下图所示：

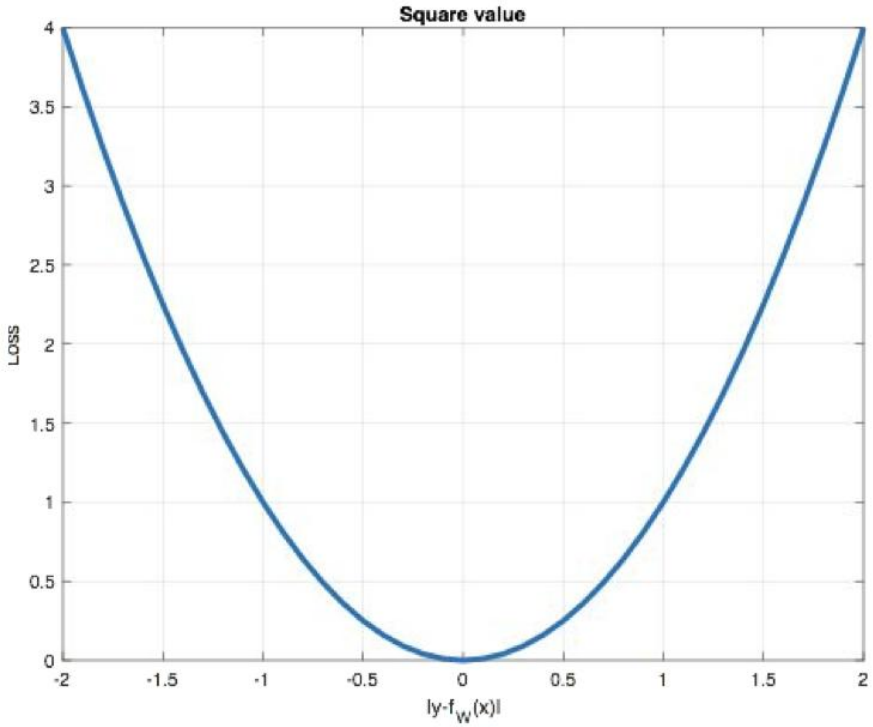

特点是：

1. L2 loss也常常作为正则项。
2. 当预测值与目标值相差很大时，梯度容易爆炸。

回归任务损失函数-MSE损失函数

在pytorch中使用nn.MSELoss()实现，如下所示：

```
def test04():
    # 1 设置真实值和预测值
    y_pred = torch.tensor([1.0, 1.0, 1.9], requires_grad=True)
    y_true = torch.tensor([2.0, 2.0, 2.0], dtype=torch.float32)
    # 2 实例MSE损失对象
    loss = nn.MSELoss()
    # 3 计算损失
    my_loss = loss(y_pred, y_true).detach().numpy()
    print('myloss:', my_loss)
```

回归任务损失函数-Smooth L1损失函数

Smooth L1说的是光滑之后的L1。损失函数公式:

$$\text{smooth}_{L_1}(x) = \begin{cases} 0.5x^2 & \text{if } |x| < 1 \\ |x| - 0.5 & \text{otherwise} \end{cases}$$

其中：x =f(x)−y 为真实值和预测值的差值。

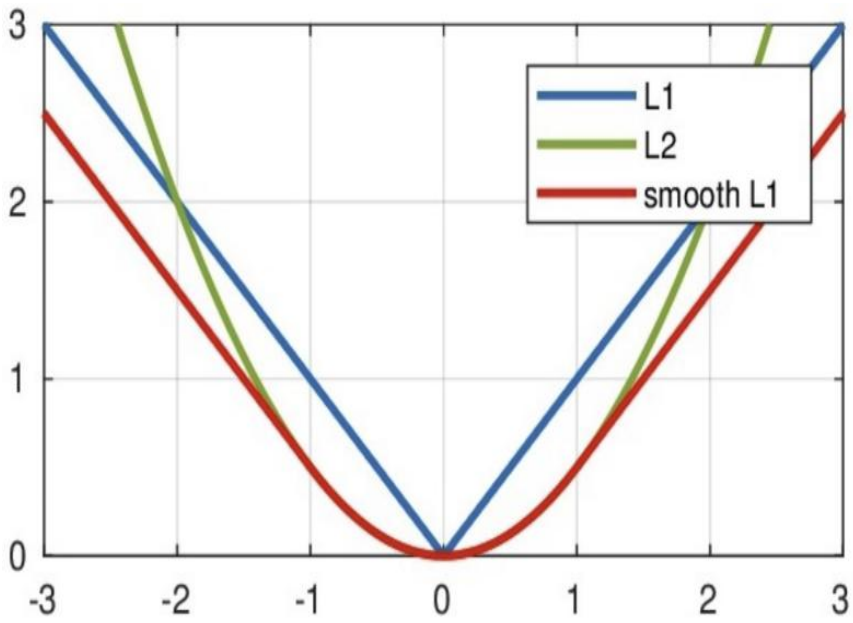

从右图中可以看出，该函数实际上就是一个分段函数

1. 在[-1,1]之间实际上就是L2损失，这样解决了L1的不光滑问题
2. 在[-1,1]区间外，实际上就是L1损失，这样就解决了离群点梯度爆炸的问题

回归任务损失函数-Smooth L1损失函数

在pytorch中使用nn.SmoothL1Loss()实现，如下所示：

```
def test05():
    # 1 设置真实值和预测值
    y_true = torch.tensor([0, 3])
    y_pred = torch.tensor ([0.6, 0.4], requires_grad=True)
    # 2 实例smmothL1损失对象
    loss = nn.SmoothL1Loss()
    # 3 计算损失
    my_loss = loss(y_pred, y_true).detach().numpy()
    print('loss:', my_loss)
```

总结

1. 分类任务的损失函数

- 多分类的交叉熵损失函数
- 二分类的交叉熵损失函数

2. 回归任务的损失函数

- MAE，MSE，smooth L1损失函数

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

梯度下降的优化方法

梯度下降优化算法中，可能会碰到以下情况：

1. 碰到平缓区域，梯度值较小，参数优化变慢
2. 碰到 “鞍点” ，梯度为 0，参数无法优化
3. 碰到局部最小值，参数不是最优

对于这些问题，出现了一些对梯度下降算法的优化方法，例如：Momentum、AdaGrad、RMSprop、Adam 等

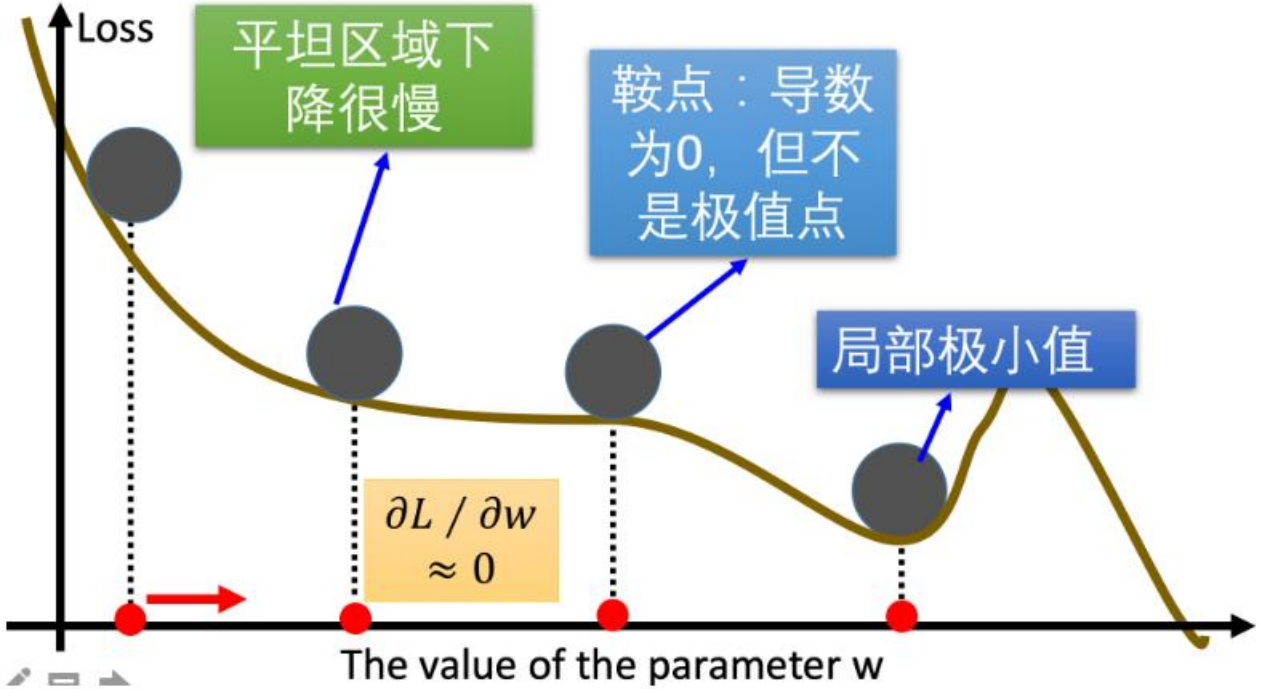

梯度下降的优化方法汇总

梯度下降的优化方法-指数加权平均

指数移动加权平均则是参考各数值，并且各数值的权重都不同，距离越远的数字对平均数计算的贡献就越小（权重较小），距离越近则对平均数的计算贡献就越大（权重越大）。

比如：明天气温怎么样，和昨天气温有很大关系，而和一个月前的气温关系就小一些。

计算公式可以用下面的式子来表示：

$$S_t = \begin{cases} Y_1, & t = 0 \\ \beta * S_{t-1} + (1-\beta) * Y_t, & t > 0 \end{cases}$$

- St 表示指数加权平均值;
- Yt 表示 t 时刻的值;
- β 调节权重系数，该值越大平均数越平缓。

下面通过代码来看结果，随机产生 30 天的气温数据：

梯度下降的优化方法-指数加权平均

```
import torch
import matplotlib.pyplot as plt

ELEMENT_NUMBER = 30
# 1. 实际平均温度
def test01():
    # 固定随机数种子
    torch.manual_seed(0)
    # 产生30天的随机温度
    temperature = torch.randn(size=[ELEMENT_NUMBER,]) * 10
    print(temperature)
    # 绘制平均温度
    days = torch.arange(1, ELEMENT_NUMBER + 1, 1)
    plt.plot(days, temperature, color='r')
    plt.scatter(days, temperature)
    plt.show()
```

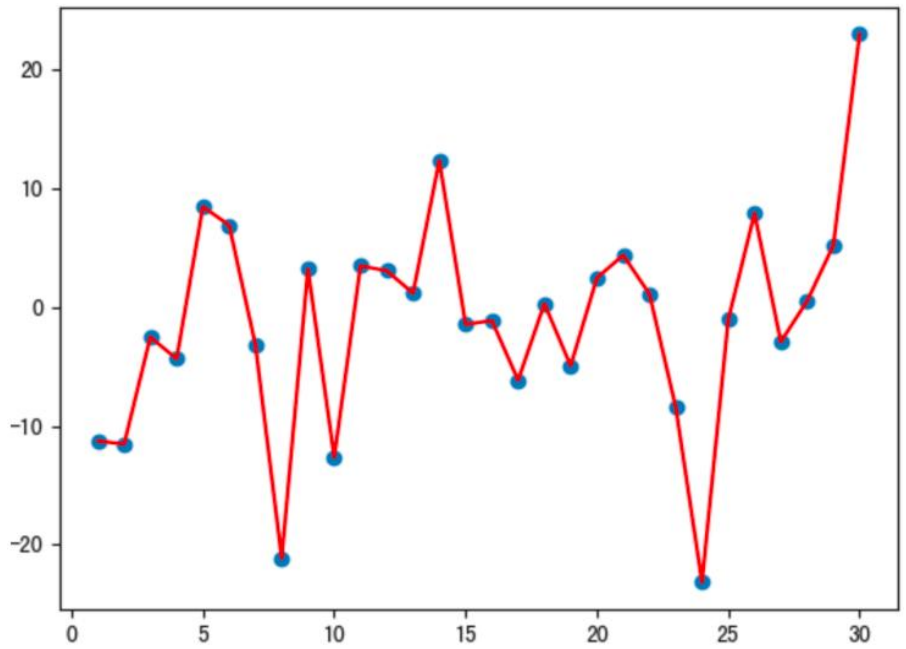

30天的气温变化（折线）

梯度下降的优化方法-指数加权平均

```
# 2. 指数加权平均温度
def test02(beta=0.9):
    torch.manual_seed(0) # 固定随机数种子
    temperature = torch.randn(size=[ELEMENT_NUMBER,]) * 10 # 产生30天的随机温度
    exp_weight_avg = []
    for idx, temp in enumerate(temperature, 1):  # 从下标1开始
        # 第一个元素的的 EWA 值等于自身
        if idx == 1:
            exp_weight_avg.append(temp)
            continue
        # 第二个元素的 EWA 值等于上一个 EWA 乘以 β+当前气温乘以 (1-β)
        new_temp = exp_weight_avg[idx - 2] * beta + (1 - beta) * temp
        exp_weight_avg.append(new_temp)
    days = torch.arange(1, ELEMENT_NUMBER + 1, 1)
    plt.plot(days, exp_weight_avg, color='r')
    plt.scatter(days, temperature)
    plt.show()
```

梯度下降的优化方法-指数加权平均

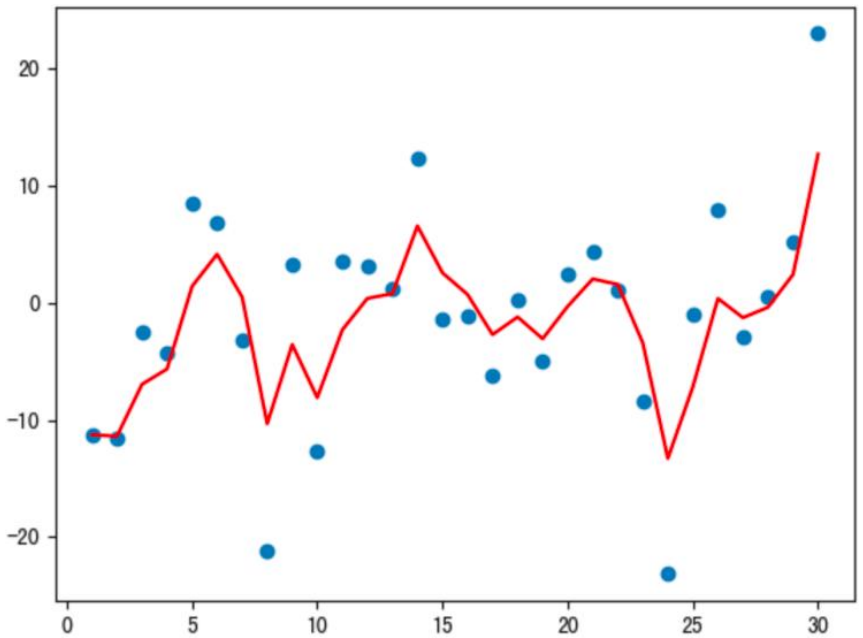

β=0.5 的气温变化（折线）

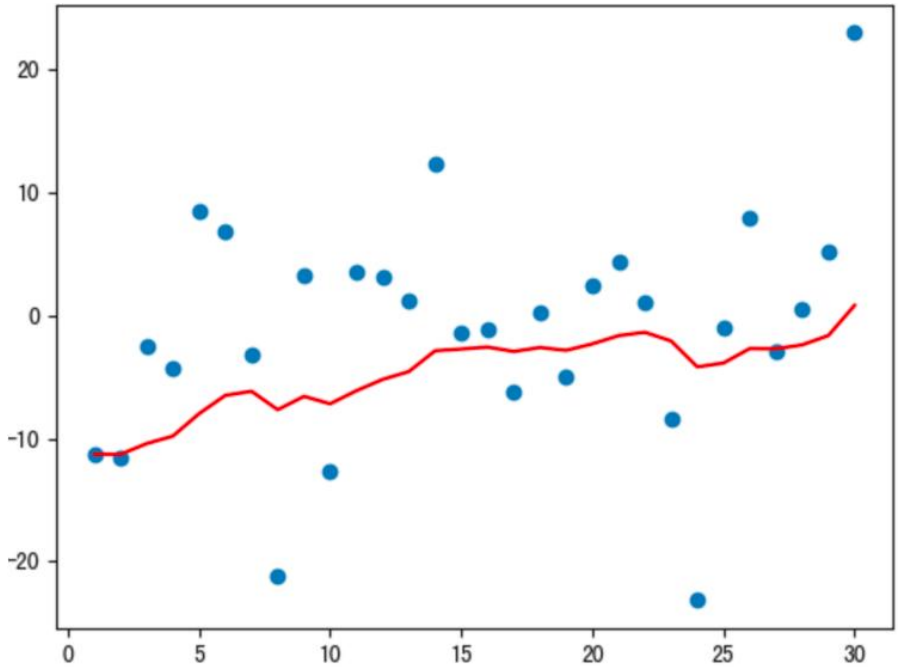

β=0.9 的气温变化（折线）

上图是β为0.5和0.9时的结果，从中可以看出：

- 指数加权平均绘制出的气温变化曲线更加平缓，
- β 的值越大，则绘制出的折线越加平缓，波动越小。(1-β越小,t时刻的St越不依赖Yt的值)
- β 值一般默认都是 0.9

梯度下降的优化方法-动量算法Momentum

梯度计算公式：

$$s_t=\beta s_{t-1} + (1-\beta)g_t$$

参数更新公式：

$$w_t=w_{t-1} - \eta s_t$$

s_t是当前时刻指数加权平均梯度值

s_{t-1}是历史指数加权平均梯度值

g_t是当前时刻的梯度值

β 是调节权重系数，通常取 0.9 或 0.99

η是学习率

w_t是当前时刻模型权重参数

梯度下降的优化方法-动量算法Momentum

咱们举个例子，假设：权重 β 为 0.9，例如：

第一次梯度值：s1 = g1 = w1

第二次梯度值：s2 = 0.9*s1 + g2*0.1

第三次梯度值：s3 = 0.9*s2 + g3*0.1

第四次梯度值：s4 = 0.9*s3 + g4*0.1

1. w 表示初始梯度
2. g 表示当前轮数计算出的梯度值
3. s 表示历史梯度移动加权平均值

梯度下降公式中梯度的计算，就不再是当前时刻t的梯度值，而是历史梯度值的指数移动加权平均值。

公式修改为：

Wt = Wt-1 - η*St

Wt：当前时刻模型权重参数

St：当前时刻指数加权平均梯度值

η：学习率

梯度下降的优化方法-动量算法Momentum

Monmentum 优化方法是如何一定程度上克服 “平缓”、”鞍点” 的问题呢？

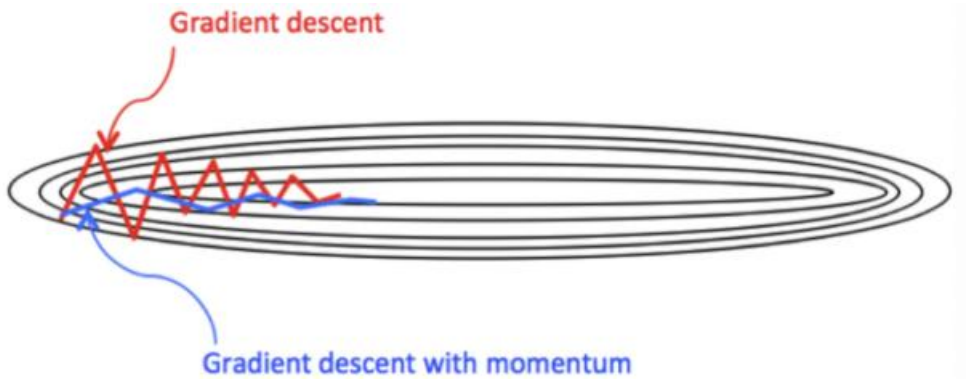

- 当处于鞍点位置时，由于当前的梯度为 0，参数无法更新。但是 Momentum 动量梯度下降算法已经在先前积累了一些梯度值，很有可能使得跨过鞍点。
- 由于 mini-batch 普通的梯度下降算法，每次选取少数的样本梯度确定前进方向，可能会出现震荡，使得训练时间变长。Momentum 使用移动加权平均，平滑了梯度的变化，使得前进方向更加平缓，有利于加快训练过程。

梯度下降的优化方法-动量算法Momentum

```
def test01():
    # 1 初始化权重参数
    w = torch.tensor([1.0], requires_grad=True, dtype=torch.float32)
    loss = ((w ** 2) / 2.0).sum()

    # 2 实例化优化方法：SGD 指定参数beta=0.9
    optimizer = torch.optim.SGD([w], lr=0.01, momentum=0.9)

    # 3 第1次更新 计算梯度，并对参数进行更新
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

    print('第1次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
    # 4 第2次更新 计算梯度，并对参数进行更新
    # 使用更新后的参数机选输出结果
    loss = ((w ** 2) / 2.0).sum()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
    print('第2次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
```

输出结果:
第1次: 梯度w.grad: 1.0000000000, 更新后的权重:0.9900000095
第2次: 梯度w.grad: 0.9900000095, 更新后的权重:0.9711000323

梯度下降的优化方法-adaGrad

AdaGrad 通过对不同的参数分量使用不同的学习率，**AdaGrad 的学习率总体会逐渐减小**。

其计算步骤如下：

1. 初始化学习率 η、初始化参数w、小常数 σ = 1e-10
2. 初始化梯度累计变量 s = 0
3. 从训练集中采样 m 个样本的小批量，计算梯度g_t
4. 累积平方梯度：s_t = s_t-1 + g_t ⊙ g_t，⊙ 表示各个分量相乘
5. 学习率 η 的计算公式如下：

$$\eta = \frac{\eta}{\sqrt{s_t}+\sigma}$$

6. 权重参数更新公式如下：

$$w_t = w_{t-1} - \frac{\eta}{\sqrt{s_t}+\sigma} * g_t$$

7. 重复 3-7 步骤

AdaGrad 缺点是可能会使得学习率过早、过量的降低，导致模型训练后期学习率太小，较难找到最优解。

梯度下降的优化方法-AdaGrad

```
def test02():
    # 1 初始化权重参数
    w = torch.tensor([1.0], requires_grad=True, dtype=torch.float32)
    loss = ((w ** 2) / 2.0).sum()

    # 2 实例化优化方法：adagrad优化方法
    optimizer = torch.optim.Adagrad ([w], lr=0.01)

    # 3 第1次更新 计算梯度，并对参数进行更新
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

    print('第1次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
    # 4 第2次更新 计算梯度，并对参数进行更新
    # 使用更新后的参数机选输出结果
    loss = ((w ** 2) / 2.0).sum()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
    print('第2次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
```

输出结果:
第1次: 梯度w.grad: 1.000000, 更新后的权重:0.990000 第2次: 梯度w.grad: 0.990000, 更新后的权重:0.982965

梯度下降的优化方法RMSProp

RMSProp 优化算法是对 AdaGrad 的优化. 最主要的不同是，其使用**指数加权平均梯度**替换历史梯度的平方和。其计算过程如下：

1. 初始化学习率 η、初始化权重参数w、小常数 σ = 1e-10
2. 初始化梯度累计变量 s = 0
3. 从训练集中采样 m 个样本的小批量，计算梯度 g_t
4. 使用指数加权平均累计历史梯度，⊙ 表示各个分量相乘，公式如下：

$$s_t = \beta s_{t-1} + (1-\beta) g_t \odot g_t$$

5. 学习率 η 的计算公式如下：

$$\eta = \frac{\eta}{\sqrt{s_t}+\sigma}$$

6. 权重参数更新公式如下：

$$w_t = w_{t-1} - \frac{\eta}{\sqrt{s_t}+\sigma} * g_t$$

7. 重复 3-7 步骤

梯度下降的优化方法

```
def test03():
    # 1 初始化权重参数
    w = torch.tensor([1.0], requires_grad=True, dtype=torch.float32)
    loss = ((w ** 2) / 2.0).sum()

    # 2 实例化优化方法：RMSprop算法，其中alpha对应这beta
    optimizer = torch.optim.RMSprop([w], lr=0.01,alpha=0.9)

    # 3 第1次更新 计算梯度，并对参数进行更新
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

    print('第1次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
    # 4 第2次更新 计算梯度，并对参数进行更新
    # 使用更新后的参数机选输出结果
    loss = ((w ** 2) / 2.0).sum()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
    print('第2次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
```

输出结果:
第1次: 梯度w.grad: 1.000000, 更新后的权重:0.968377 第2次: 梯度w.grad: 0.968377, 更新后的权重:0.945788

梯度下降的优化方法-Adam

- Momentum 使用指数加权平均计算当前的梯度值
- AdaGrad、RMSProp 使用自适应的学习率
- Adam优化算法（Adaptive Moment Estimation，自适应矩估计）将 Momentum 和 RMSProp 算法结合在一起
  - **修正梯度：使用梯度的指数加权平均**
  - **修正学习率：使用梯度平方的指数加权平均**
- **原理：**Adam 是结合了 **Momentum** 和 **RMSProp** 优化算法的优点的自适应学习率算法。它计算了梯度的一阶矩（平均值）和二阶矩（梯度的方差）的自适应估计，从而动态调整学习率。
- 梯度计算公式：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$$

$$s_t = \beta_2 s_{t-1} + (1-\beta_2) gt^2$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{s}_t = \frac{s_t}{1-\beta_2^t}$$

- 权重参数更新公式:

$$w_t = w_{t-1} - \frac{\eta}{\sqrt{\hat{s}_t}+\epsilon}\hat{m}_t$$

其中，m_t 是梯度的一阶矩估计，s_t 是梯度的二阶矩估计，$\hat{m}_t$ 和 $\hat{s}_t$ 是偏差校正后的估计。

梯度下降的优化方法-Adam

```
def test04():
    # 1 初始化权重参数
    w = torch.tensor([1.0], requires_grad=True)
    loss = ((w ** 2) / 2.0).sum()

    # 2 实例化优化方法：Adam算法，其中betas是指数加权的系数
    optimizer = torch.optim.Adam([w], lr=0.01,betas=[0.9,0.99])

    # 3 第1次更新 计算梯度，并对参数进行更新
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

    print('第1次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
    # 4 第2次更新 计算梯度，并对参数进行更新
    # 使用更新后的参数机选输出结果
    loss = ((w ** 2) / 2.0).sum()
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()
    print('第2次: 梯度w.grad: %f, 更新后的权重:%f' % (w.grad.numpy(), w.detach().numpy()))
```

输出结果:
第1次: 梯度w.grad: 1.000000, 更新后的权重:0.990000
第2次: 梯度w.grad: 0.990000, 更新后的权重:0.980003

学习率衰减方法-等间隔学习率衰减

等间隔学习率衰减方式如下所示：

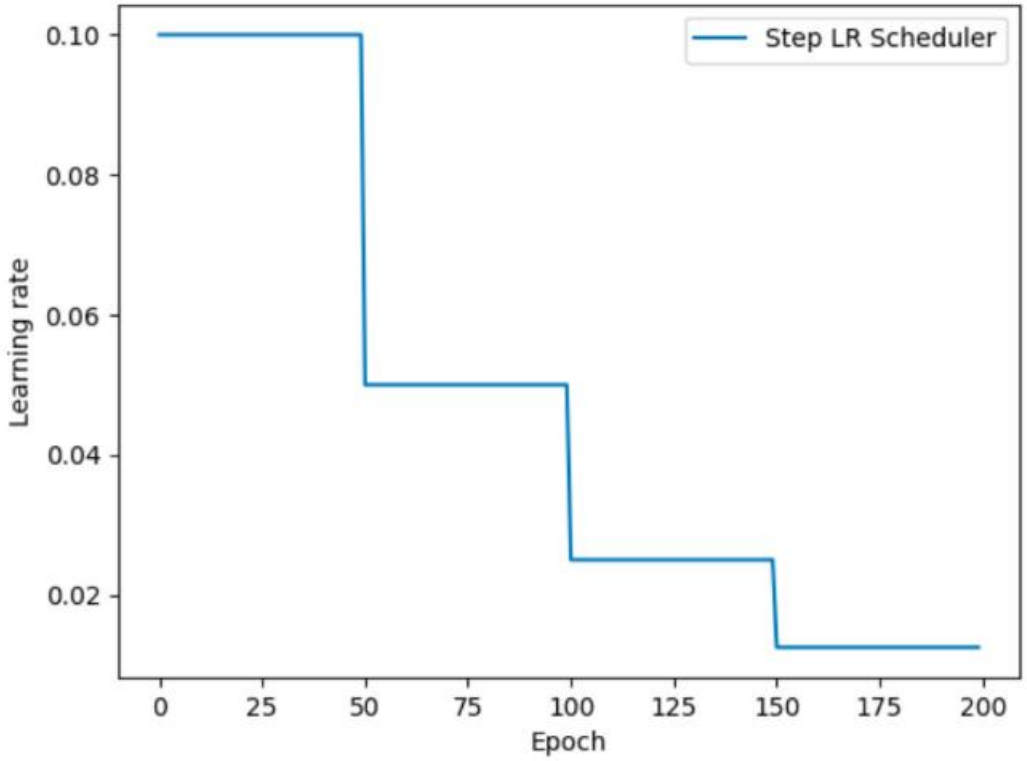


```
#   step_size：调整间隔数=50
#   gamma：调整系数=0.5
#   调整方式：lr = lr * gamma
lr_scheduler.StepLR(optimizer, step_size, gamma=0.1)
```

学习率衰减方法-等间隔学习率衰减

```
def test_StepLR():
    # 0.参数初始化
    LR = 0.1  # 设置学习率初始化值为0.1
    iteration = 10
    max_epoch = 200
    # 1 初始化参数
    y_true = torch.tensor([0])
    x = torch.tensor([1.0])
    w = torch.tensor([1.0], requires_grad=True)
    # 2.优化器
    optimizer = optim.SGD([w], lr=LR, momentum=0.9)
    # 3.设置学习率下降策略
    scheduler_lr = optim.lr_scheduler.StepLR(optimizer, step_size=50, gamma=0.5)
    # 4.获取学习率的值和当前的epoch
    lr_list, epoch_list = list(), list()
```

学习率衰减方法-等间隔学习率衰减方法

```
for epoch in range(max_epoch):
    lr_list.append(scheduler_lr.get_last_lr()) # 获取当前lr
    epoch_list.append(epoch) # 获取当前的epoch
    for i in range(iteration):  # 遍历每一个batch数据
        loss = ((w*x-y_true)**2)/2.0 # 目标函数
        optimizer.zero_grad()
        # 反向传播
        loss.backward()
        optimizer.step()
    # 更新下一个epoch的学习率
    scheduler_lr.step()
# 5.绘制学习率变化的曲线
plt.plot(epoch_list, lr_list, label="Step LR Scheduler")
plt.xlabel("Epoch")
plt.ylabel("Learning rate")
plt.legend()
plt.show()
```

学习率优化方法-指定间隔学习率衰减

指定间隔学习率衰减的效果如下：

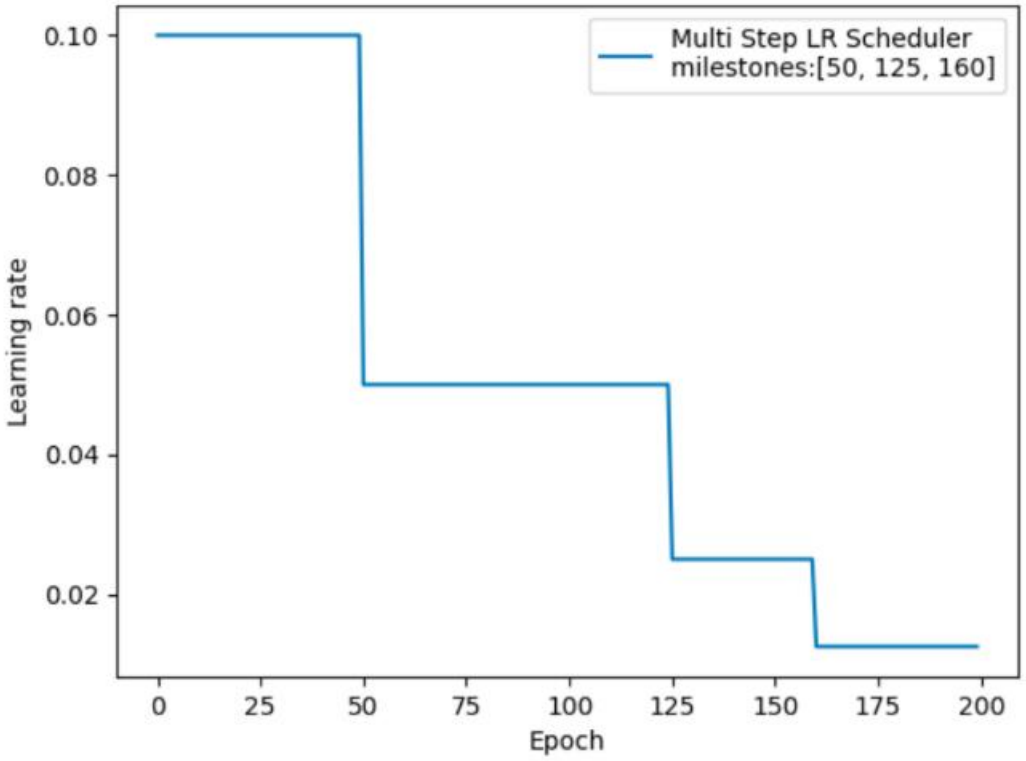


```
# milestones：设定调整轮次:[50, 125, 160]
# gamma：调整系数
# 调整方式：lr = lr * gamma
optim.lr_scheduler.MultiStepLR(optimizer, milestones,
gamma=0.1)
```

学习率优化方法-指定间隔学习率衰减

```
def test_MultiStepLR():
    torch.manual_seed(1)
    LR = 0.1
    iteration = 10
    max_epoch = 200
    weights = torch.randn((1), requires_grad=True)
    target = torch.zeros((1))
    print('weights--->', weights, 'target--->', target)
    optimizer = optim.SGD([weights], lr=LR, momentum=0.9)
    # 设定调整时刻数
    milestones = [50, 125, 160]
    # 设置学习率下降策略
    scheduler_lr = optim.lr_scheduler.MultiStepLR(optimizer,
milestones=milestones, gamma=0.5)
    lr_list, epoch_list = list(), list()
```

学习率优化方法-指定间隔学习率衰减

```
for epoch in range(max_epoch):
    lr_list.append(scheduler_lr.get_last_lr())
    epoch_list.append(epoch)
    for i in range(iteration):
        loss = torch.pow((weights - target), 2)
        optimizer.zero_grad()
        # 反向传播
        loss.backward()
        # 参数更新
        optimizer.step()
    # 更新下一个epoch的学习率
    scheduler_lr.step()
plt.plot(epoch_list, lr_list, label="Multi Step LR Scheduler\nmilestones:{}".format(milestones))
plt.xlabel("Epoch")
plt.ylabel("Learning rate")
plt.legend()
plt.show()
```

学习率优化方法-按指数学习率衰减

按指数学习率衰减的效果如下：

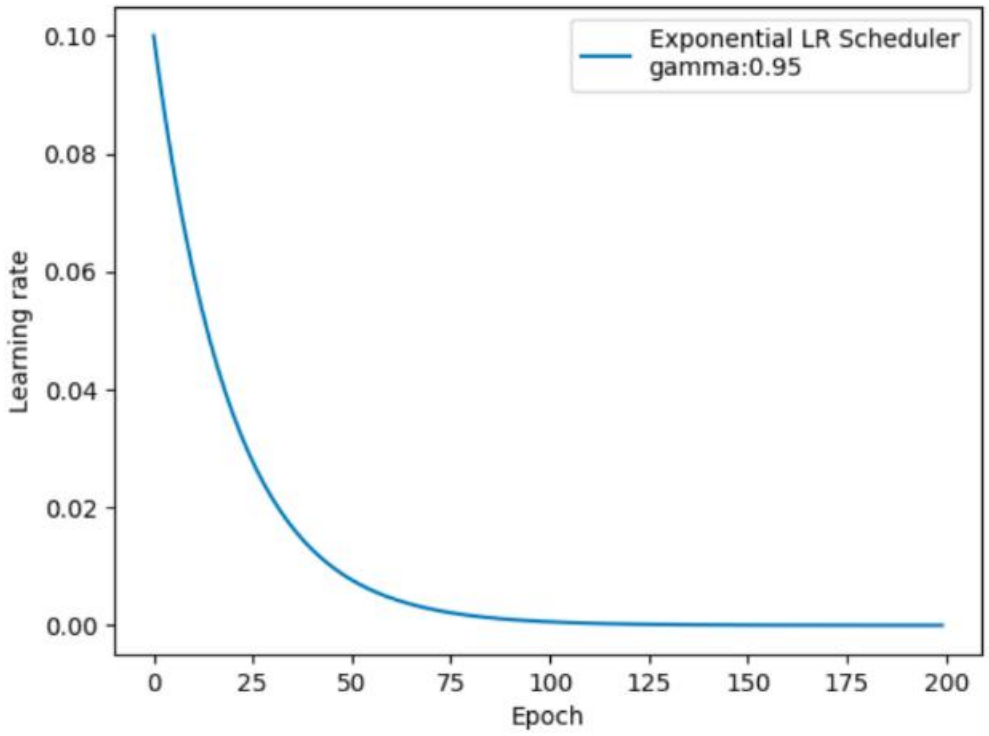


```
# gamma：指数的底
# 调整方式
# lr= lr*  gamma^epoch
optim.lr_scheduler.ExponentialLR(optimizer, gamma)
```

学习率优化方法-按指数学习率衰减

```
def test_ExponentialLR():
    # 0.参数初始化
    LR = 0.1  # 设置学习率初始化值为0.1
    iteration = 10
    max_epoch = 200
    # 1 初始化参数
    y_true = torch.tensor([0])
    x = torch.tensor([1.0])
    w = torch.tensor([1.0], requires_grad=True)
    # 2.优化器
    optimizer = optim.SGD([w], lr=LR, momentum=0.9)
    # 3.设置学习率下降策略
    gamma = 0.95
    scheduler_lr = optim.lr_scheduler.ExponentialLR(optimizer,
gamma=gamma)
    # 4.获取学习率的值和当前的epoch
    lr_list, epoch_list = list(), list()
```

学习率优化方法-按指数学习率衰减

```
for epoch in range(max_epoch):
    lr_list.append(scheduler_lr.get_last_lr())
    epoch_list.append(epoch)
    for i in range(iteration):  # 遍历每一个batch数据
        loss = ((w*x-y_true)**2)/2.0
        optimizer.zero_grad()
        # 反向传播
        loss.backward()
        optimizer.step()
    # 更新下一个epoch的学习率
    scheduler_lr.step()
# 5.绘制学习率变化的曲线
plt.plot(epoch_list, lr_list, label="Multi Step LR Scheduler")
plt.xlabel("Epoch")
plt.ylabel("Learning rate")
plt.legend()
plt.show()
```

总结

梯度下降优化方法汇总

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

学习目标

Learning Objectives

1. 知道正则化的作用
2. 掌握随机失活DropOut策略
3. 知道BN层的作用

正则化

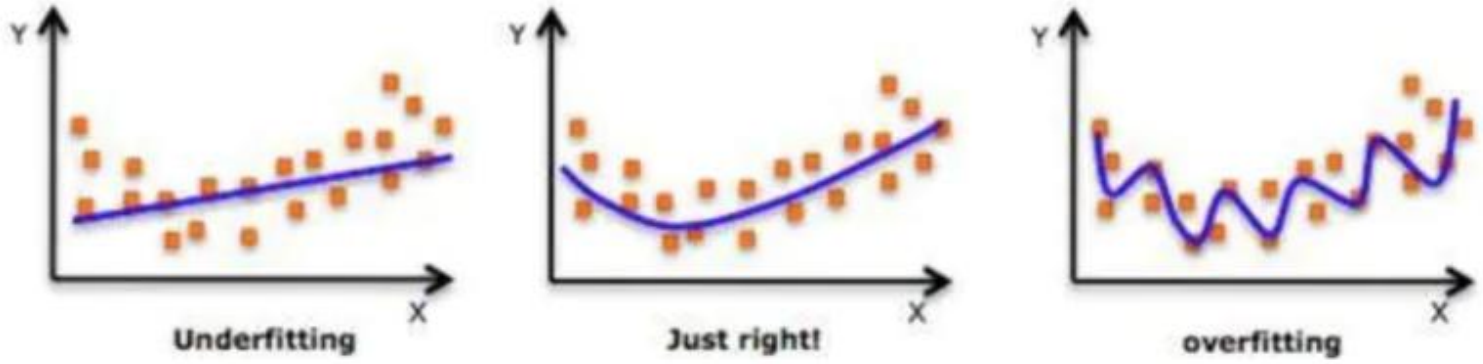

- 在设计机器学习算法时希望在新样本上的泛化能力强。许多机器学习算法都采用相关的策略来减小测试误差，这些策略被统称为正则化。
- 神经网络强大的表示能力经常遇到过拟合，所以需要使用不同形式的正则化策略。
- 目前在深度学习中使用较多的策略有**范数惩罚**，DropOut，**特殊的网络层等**，接下来我们对其进行详细的介绍。

Dropout正则化

在练神经网络中模型参数较多，在数据量不足的情况下，很容易过拟合。Dropout（随机失活）是一个简单有效的正则化方法。

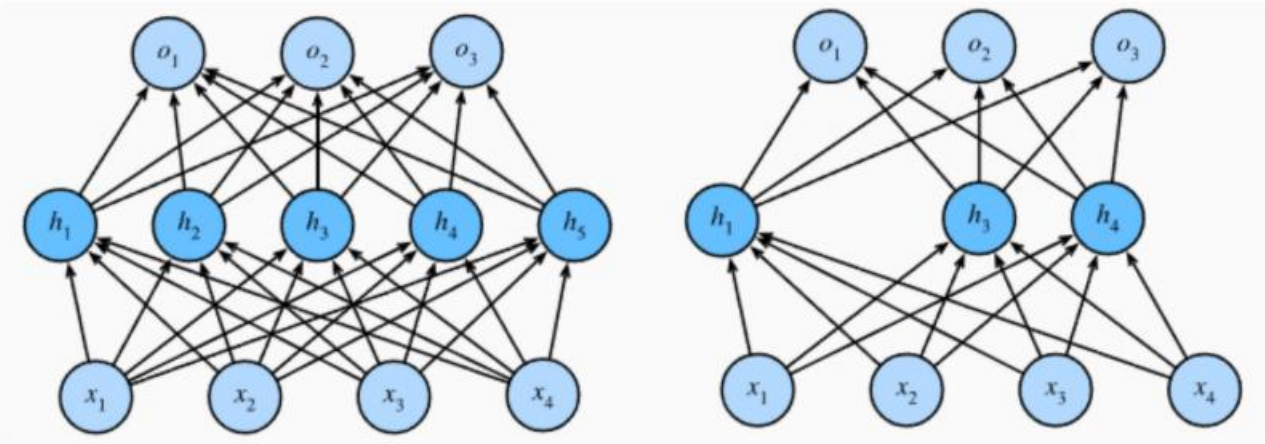

- 在训练过程中，Dropout的实现是**让神经元以超参数p的概率停止工作或者激活被置为0,未被置为0的进行缩放，缩放比例为1/(1-p)**。训练过程可以认为是对完整的神经网络的一些子集进行训练，每次基于输入数据只更新子网络的参数。
- **在测试过程中，随机失活不起作用。**

Dropout正则化

```
import torch
import torch.nn as nn

def test():
    # 初始化随机失活层
    dropout = nn.Dropout(p=0.4)
    # 初始化输入数据:表示某一层的weight信息
    inputs = torch.randint(0, 10, size=[1, 4]).float()
    layer = nn.Linear(4,5)
    y = layer(inputs)
    print("未失活FC层的输出结果：\n", y)

    y =  dropout(y)
    print("失活后FC层的输出结果：\n", y)
```

输出结果:

```
未失活FC层的输出结果：
 tensor([[-0.8369, -5.5720, 0.2258, 3.4256, 2.1919]],
     grad_fn=<AddmmBackward0>)

失活后FC层的输出结果：
 tensor([[-1.3949, -9.2866, 0.3763, 0.0000, 3.6531]],
grad_fn=<MulBackward0>)
```

上述代码将 Dropout 层的概率 p 设置为 0.4，此时经过 Dropout 层计算的张量中就出现了很多 0 ，未变为0的按照（1/(1-0.4)）进行处理。

批量归一化(Batch Normalization)

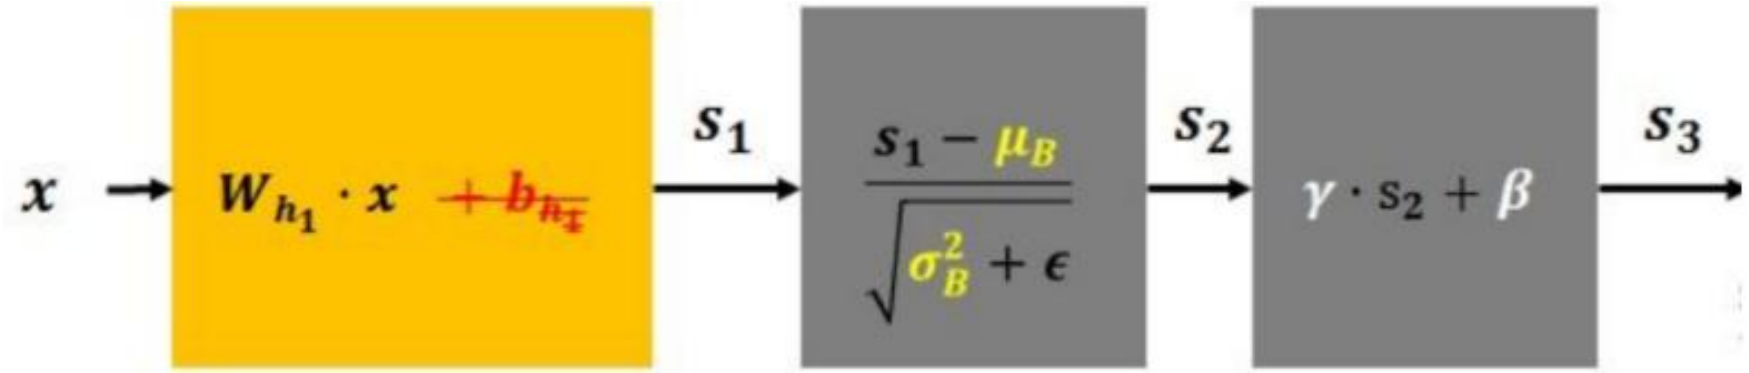

先对数据标准化，再对数据重构（缩放+平移），如下所示：

$$f(x) = \lambda \cdot \frac{x - E(x)}{\sqrt{Var(x) + \epsilon}} + \beta$$

1. λ 和 β 是可学习的参数，它相当于对标准化后的值做了一个**线性变换**，λ **为系数**，β **为偏置**；
2. eps 通常指为 1e-5，避免分母为 0；
3. E(x) 表示变量的均值；
4. Var(x) 表示变量的方差；

批量归一化层在计算机视觉领域使用较多。

批量归一化(Batch Normalization)

```
import torch
import torch.nn as nn

m = nn.BatchNorm2d(2, eps=1e-05, momentum=0.1, affine=True)  # affine参数设为True表示weight和bias将被使用
input = torch.randn(1, 2, 3, 4)
print("input-->", input)

output = m(input)
print("output-->", output)
print(output.size())

print(m.weight)
print(m.bias)
```

输出结果:

```
input--> tensor([[[[-0.2751, -1.2183, -0.5106, -0.1540],
        [-0.4585, -0.5989, -0.6063,  0.5986],
        [-0.4745,  0.1496, -1.1266, -1.2377]],

       [[ 0.2580,  1.2065,  1.4598,  0.8387],
        [-0.4586,  0.8938, -0.3328,  0.1192],
        [-0.3265, -0.6263,  0.0419, -1.2231]]]])
output--> tensor([[[[ 0.4164, -1.3889, -0.0343,  0.6484],
        [ 0.0655, -0.2032, -0.2175,  2.0889],
        [ 0.0349,  1.2294, -1.2134, -1.4262]],

       [[ 0.1340,  1.3582,  1.6853,  0.8835],
        [-0.7910,  0.9546, -0.6287, -0.0452],
        [-0.6205, -1.0075, -0.1449, -1.7779]]]],
      grad_fn=<NativeBatchNormBackward0>)
torch.Size([1, 2, 3, 4])
Parameter containing:
tensor([1., 1.], requires_grad=True)
Parameter containing:
tensor([0., 0.], requires_grad=True)
```

总结

1、正则化的作用

缓解过拟合

2、随机失活DropOut策略

让神经元以超参数p的概率停止工作或者激活被置为0

3、BN层是什么？

对数据标准化，再对数据重构（缩放+平移）

目录

Contents

- 神经网络
- 激活函数
- 参数初始化
- 损失函数
- 网络优化方法
- 正则化方法
- 案例-价格分类案例

学习目标

Learning Objectives

1. 掌握构建分类模型流程
2. 动手实践整个过程

需求分析

小明创办了一家手机公司，他不知道如何估算手机产品的价格。为了解决这个问题，他收集了多家公司的手机销售数据。该数据为二手手机的各个性能的数据，最后根据这些性能得到4个价格区间，作为这些二手手机售出的价格区间。主要包括：

```
battery_power：电池一次可储存的总能量，单位为毫安时
blue ：是否有蓝牙
clock_speed：微处理器执行指令的速度
dual_sim：是否支持双卡
fc：前置摄像头百万像素
four_g：是否有4G
int_memory：内存（GB）
m_dep：移动深度（cm）
mobile_wt：手机重量
n_cores：处理器内核数
pc：主摄像头百万像素
px_height：像素分辨率高度
px_width：像素分辨率宽度
ram：随机存取存储器（兆字节）
sc_h：手机屏幕高度（cm）
sc_w：手机屏幕宽度（cm）
talk_time：一次电池充电持续时间最长的时间
three_g：是否有3G
touch_screen：是否有触控屏
wifi：是否能连wifi
price_range：价格区间（0，1，2，3）
```

需求分析

我们需要帮助小明找出手机的功能（例如：RAM等）与其售价之间的某种关系。我们可以使用机器学习的方法来解决这个问题，也可以构建一个全连接的网络。

需要注意的是：在这个问题中，我们**不需要预测实际价格**，而是**一个价格范围**，它的范围**使用 0、1、2、3 来表示**，所以该问题也是一个**分类问题**。接下来我们还是按照四个步骤来完成这个任务：

- 准备训练集数据
- 构建要使用的模型
- 模型训练
- 模型预测评估

导入所需的工具包

```
# 导入相关模块
import torch
from torch.utils.data import TensorDataset
from torch.utils.data import DataLoader
import torch.nn as nn
import torch.optim as optim
from sklearn.datasets import make_regression
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import time
```

构建数据集

数据共有 2000 条，其中 1600 条数据作为训练集，400 条数据用作测试集。 我们使用 sklearn 的数据集划分工作来完成。并使用 PyTorch 的 TensorDataset 来将数据集构建为 Dataset 对象，方便构造数据集加载对象。

```
# 构建数据集
def create_dataset():
    # 使用pandas读取数据
    data = pd.read_csv('data/手机价格预测.csv')
    # 特征值和目标值
    x, y = data.iloc[:, :-1], data.iloc[:, -1]
    # 类型转换：特征值，目标值
    x = x.astype(np.float32)
    y = y.astype(np.int64)
    # 数据集划分
    x_train, x_valid, y_train, y_valid = train_test_split(x, y, train_size=0.8, random_state=88)
    # 构建数据集,转换为pytorch的形式
    train_dataset = TensorDataset(torch.from_numpy(x_train.values), torch.tensor(y_train.values))
    valid_dataset = TensorDataset(torch.from_numpy(x_valid.values), torch.tensor(y_valid.values))
    # 返回结果
    return train_dataset, valid_dataset, x_train.shape[1], len(np.unique(y))
```

获取数据的结果

```
if __name__ == '__main__':
    # 获取数据
    train_dataset, valid_dataset, input_dim, class_num = create_dataset()
    print("输入特征数：", input_dim)
    print("分类个数：", class_num)
```

输出结果为：

输入特征数： 20

分类个数： 4

构建分类网络模型

构建全连接神经网络来进行手机价格分类，该网络主要由三个线性层来构建，使用relu激活函数。

网络共有 3 个全连接层，具体信息如下：

1. 第一层：输入为维度为 20，输出维度为：128
2. 第二层：输入为维度为 128，输出维度为：256
3. 第三层：输入为维度为 256，输出维度为：4

构建分类网络模型

```
# 构建网络模型
class PhonePriceModel(nn.Module):
    def __init__(self, input_dim, output_dim):
        super(PhonePriceModel, self).__init__()
        # 1. 第一层: 输入为维度为 20, 输出维度为: 128
        self.linear1 = nn.Linear(input_dim, 128)
        # 2. 第二层: 输入为维度为 128, 输出维度为: 256
        self.linear2 = nn.Linear(128, 256)
        # 3. 第三层: 输入为维度为 256, 输出维度为: 4
        self.linear3 = nn.Linear(256, output_dim)

    def forward(self, x):
        # 前向传播过程
        x = torch.relu(self.linear1(x))
        x = torch.relu(self.linear2(x))
        output = self.linear3(x)
        # 获取数据结果
        return output
```

构建分类网络模型

模型实例化：

```
if __name__ == '__main__':
    # 模型实例化
    model = PhonePriceModel(input_dim, class_num)
    summary(model,input_size=(input_dim,),batch_size= 16)
```

```
----------------------------------------------------------------
        Layer (type)               Output Shape         Param #
================================================================
            Linear-1                  [16, 128]           2,688
            Linear-2                  [16, 256]          33,024
            Linear-3                    [16, 4]           1,028
================================================================
Total params: 36,740
Trainable params: 36,740
Non-trainable params: 0
----------------------------------------------------------------
Input size (MB): 0.00
Forward/backward pass size (MB): 0.05
Params size (MB): 0.14
Estimated Total Size (MB): 0.19
----------------------------------------------------------------
```

模型训练

网络编写完成之后，我们需要编写训练函数。所谓的训练函数，指的是输入数据读取、送入网络、计算损失、更新参数的流程，该流程较为固定。我们使用的是多分类交叉生损失函数、使用 SGD 优化方法。最终，将训练好的模型持久化到磁盘中。

```
# 模型训练过程
def train(train_dataset,input_dim,class_num,):
    # 固定随机数种子
    torch.manual_seed(0)
    # 初始化数据加载器
    dataloader = DataLoader(train_dataset, shuffle=True, batch_size=8)
    # 初始化模型
    model = PhonePriceModel(input_dim, class_num)
    # 损失函数
    criterion = nn.CrossEntropyLoss()
    # 优化方法
    optimizer = optim.SGD(model.parameters(), lr=1e-3)
    # 训练轮数
    num_epoch = 50
```

编写训练函数

```
# 遍历每个轮次的数据
for epoch_idx in range(num_epoch):
    # 训练时间
    start = time.time()
    # 计算损失
    total_loss = 0.0
    total_num = 0
    # 遍历每个batch数据进行处理
    for x, y in dataloader:
        # 将数据送入网络中进行预测
        output = model(x)
        # 计算损失
        loss = criterion(output, y)
        # 梯度清零
        optimizer.zero_grad()
        # 反向传播
        loss.backward()
        # 参数更新
        optimizer.step()
        # 损失计算
        total_num += 1
        total_loss += loss.item()
    # 打印损失变换结果
    print('epoch: %4s loss: %.2f, time: %.2fs' %(epoch_idx + 1, total_loss / total_num, time.time() - start))
# 模型保存
torch.save(model.state_dict(), 'model/phone.pth')
```

模型训练

调用训练函数：

```
if __name__ == '__main__':
    # 获取数据
    train_dataset, valid_dataset, input_dim, class_num = create_dataset()
    # 模型训练过程
    train(train_dataset,input_dim,class_num )
```

训练结果如下所示：

```
epoch:    1 loss: 13.10, time: 0.11s
epoch:    2 loss: 0.97, time: 0.09s
epoch:    3 loss: 0.92, time: 0.10s
epoch:    4 loss: 0.89, time: 0.10s

。。。。
epoch:   48 loss: 0.69, time: 0.10s
epoch:   49 loss: 0.71, time: 0.09s
epoch:   50 loss: 0.71, time: 0.10s
```

编写评估函数

使用训练好的模型，对未知的样本的进行预测的过程。我们这里使用前面单独划分出来的验证集来进行评估。

```python
def test(valid_dataset,input_dim,class_num):

    # 加载模型和训练好的网络参数
    model = PhonePriceModel(input_dim, class_num)
    model.load_state_dict(torch.load('model/phone.pth'))

    # 构建加载器
    dataloader = DataLoader(valid_dataset, batch_size=8, shuffle=False)

    # 评估测试集
    correct = 0
    # 遍历测试集中的数据
    for x, y in dataloader:
        #  将其送入网络中
        output = model(x)
        # 获取类别结果
        y_pred = torch.argmax(output, dim=1)
        # 获取预测正确的个数
        correct += (y_pred == y).sum()
    # 求预测精度
    print('Acc: %.5f' % (correct.item() / len(valid_dataset)))
```

```python
if __name__ == '__main__':
    # 获取数据
    train_dataset, valid_dataset, input_dim, class_num = create_dataset()
    # 模型预测结果
    test(valid_dataset,input_dim,class_num)
```

输出结果:

Acc: 0.64250

总结

1. 案例的整体流程是：

- 数据集构建
- 模型构建
- 模型训练
- 模型预测

今日作业

我们前面的网络模型在测试集的准确率为：0.64250，

我们可以通过以下方面进行调优：

1. 优化方法由 SGD 调整为 Adam
2. 学习率由 1e-3 调整为 1e-4
3. 对数据进行标准化
4. 增加网络深度，即：增加网络参数量
5. 调整训练轮次
6. ...

黑马程序员
www.itheima.com
传智教育旗下高端IT教育品牌